硕 士 学 位 论 文

城市交通信号控制大语言模型方法研究与系统实现

Research and System Implementation of Urban Traffic Signal Control Methods Based on Large Language Models

作 者 姓 名: 王之颢

学 号: 32209118

指 导 教 师: 孙景昊 王宝财 (企业导师)

学科、 专业: 计算机技术

答 辩 日 期: 2025 年 6 月

大连理工大学

Dalian University of Technology

中国知网 https://www.cnki.net

硕士学位论文答辩委员会

答辩人: 王之颢

答辩委员会委员:

大连理工大学教授: 申彦明 （注: 主席）

大连理工大学教授: 林恺

大连理工大学副教授: 周惠巍

大连理工大学副教授: 徐齐

大连理工大学助理教授: 罗午阳

答辩日期: 2025 年 06 月 05 日

答辩地点: 大连理工大学第一教学馆 1-206

中国知网 https://www.cnki.net

摘要

智能交通系统（Intelligent Transportation Systems，ITS）作为现代城市建设的核心基础设施，其技术演进与创新应用正持续推动城市交通治理模式的深刻变革。作为ITS中的关键子系统，交通信号控制直接关系到城市路网运行效率与公共出行服务质量。近年来，随着人工智能技术取得突破性进展，特别是大语言模型（Large Language Model，LLM）在自然语言处理领域大放异彩后，其应用场景正逐步延伸至其它领域，为城市智能交通管控提供了全新的研究思路。本文聚焦于大语言模型在交通信号控制领域的应用展开研究，主要研究内容如下:

（1）本文提出了一种基于强化学习辅助训练的动态交通信号控制大模型方法。首先，针对现有信号控制方法存在的控制粒度较粗、状态表征不足等问题，设计了一种融合邻居信息的动态交通信号控制强化学习算法。该算法设计了注意力机制驱动的邻居信息融合模块，通过特征交叉增强路网表征能力，并引入动态相位调控机制，实现了相位与持续时间的协同优化。随后，针对强化学习方法在扩展性、泛化能力和可信度方面的固有局限，以及通用LLM领域知识匮乏难以直接应用于信号控制的问题，设计了强化学习辅助的两阶段LLM微调训练框架，以强化学习算法作为辅助模型指导LLM的训练全过程，使LLM理解信号控制任务的内在逻辑，最终获得性能优越的动态交通信号控制大模型。在真实世界杭州城市路网数据下的实验结果表明，本文提出的信号控制大模型对比当前SOTA方法，关键评价指标平均旅行时间的性能综合提升了4.43%，充分证明了本文方法的有效性。经过训练的信号控制大模型不仅能够做出精准高效的控制决策，还能提供决策依据，有效缓解了传统强化学习方法因“黑箱”机制导致的透明度不足问题，同时展现出优秀的扩展性和泛化能力。

（2）本文构建了交通信号控制智能体系统，将所提出的信号控制大模型与交通仿真软件相结合，构建了包括交通状态感知、信号控制决策和交通状态更新在内的闭环信号控制系统，实现了真实世界历史交通数据回放与LLM决策流程的可视化。进一步地，本文提出了一个面向智能交通领域的通用智能体系统，充分发挥LLM在任务理解逻辑推理与规划决策方面的优势，深度融合交通工具的专业能力，通过全自然语言交互即可完成复杂交通任务，为城市交通管理提供了更加全面、智能的解决方案。实验结果表明，本文设计的智能体系统在指令遵循、格式生成与多步任务处理等方面均表现优异。

关键词：智能交通系统；大语言模型；交通信号控制

中国知网 https://www.cnki.net

ABSTRACT

Intelligent Transportation Systems (ITS) serve as a core infrastructure in modern urban development, with their technological advancements and innovative applications continuously driving profound changes in urban traffic governance models. As a key subsystem of ITS, traffic signal control directly impacts the operational efficiency of urban road networks and the quality of public transportation services. In recent years, breakthroughs in artificial intelligence technologies—especially the remarkable success of Large Language Models (LLMs) in natural language processing—have gradually expanded their application scenarios to other domains, offering novel research perspectives for intelligent urban traffic management. This paper focuses on the application of large language models in the field of traffic signal control and presents the following main research contributions:

(1) This paper proposes a dynamic traffic signal control large model method based on reinforcement learning-assisted training. First, to address the issues of coarse-grained control and insufficient state representation in existing signal control approaches, we design a reinforcement learning algorithm for dynamic traffic signal control that incorporates neighborhood information. This algorithm features an attention mechanism-driven module for fusing neighbor information, enhancing the representation capability of the road network through feature interaction. Additionally, a dynamic phase adjustment mechanism is introduced to achieve coordinated optimization of phase selection and duration. Subsequently, considering the inherent limitations of reinforcement learning methods in scalability, generalization ability, and reliability, as well as the lack of domain knowledge in general-purpose LLMs that hinders their direct application to signal control tasks, a two-stage LLM fine-tuning framework guided by reinforcement learning is designed. In this framework, the reinforcement learning algorithm acts as an auxiliary model to guide the entire training process of the LLM, thereby improving the LLM's understanding the internal logic of signal control tasks and ultimately obtaining a high-performance dynamic traffic signal control large model. Experimental results using real-world data from Hangzhou city demonstrate that the proposed signal control large model improves the comprehensive performance of the key evaluation metric average travel time by 4.43% compared to current state-of-the-art methods, validating the effectiveness of the proposed approach. The trained signal control large model not only makes accurate and efficient control decisions but also provides decision rationales, effectively alleviating the transparency issues caused by the "black-box" nature of traditional reinforcement learning methods. Moreover, it demonstrates excellent scalability and generalization capa-

中国知网 https://www.cnki.net

bilities.

(2) This paper constructs a traffic signal control agent system by integrating the proposed signal control large model with traffic simulation software. This system includes traffic state perception, signal control decision-making, and traffic state updating, forming a closed-loop signal control system that enables replay of real-world historical traffic data alongside visualization of the LLM decision-making process. Then, this paper further proposes a general agent system for the field of intelligent transportation that leverages the strengths of LLMs in task understanding, logical reasoning, and planning decision-making. By deeply integrating professional capabilities of traffic tools, the system allows complex traffic tasks to be completed through fully natural language interaction, providing a more comprehensive and intelligent solution for urban traffic management. Experimental results show that the designed agent system performs excellently in command following, format generation, and multi-step task processing.

Key Words: Intelligent Transportation System; Large Language Model; Traffic Signal Control

中国知网 https://www.cnki.net

目　录

1 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....2
1.2.1 传统方法在交通信号控制领域研究现状.....2
1.2.2 大语言模型在交通信号控制领域研究现状.....3
1.2.3 智能交通智能体研究现状.....4
1.3 论文研究内容.....5
1.4 论文章节结构.....6
2 相关技术与知识.....7
2.1 深度强化学习.....7
2.1.1 深度 Q 网络.....7
2.1.2 近端策略优化.....7
2.2 预训练语言模型.....8
2.2.1 Transformer 架构.....9
2.2.2 BERT 模型.....11
2.2.3 GPT 模型.....12
2.2.4 大语言模型.....14
2.3 交通信号控制经典算法.....14
2.3.1 SOTL 算法.....14
2.3.2 MaxPressure 算法.....15
2.3.3 CoLight 算法.....16
2.4 本章小结.....18
3 交通信号控制系统模型与问题定义.....19
3.1 路网结构建模.....19
3.1.1 道路与车道建模.....19
3.1.2 交叉口建模.....20
3.2 信号相位与持续时间建模.....21
3.3 问题定义.....23
3.4 本章小结.....24
4 基于强化学习辅助训练的动态交通信号控制大模型方法.....25
4.1 问题背景.....25
4.2 融合邻居信息的动态交通信号控制强化学习算法.....27
4.2.1 状态、动作及奖励定义.....27
4.2.2 邻居交叉口信息融合模块设计.....28

中国知网　https://www.cnki.net

4.2.3 强化学习模型总体框架.....32
4.3 智能交通信号控制大模型方法.....34
4.4 强化学习模型辅助的两阶段高效微调训练框架.....37
4.4.1 基于大参数量模型推理数据的监督微调.....38
4.4.2 基于强化学习模型排序的偏好对齐微调.....40
4.5 实验设置与准备.....43
4.5.1 数据集.....43
4.5.2 评价指标.....44
4.5.3 基线方法.....45
4.5.4 实验设置.....46
4.6 实验结果与分析.....47
4.6.1 相位持续时间敏感性实验.....47
4.6.2 主实验结果与分析.....48
4.6.3 可迁移性实验与分析.....51
4.6.4 极端高流量实验与分析.....53
4.7 消融实验.....54
4.7.1 邻居信息融合模块的影响.....54
4.7.2 奖励平衡系数 η 的影响.....55
4.7.3 两阶段训练流程有效性验证.....56
4.7.4 对齐微调损失函数中 NLL 损失函数系数 λ 的影响.....57
4.8 本章小结.....58
5 基于大语言模型的智能体系统实现.....59
5.1 问题背景.....59
5.2 交通信号控制智能体系统.....59
5.2.1 系统总体框架.....59
5.2.2 系统前后端搭建.....60
5.3 智能交通智能体系统.....61
5.3.1 系统总体框架.....61
5.3.2 智能体工作流程.....62
5.3.3 工具模块.....65
5.3.4 系统前后端搭建.....68
5.4 实验与分析.....69
5.4.1 训练数据集收集.....69
5.4.2 实验设置与准备.....69
5.4.3 任务执行能力实验.....70
5.5 本章小结.....72
6 结论与展望.....74
6.1 结论.....74

中国知网 https://www.cnki.net

6.2 创新点.....75
6.3 展望.....75
参考文献.....76

中国知网 https://www.cnki.net

图 目 录

图 2.1 Transformer 架构图 9
图 2.2 BERT 模型结构 11
图 2.3 GPT 模型结构 13
图 2.4 大语言模型的发展历程 14
图 2.5 MaxPressure 算法在 t 时刻至 $t+1$ 时刻的运行示意图 16
图 2.6 CoLight 算法框架图 17
图 3.1 路网拓扑结构示意图 19
图 3.2 交叉口结构与相位示意图 21
图 4.1 网格型交叉口和异构交叉口结构示意图 25
图 4.2 本章总体研究框架 26
图 4.3 交叉口与车道的状态定义 27
图 4.4 不同方位邻居对目标交叉口的影响 29
图 4.5 邻居关系特征融合模块结构 30
图 4.6 邻居作用强度评估模块结构 31
图 4.7 强化学习模型总体框架图 32
图 4.8 特征提取网络结构 33
图 4.9 大模型工作流程图 34
图 4.10 任务背景提示模板 35
图 4.11 交通状态提示模板 36
图 4.12 推理思维链提示模板 37
图 4.13 大模型方法两阶段高效微调训练框架 38
图 4.14 济南和杭州数据集路网 44
图 4.15 各方法迁移前后 ATT 指标对比图 52
图 5.1 交通信号控制智能体系统框架 60
图 5.2 基于大语言模型的交通信号控制智能体系统可视化 61
图 5.3 智能体总体框架图 62
图 5.4 基于大语言模型的智能交通智能体工作流程图 63
图 5.5 主智能体提示模板 64
图 5.6 可视化示例 66
图 5.7 交通问答智能体工作流程图 67
图 5.8 智能交通智能体系统前端交互界面展示 68
图 5.9 不同 LLM 智能体系统生成格式准确率 72

中国知网 https://www.cnki.net

表 目 录

表 4.1 1920 条随机数据上 LLM 所选相位动作的分数分布 39
表 4.2 随机数据上 LLM 决策得分的最高分与最低分差值分布 42
表 4.3 数据集具体信息 43
表 4.4 极端高流量模拟数据集具体信息 44
表 4.5 本研究主要比较的基线方法 45
表 4.6 不同相位持续时间下模型性能比较 47
表 4.7 不同相位持续时间集合下模型性能比较 47
表 4.8 各方法在济南数据集上的总体表现 48
表 4.9 各方法在杭州数据集上的总体表现 49
表 4.10 本章方法相较于各基线方法的性能提升或下降情况 50
表 4.11 主流方法可迁移性实验 51
表 4.12 极端高流量场景下主流方法性能 53
表 4.13 邻居信息融合模块对模型性能的影响 54
表 4.14 奖励平衡系数 η 对模型性能的影响 55
表 4.15 两阶段训练流程有效性实验 56
表 4.16 NLL 损失函数系数 λ 对模型性能的影响 57
表 5.1 不同 LLM 智能体系统任务成功率对比 71

中国知网 https://www.cnki.net

主要符号表

符号	代表意义	单位或定义
英文字母		
S	状态	\
A	动作	\
R	奖励	\
F	特征	\
X	提示词	\
Y	大语言模型响应	\
希腊字母		
η	奖励平衡系数	\
π	策略	\
λ	NLL 损失系数	\
σ	sigmoid 函数	\
下标		
ref	参考模型	\
θ	模型参数	\
缩写		
DQN	深度 Q 网络	\
LLM	大语言模型	\
NLL	负对数似然	\
DPO	直接偏好优化	\

注：如文中对符号另有说明，以文中对应位置说明为准。

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景与意义

随着社会经济的快速发展和城市化进程的不断加快，机动车保有量迅速增长，交通拥堵已成为制约城市可持续发展的关键瓶颈问题，其不仅造成巨大的经济损失和环境污染，还为城市交通治理带来了严峻挑战。在此背景下，构建高效、智能的交通信号控制系统，已成为现代智能交通系统发展的核心任务。智能交通系统[1]通过充分利用物联网、云计算、互联网、人工智能、自动控制、移动互联网等前沿技术，实现对交通信息的高效集成与处理，为交通管理、运输组织以及公众出行等提供全面支持与优化。当前交通信号控制领域的研究主要采用启发式方法或强化学习方法，但这两类方法均存在一定的局限性：

（1）启发式方法[2–4]通常基于预设的规则来调整信号相位。这类方法在面对复杂、动态变化的交通流时表现出较差的适应能力，其优化目标往往较为单一，且扩展性有限。此外，单个交叉口设计的控制规则难以实现多交叉口之间的协调控制，并且高度依赖人工设定规则，当交通模式变化时，需要重新设计和调整规则，导致维护成本较高。

（2）强化学习方法[5–12]虽然展现出优于传统启发式方法的性能，但仍面临诸多挑战。一方面，现有方法未能充分考虑交叉口之间的异质性以及信息交互对齐问题，限制了算法的可扩展性；另一方面，模型在迁移性与泛化性方面存在显著瓶颈，针对特定路网训练的模型在新环境中会出现明显的性能衰减。此外，强化学习固有的“黑盒”特性使其缺乏可解释性，限制了其在实际交通控制系统中的可信度与应用前景。

近年来，随着基于大规模通用语料预训练的 Transformer[13]模型的发展，预训练语言模型在自然语言处理任务中的表现卓越，引起了学术界广泛关注。研究表明，随着模型参数规模的增大，模型性能出现了显著提高，并且涌现出一些小规模模型所不具备的特殊能力[14]。为此，学术界提出了大语言模型（Large Language Model, LLM）这一概念，特指那些因参数规模增大而涌现出独特能力的语言模型。尤其是 OpenAI 推出的基于 LLM 构建的强大 AI 聊天机器人——ChatGPT，标志着人工智能技术和应用进入了一个新的阶段，推动了整个人工智能领域的发展，预示着 AI 算法开发与应用模式的重大转变。

在智能交通系统快速发展的当下，将大语言模型的先进能力引入交通领域具有重要的研究价值与应用前景。LLM 凭借其卓越的常识理解、逻辑推理[15, 16]、规划决策能力以及强大的泛化性能，能够有效支持交通信号控制策略的制定与优化，并提供精准的交通状况分析与决策建议，显著缓解传统方法在扩展性、泛化性以及可信度方面

中国知网 https://www.cnki.net

的局限。同时，LLM 还可以模拟人类专家的决策过程，为智能交通系统带来新的解决方案。基于上述研究背景，本文将深入探讨大语言模型在智能交通系统中的技术潜力，重点聚焦其在交通信号控制与智能体系统这两个关键场景中的应用研究，旨在为智能交通领域的发展提供新的实践方向。

1.2 国内外研究现状

本节首先将围绕智能交通系统中的交通信号控制核心任务展开研究综述，梳理该领域的研究现状，从传统的启发式方法到现代强化学习算法的演进过程进行系统阐述。随后，本节将重点探讨大语言模型在交通信号控制任务中的创新应用。最后，本节将进一步扩展研究视野，分析以大语言模型为核心的智能体系统在智能交通领域的研究现状。通过这种递进式的结构，旨在全面呈现智能交通控制技术的发展脉络以及大语言模型在其中的应用现状。

1.2.1 传统方法在交通信号控制领域研究现状

在智能交通系统的具体任务中，交通信号控制作为提升城市交通流畅度与安全性的重要环节，是近年来的研究与应用热点。传统方法主要依赖于交通工程启发式方法[2–4] 或强化学习方法[5–12]。交通工程启发式方法依据预先设定的规则来调整信号相位时序，以适应不同时间段内的流量变化。Koonce[2] 等人提出了基于历史交通流量统计数据来确定信号相位及其持续时间的 FixedTime 算法。其中信号相位的顺序被设定为固定且循环执行，并且每个相位的持续时间也是预设固定的。在实际部署过程中，相位顺序及持续时间将根据历史交通流量数据进行适应性调整，以此达到优化交通流效率的目的。Varaiya[3] 等人提出了 MaxPressure 算法，一种基于交通压力概念的启发式算法，通过激活具有最大压力值的相位来优化交通流。“压力”具体被定义为上游路段排队车辆数与下游路段排队车辆数之间的差值，该方法首先计算每个相位所对应路段的压力值，随后比较这些压力值，并选择压力最大的相位进行激活。相位的持续时间可以设定为一个固定值，或者依据当前的压力数值进行动态调整，即按照压力大小成比例地调控持续时间。

不同于交通工程启发式方法，强化学习方法则通过在环境中的试错过程让系统学习最优策略，从而实现对交通信号的有效控制。Chen[5] 等人指出传统交通工程方法难以满足大规模网络的实际需求，在实际部署过程中面临诸多挑战。为此，他们提出了 MPLight 算法，一种基于去中心化深度强化学习的交通信号控制算法。该算法沿用了启发式方法中对压力的定义，即上游与下游车辆队列长度之差，利用这一概念来实现区域层面的信号协调。通过最小化系统内的压力，旨在均衡车辆分布并最大化整体吞吐量，并采用在所有交叉口之间共享模型参数，使得单一模型能够从不同位置接收观测数据、预测相应动作，从而根据环境反馈调整其参数，有效地协调和控制大规模城

中国知网 https://www.cnki.net

市中的交通信号。

Wei[8] 等人指出传统交通信号控制方法通过预先设定两个交叉口间的偏移量来促进协作，但这种方法难以适应动态变化的交通环境，由于交叉口的流量及影响会随时间而变化，这就对实时通信与建模提出了挑战。为此，他们提出了 CoLight 算法，一种基于图注意力网络的强化学习算法，利用图注意力机制来优化交叉口间的信息交流，能够将邻近交叉口的时间和空间影响纳入决策过程之中，且无需提前计算特定的索引值。通过动态通信和无索引建模的方式，该方法能够在多种网络结构和交通流量模式下实现高效的交通信号控制。

而随着强化学习方法研究的深入，Zhang[10] 等人指出传统方法缺乏灵活性，无法适应复杂的动态交通流，并且现有基于强化学习的方法在状态表示方面存在局限性。为解决上述问题，该研究创新性地提出了基于交通流有效压力和有效运行车辆数量的状态表征方法，以更精确地刻画交通优化需求。实验结果表明，采用该状态表达方法的强化学习算法在交通信号相位控制任务中达到了当前最先进的性能水平。

随后，Zhang 等人[11] 对现有交通信号控制方法进行了深入分析，指出传统单阶段控制策略在动态交通环境下的灵活性和适应性存在显著局限。现有方法通常采用固定相位持续时间策略，仅进行信号相位切换决策，导致系统缺乏动态调节能力，难以适应实时交通流变化。为解决上述问题，该研究提出了 DynamicLight 算法，一种新颖的两阶段控制算法。该算法首先确定最优相位切换策略，继而根据实时交通状态动态调整相位持续时间，从而实现了交通信号控制的动态调节，使交通信号控制系统能够更加有效地应对交通流量的变化，显著提升了系统整体性能及对不同交通环境的适应能力。

1.2.2 大语言模型在交通信号控制领域研究现状

随着 LLM 表现出的强大类人推理能力，研究人员开始探索将 LLM 应用于交通信号控制任务的可能性。相关研究通过利用 LLM 对复杂交通模式的理解和推理决策能力，旨在实现更加智能、更加精确、交通流更高效的交通信号控制，以期减少交通拥堵让交通流运转加倍顺畅。

Da[17] 等人指出尽管强化学习在交通模拟环境中表现优异，但在实际部署时仍面临性能下降的问题，这主要是由于模拟环境与现实世界之间存在系统动态的差异。为解决这一问题，该研究提出了 PromptGAT 算法，一种利用大型语言模型的知识来缩小从模拟到现实应用中的性能差距的创新方法。该研究基于提示学习技术，将 LLM 的推理能力应用于理解系统动态的变化，并设计了一个基于提示的动态建模模块，能够整合车道状态、车道级别的领域知识以及动态信息，从而将 LLM 的知识作为强化学习状态表示的补充。最终提高了前向模型在动作转换过程中的准确性，并显著提升了模型的整体性能，为交通信号控制任务提供了一种新的思路和解决方案。

中国知网 https://www.cnki.net

Pang 等人[18] 指出现有的基于强化学习的交通信号控制任务在通信退化的条件下表现不佳。传统方法往往忽略了因数据包丢失、传输延迟和环境噪声等因素引起的观测误差问题，且现有奖励机制的设计未能充分纳入紧急交通状况的特殊需求，导致控制策略在实际应用中的可靠性受限。为解决上述问题，该研究提出了一种名为 iLLM-TSC 的任务框架。该框架首先让强化学习智能体根据当前观测到的交通数据作出初步决策。随后，通过设计结构化提示模板将交通场景转换成自然语言描述来让 LLM 介入以评估这些决策的合理性，并在必要时进行调整。最终形成了一个两阶段的决策流程，首先是基于直接观测数据的强化学习决策，然后是 LLM 基于更广泛环境上下文对决策进行优化。该研究通过在交通信号控制领域引入 LLM，弥补了传统方法在现实世界尤其是通信条件不佳或面对罕见事件时处理能力不足的问题。

上述方法的核心思想通常是利用大型语言模型的强大推理能力来增强传统强化学习模型在交通信号控制任务中的性能。然而，这种方法可能未能充分发挥 LLM 的全部潜力。因此，也有研究尝试将 LLM 作为决策主体应用于交通信号控制任务中，并取得了显著成效，展现了直接利用 LLM 执行此类任务的可能性及其潜在优势。

Lai 等人[19] 指出传统交通信号控制方法在处理多样化交通场景时，特别是在大规模道路网络与极端情况下，存在泛化能力有限的问题，并且深度强化学习方法普遍存在的黑箱特性，也限制了其在实际应用中的可信度。为解决这些问题，该研究创新性地提出了基于 LLM 的智能交通控制智能体框架，为路网中的每个交叉口配备专门的 LLM 智能体负责信号控制。在每个信号切换的时间步，智能体会收集目标交叉口的实时交通状况，并构建一个包含实时观测数据、交通场景描述、任务说明及常识知识的提示，以此来指导 LLM 的决策过程。实验结果表明，该方法在多个数据集上均达到了最先进的性能水平，充分展示了 LLM 在交通信号控制任务中的卓越性能与适用性。更重要的是，基于 LLM 的信号控制方法还能为每次决策提供合理的自然语言解释，显著提升了系统的透明度和可解释性，展现了其在智能交通系统中的应用潜力。

1.2.3 智能交通智能体研究现状

近年来，一些研究尝试将 LLM 应用于智能交通系统中，以构建具备信息处理与决策能力的智能体。通过结合特定工具，这类智能体能够高效处理复杂的交通数据，并借助 LLM 强大的逻辑推理能力，完成诸如交通管理、安全监控以及自动驾驶等上层任务，显著提升了交通系统的智能化水平。

Zhang 等人[20] 提出了一种基于大语言模型的智能体框架，通过将 LLM 与交通领域基础模型相结合，赋予 LLM 查看、分析和处理交通数据的能力，旨在提升城市交通管理和控制水平。该研究设计了一个多层次的系统架构，首先构建了一个数据库管理层，用于整合来自视频监控、交通检测器和模拟系统等多元数据源；在此基础上，利用 LLM 作为顶层协调器，通过自然语言交互识别用户需求并规划任务执行流程，最

中国知网 https://www.cnki.net

终实现了从自然语言输入到自然语言输出的完整闭环。实验结果表明，该智能体在面对交通管理任务时展现出卓越的逻辑推理和执行能力，为构建更高效、智能和可持续的城市交通管理系统提供了新的技术路径。

Li 等人[21] 指出现代交通系统日益增长的复杂性对从业人员提出了更高要求，尤其是新手和基层工作者往往面临专业知识门槛高、学习曲线陡峭等挑战。为应对这一问题，该研究创新性提出了一种基于 LLM 的智能体框架，旨在通过自然语言交互降低交通仿真模拟的技术门槛。该研究首先通过大规模数据训练和人类反馈强化学习对智能体进行优化，使其在指令理解、任务专注度和执行效率等方面表现显著提升，最终实现了用户仅需输入自然语言描述，系统即可将抽象道路网络数据转化为可执行模型，以及将特定地理区域自动转换为 SUMO 交通模拟场景，从而使用户无需掌握专业的交通仿真知识即可完成复杂操作。实验结果表明，该框架有效简化了交通模拟场景的生成、定制和交互全流程，为交通仿真技术的普及应用提供了新的解决方案。

1.3 论文研究内容

本文以交通信号控制任务为研究切入点，首先对交通信号控制系统进行建模。在此基础上，针对控制任务所依托的道路网络结构、控制逻辑中的信号相位及其持续时间进行了系统建模，并对交通信号控制问题进行了明确定义。通过分析可知，交通信号控制本质上是一个动态决策优化问题，其核心在于优化控制策略。这一建模过程不仅为后续研究提供了统一的理论基础，也为开发面向交通信号控制的深度学习算法奠定了坚实的基础。本文的主要研究工作围绕以下两个方面展开：

（1）本文提出了一种基于强化学习辅助训练的动态交通信号控制大模型方法。首先，本文设计了一种融合邻居信息的动态交通信号控制强化学习算法。在特征表示层面，设计了邻居信息融合模块，使智能体能够有效利用邻居路口的信息，实现多交叉口协同优化以及对交通环境更全面的观测特征表示；在控制机制层面，设计了相位与持续时间协同调控机制，实现了更灵活与更细粒度的动态信号控制，并将该模型作为后续大模型方法的辅助模型。在此基础上，本文进一步引入 LLM 替代传统强化学习模型，在交通信号控制任务中承担决策功能。通过设计结构化提示模板，将交通环境状态转化为自然语言提示作为 LLM 的输入，LLM 的输出包含相位与持续时间的动作选择以及相应的决策依据，并据此更新交通环境状态，循环往复实现信号控制与优化。为了使 LLM 更好地掌握交通信号控制任务的内在逻辑和动态调控能力，本文还设计了一种两阶段微调训练框架。在整个训练过程中，以强化学习模型作为辅助，隐式引导 LLM 的学习过程，使其逐步具备对复杂交通场景的理解与决策能力。

（2）本文构建了一个交通信号控制智能体系统，以本文所提出的信号控制大模型为核心，实现了一个支持与主流交通仿真软件交互的闭环信号控制系统。在此基础上，

中国知网 https://www.cnki.net

本章进一步设计了一个面向智能交通领域的通用智能体系统，将大语言模型与交通专业工具深度集成，构建了一个可交互的智能体框架。系统通过自然语言交互方式显著降低了使用门槛，用户只需用自然语言描述任务需求，智能体即可自动完成任务的分解、规划，自主调用合适的专业工具，并通过迭代思考确保任务完成质量。本文还开发了相应的前后端交互系统，直观展示了智能体从需求理解到任务完成的完整工作流程，最终使不具备专业工具操作经验的新手用户，也能通过自然语言交互轻松完成复杂的专业级任务。

1.4 论文章节结构

本文各章节内容安排如下：

第一章为绪论部分。本章首先从智能交通系统的发展需求出发，结合当前交通信号控制任务面临的挑战以及人工智能技术的突破性进展，阐述了本课题的研究背景与意义。随后，对交通信号控制领域的传统方法、大模型方法以及智能交通智能体的国内外研究现状进行综述。最后，整理并概括了本文研究内容与章节安排。

第二章为相关技术与知识。本章概述了本文研究所涉及的基础理论与技术，为后续研究奠定基础。

第三章为交通信号控制系统模型与问题定义。本章对交通信号控制系统进行建模，并对交通信号控制问题进行了清晰的定义，为后续算法研究提供理论基础。

第四章为基于强化学习辅助训练的动态交通信号控制大模型方法。本章首先提出了一种融合邻居信息的动态交通信号控制强化学习算法，详细阐述了邻居信息融合模块的设计原理与实现方法，并介绍了算法的网络结构以及智能体的工作流程。在此基础上，本章设计了一种两阶段微调训练框架，以上述强化学习算法作为辅助模型指导 LLM 的训练过程，有效缓解通用 LLM 领域知识匮乏的问题，优化 LLM 对信号控制任务的理解，最终获得性能优越的动态交通信号控制大模型。本章在济南和杭州的真实交通数据集上进行了全面的对比实验，实验结果充分证明了本章方法的有效性。

第五章为基于大语言模型的智能体系统实现。本章首先以第四章提出的动态交通信号控制大模型为基础，构建了信号控制智能体系统，形成了从环境感知、决策制定到环境更新的闭环信号控制系统。在此基础上，本章进一步设计了一个面向智能交通领域的通用智能体系统，旨在拓展其在更广泛交通场景中的应用能力，通过整合包括前述交通信号控制智能体在内的多种工具模块，能够高效应对各类复杂的交通问题，提升交通管理的智能化水平。

第六章为结论与展望部分。本章首先对全文研究工作进行总结，并提炼了本文的研究创新点，随后基于本文研究内容与成果对后续研究方向进行思考与展望。

中国知网 https://www.cnki.net

2 相关技术与知识

2.1 深度强化学习

2.1.1 深度 Q 网络

深度 Q 网络（Deep Q-Network，DQN）是由 DeepMind[22] 提出的经典深度强化学习算法，通过结合深度神经网络与 Q-learning 算法，解决了传统强化学习在高维状态空间中的局限性。DQN 的核心思想是用深度神经网络近似 Q 值函数 $Q(s,a)$，取代传统 Q-learning 中的 Q 表，其关键技术包括：

（1）经验回放区（Replay Buffer）：用于存储智能体的经验 (s,a,r,s')，训练时随机采样以打破数据相关性，提升稳定性。

（2）目标网络：使用独立的目标网络计算目标 Q 值，定期同步主网络参数，减少目标波动。

（3）ϵ-贪婪策略：平衡探索与利用，智能体以概率 ϵ 随机选择动作，否则选择当前最优动作。

在训练阶段时，算法首先从经验回放区随机采样批次数据，计算目标 Q 值，计算公式如 2.1 所示。

$$y = r + \gamma \max_{a'} Q(s', a'; \theta^-) \tag{2.1}$$

其中，y 为计算得到的目标 Q 值，r 为即时奖励，s' 为下一时间步状态，a' 为目标网络在 s' 下选择的动作，θ 是主网络参数，θ^- 是目标网络参数，γ 为折扣因子。

随后，通过梯度下降更新主网络参数，损失函数与参数更新计算公式如 2.2 所示，并定期同步目标网络参数，循环往复直至模型训练收敛。

$$\begin{aligned} L(\theta) &= \mathbb{E}\left[(y - Q(s,a;\theta))^2\right] \\ \theta &\leftarrow \theta - \alpha \cdot \nabla_\theta L(\theta) \end{aligned} \tag{2.2}$$

其中，s 为当前时间步状态，a 为主网络在 s 下选择的动作，α 为学习率。

随着研究的深入，研究人员发现传统的 DQN 算法存在 Q 值过估计与 ϵ-贪婪策略缺乏针对性等问题，容易导致算法收敛到次优解。针对这些问题，目前也衍生了多种 DQN 的改进与变体算法[23–27]。

2.1.2 近端策略优化

近端策略优化（Proximal Policy Optimization，PPO）是由 OpenAI[28] 提出的强化学习算法，旨在通过限制策略更新的幅度来平衡探索与利用，同时解决传统策略梯度

中国知网 https://www.cnki.net

方法的复杂性和训练稳定性问题。PPO 的核心思想是通过约束新旧策略之间的差异来确保策略更新的稳定性，其关键技术包括：

（1） 重要性采样 ：在无法直接从目标分布 $p(x)$ 采样时，通过另一个易采样的分布 $q(x)$ 来估计期望值。在 PPO 中通过重要性采样将旧策略生成的数据用于优化新策略，提高样本效率。

（2）优势函数估计：使用广义优势估计（Generalized Advantage Estimation，GAE）计算优势函数，以平衡偏差与方差，更准确评估动作的价值，计算公式如式 2.3 所示。

$$\begin{aligned} A(s_t, a_t) &= \sum_{k=0}^{T-t} (\gamma\lambda)^k \delta_{t+k} \\ \delta_t &= r_t + \gamma V(s_{t+1}) - V(s_t) \end{aligned} \tag{2.3}$$

其中，γ 为折扣因子，λ 为平滑参数，$V(s_t)$ 为状态价值函数，衡量在状态 s_t 下，遵循当前策略 π 所能获得的 期望累积回报。

（3）裁剪机制：替代原始目标函数，通过约束新旧策略之间的差异，确保更新后的策略不会偏离旧策略太远，裁剪后的目标函数公式如 2.4 所示。

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) A_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon) A_t \right) \right] \tag{2.4}$$

其中，$r_t(\theta)$ 为新旧策略的概率比，衡量策略变化程度。A_t 为优势函数，衡量当前动作相对于平均表现的优劣。ϵ 为裁剪阈值，控制策略更新幅度。

PPO 算法的实现流程可分为数据采集、优势估计和网络优化三个阶段。首先，智能体基于当前策略 π_θ 与环境交互，采集包含状态 s_t、动作 a_t、即时奖励 r_t 和下一状态 s_{t+1} 等信息的完整轨迹数据。随后，算法利用收集的轨迹数据，结合状态价值函数 $V(s_t)$ 计算各时间步的优势函数估计值 $A(s_t, a_t)$。最后，在参数更新阶段，采用裁剪目标函数优化策略网络，采用价值估计与实际回报之间的均方误差优化价值网络。

2.2 预训练语言模型

预训练语言模型的兴起标志着自然语言处理研究迈入了一个全新的阶段。预训练语言模型通过在大规模且多样化的数据集上实施无监督或自监督学习，能够在无需特定人工标注的条件下，从海量文本数据中习得通用的语言表示。这一过程不仅促进了模型对语言内在结构的深入掌握，还显著增强了其在各类下游任务中的表现，推动了 NLP 领域的整体进步。

随着深度学习技术的快速发展以及硬件资源和可获取数据量的丰富，预训练语言模型的设计逐渐趋向于更大规模。在此背景下，基于 Transformer 架构的模型因其在自然语言处理任务中的卓越性能、出色的可扩展性以及强大的迁移学习能力，逐

中国知网 https://www.cnki.net

渐成为预训练语言模型领域的主流选择。本节将重点介绍 Transformer 架构的核心原理，并深入分析 BERT（Bidirectional Encoder Representations from Transformers）和 GPT（Generative Pre-trained Transformer）这两类对预训练语言模型发展产生深远影响的代表性模型。

2.2.1 Transformer 架构

Vaswani 等人[13] 在其开创性论文《Attention Is All You Need》中提出了革命性的 Transformer 架构。Transformer 摒弃了传统的循环神经网络（Recurrent Neural Network，RNN）结构，创新性地完全基于注意力机制进行设计，能够直接建模序列中任意两个词元之间的依赖关系，不仅有效解决了 RNN 在处理长距离依赖时存在的梯度消失和计算效率低下等问题，还在处理长序列任务时展现出显著的性能优势。这一突破性进展为自然语言处理领域带来了范式转变，奠定了后续大语言模型发展的基础。

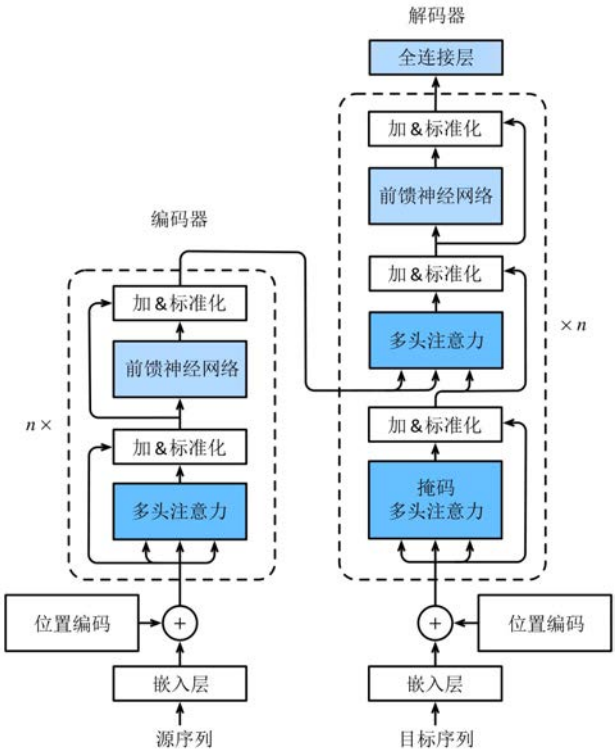


图 2.1 Transformer 架构图

Fig. 2.1 Transformer Architecture Diagram

Transformer 采用编码器——解码器架构，如图 2.1 所示，其每一侧分别由 N 个结构相同且顺序堆叠的编码器层和解码器层构成。编码器负责将输入序列映射为高维向量空间中的隐状态表示，以捕捉并编码输入数据的内在结构和特征；解码器则基于编码器输出的隐状态表示，通过自回归方式逐步生成目标序列。这种分层堆叠的设计使得模型能够逐级提取和组合不同抽象层次的特征信息。

中国知网 https://www.cnki.net

编码器内部包含两个子层，分别是多头注意力（Multi-Head Attention）与前馈神经网络，子层间均采用残差连接[29]（Residual Connection）以促进信息流动并加速训练过程，在残差连接加法运算后紧接着应用层标准化[30]（Layer Normalization）。解码器的设计与编码器相比，在多头注意力与前馈神经网络两个子层之间额外插入了一个多头交叉注意力层，其中查询来自前一个解码器层的输出，而键和值来自整个编码器的输出。而在解码器自注意力机制中，查询、键和值都来自上一个解码器层的输出，并且解码器中的每个位置只能考虑该位置之前的所有位置，即采用了掩码（Masked）注意力确保预测仅依赖于已生成的输出词元。

多头注意力机制允许模型并行学习多个不同表征空间中的注意力表示，每个注意力头独立地计算注意力权重，从而捕捉输入序列中多样化的信息模式。Transformer 模型中除了解码器的多头交叉注意力层利用了不同来源的输入外，其余部分所使用的多头注意力机制均采用自注意力（Self-Attention），即查询、键和值三个矩阵的输入均源自同一序列。给定查询 $\boldsymbol{q} \in \mathbb{R}^{d_q}$、键 $\boldsymbol{k} \in \mathbb{R}^{d_k}$ 和值 $\boldsymbol{v} \in \mathbb{R}^{d_v}$，那么每个注意力头的计算公式如式 2.5 所示。

$$\begin{cases} \boldsymbol{Q}_i = \boldsymbol{W}_i^q \boldsymbol{q} \\ \boldsymbol{K}_i = \boldsymbol{W}_i^k \boldsymbol{k} \\ \boldsymbol{V}_i = \boldsymbol{W}_i^v \boldsymbol{v} \\ \boldsymbol{h}_i = f(\boldsymbol{Q}_i, \boldsymbol{K}_i, \boldsymbol{V}_i) \end{cases} \tag{2.5}$$

其中，$\boldsymbol{W}_i^q$、$\boldsymbol{W}_i^k$、$\boldsymbol{W}_i^v$ 为可训练的参数矩阵，$f(\cdot)$ 为注意力汇聚函数。在 Transformer 中通常采用缩放点积注意力，使用 d_h 表示每个注意力头对应的维度，那么缩放点积注意力的计算公式如式 2.6 所示。

$$f(\boldsymbol{Q}_i, \boldsymbol{K}_i, \boldsymbol{V}_i) = \text{softmax}(\frac{\boldsymbol{Q}_i \boldsymbol{K}_i^T}{\sqrt{d_h}}) \boldsymbol{V}_i \tag{2.6}$$

多头注意力机制由多个子注意力机制组合而成，在获取所有 h 个头的计算结果后，为了整合这些来自不同注意力头的信息，需要将它们拼接并通过一个额外的线性层进行处理。设这个额外线性层的可训练参数为 $\boldsymbol{W}_o$，生成的最终输出为 $\boldsymbol{O}$，那么具体计算过程如式 2.7 所示。

$$\boldsymbol{O} = \boldsymbol{W}_o \begin{bmatrix} \boldsymbol{h}_1 \\ \vdots \\ \boldsymbol{h}_h \end{bmatrix} \tag{2.7}$$

从模型架构设计的角度来看，Transformer 利用自注意力机制有效地捕捉输入序列中任意两个元素间的依赖关系，对于上下文理解、语义关联以及处理长距离依赖性问题尤为关键。多头注意力机制进一步增强了这种能力，使模型能够同时关注不同维度

中国知网 https://www.cnki.net

的特征，从而丰富了对输入数据的理解并提升了表达能力。在训练方面，Transformer 摒弃了传统的循环结构，转而使用线性变换和逐元素操作，简化了训练过程，降低了训练难度并加速了训练。此外，其高度可扩展的特点允许通过增加网络深度或宽度来提升模型容量，确保在大规模数据集上进行有效训练，为复杂任务提供强有力的支持。目前，基于 Transformer 架构的模型已在人工智能多个领域得到广泛应用，如计算机视觉与自然语言处理等主流方向，并在这些应用中展现了卓越的性能。

2.2.2 BERT 模型

在 Transformer 模型提出的初期，自然语言处理领域针对特定任务仍依赖于大规模标注数据驱动的监督学习方法。然而很多任务标注数据较少，仍需要进行大量人工标注工作，使研究者们探索更高效的解决方案。因此，学术界的研究焦点逐渐转向如何利用丰富的无监督数据[31, 32] 来学习上下文信息的词向量表示。在此背景下，Google 在 2018 年提出了 BERT[33]，一种基于多层 Transformer 编码器堆叠的预训练模型，模型基本结构如图 2.2 所示。

BERT 在处理信息时采用双向注意力机制，即输入序列每个位置的元素都能够同时考虑前后文的信息，从而实现更深层次的语义理解并学习到更丰富的上下文依赖关系。在对文本进行编码前，BERT 要先对输入进行分词（Tokenization）处理为词元（Token），并在句首和句尾分别插入特殊标记“[CLS]”和“[SEP]”，前者汇集整个句子的特征表示，后者用作句子间的分隔符，以区分同一输入中的不同句子或段落。

BERT 在对文本编码时考虑了三种类型的嵌入：词嵌入（Token Embedding）、片段嵌入（Segment Embedding）、位置嵌入（Position Embedding）。词嵌入表征了词元本身的含义；片段嵌入表征了词元所处的句子位置信息；位置嵌入表征了词元在序列中的绝对位置。三种嵌入相加形成了每个词元的最终嵌入表示，作为后续的 BERT 编码器层的初始输入。

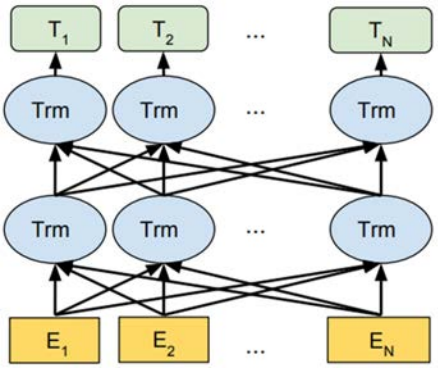


图 2.2 BERT 模型结构

Fig. 2.2 The architecture of BERT

在预训练阶段，BERT 采用两种自监督学习任务在未标注数据上进行训练。第一

中国知网 https://www.cnki.net

项任务是掩码语言建模（Masked Language Model, MLM），在该任务中将随机选取输入序列中 15% 的词元进行掩码处理。对于这些被选中的词元，其中的 80% 用特殊符号“[MASK]”替换；10% 随机替换成其他词元；剩余的 10% 则保持原样不变。随后，模型将基于上下文信息预测这些被遮蔽的词元。这一任务旨在训练模型在充分考虑上下文信息的基础上更精准地学习词元的语义特征，并且这种特殊的掩码机制还能够提升模型的泛化能力，使其更好地适应真实数据。第二项任务是下一句预测（Next Sentence Prediction，NSP），在该任务中将给定两个句子，要求判断第二个句子是否为第一个句子的直接后续句。在这些句子对中，有 50% 是连续的两句，而另 50% 则是随机选取不相关的句子配对。模型的任务是评估并确定这两句话是否具有连续性，即判断第二句是否为第一句的“下一个句子”，本质上是一个二分类问题。这一任务能够训练模型捕捉句子间的关联性，进而更深入地理解语义结构和上下文关系。

针对具体的下游任务，根据任务的特性在预训练的 BERT 模型后附加特定的可训练层，并利用标注数据对模型进行微调。微调后的模型能够适应具体的应用场景，提升其在特定任务上的性能。

BERT 的出现显著推动了预训练与微调范式在自然语言处理领域的研究。通过利用大规模无标签文本数据进行预训练，再针对具体任务使用相对少量的标注数据进行微调，这一方法大幅降低了为每个特定任务从零开始训练模型所需的时间和计算资源。BERT 在多个 NLP 基准测试中取得了当时最优的效果，不仅展示了其在自然语言理解任务上的强大能力，还促进了更多基于 BERT 改进的预训练语言模型研究[34–39]。

2.2.3 GPT 模型

GPT 模型的首次提出[40] 更早于 BERT，并且与 BERT 的仅编码器架构不同，GPT 采用了仅解码器堆叠的架构。与标准 Transformer 中的解码器相比，GPT 中的解码器去除了交叉注意力模块，只保留掩码自注意力与前馈神经网络模块。相较于 BERT 采用的双向注意力机制，GPT 采用因果注意力（Causal Attention）机制实现了不同的信息处理方式。具体来说，GPT 中每个位置的元素只能访问其自身及之前的信息，而无法预见后续的内容，模型只能依赖已有的历史信息预测下一个词元，这种设计更契合自然语言生成任务的需求。GPT 模型结构如图 2.3 所示。

在预训练阶段，GPT 通过大规模的未标注文本数据进行语言建模训练，主要任务是下一词预测，即使用已知序列上文来预测下一词元。在这个过程中，输入文本经过分词后，会为每个词元计算其词嵌入和位置嵌入，并作为模型的输入。在每次计算带掩码的多头自注意力时，来自未来时间步的信息在注意力矩阵中对应的值都被置为零，输出的向量随后会传递给后续解码器继续处理。解码器层的最终输出将经过一个线性层转换为词表中各个词的概率分布，从而预测下一个可能出现的词。这种预训练任务的设计能够让模型学习到语言的复杂模式，并且能够在生成文本时产生连贯且上

中国知网 https://www.cnki.net

下文相关的输出。

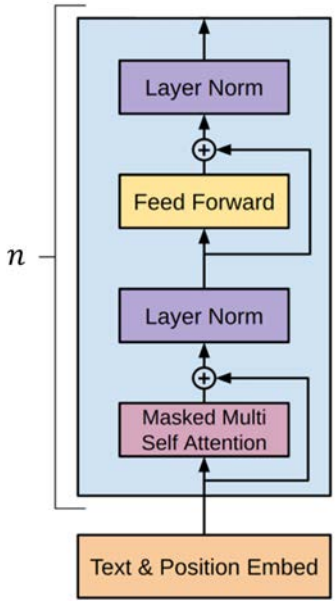


图 2.3　GPT 模型结构

Fig. 2.3　The architecture of GPT

然而，OpenAI 最初推出的 GPT-1 模型存在参数数量有限、预训练数据集规模较小以及预训练任务较复杂等问题，其训练和性能表现均不如同期的 BERT 模型。为了解决这些问题，OpenAI 的研究者们尝试增大模型参数量与训练数据量，随之提出了 GPT-2[41]，其参数量增长到了 15 亿，并采用更大规模预训练数据集以及引入了一些结构上的改进，例如将后置标准化（Post-norm）调整为前置标准化（Pre-norm）。GPT-2 沿用了与 GPT-1 相同的预训练任务，但通过参数量、数据量及模型结构的改进，模型整体性能得到了显著的提升。

GPT-2 提出了一种创新性的多任务学习思想，将不同的自然语言处理任务统一归结为上下文问题回答任务，采用提示词（Prompt）机制，通过输入自然语言文本序列，模型能够自主识别并适应不同的任务需求，进而在无需特定模块或参数的情况下，做出相应回答、完成相应任务。该方法将各种下游任务转化为上下文中的问答形式，使得模型仅依赖于自然语言提示即可执行多样化的操作，从而实现了 NLP 任务的统一处理框架。

随着研究的不断深入，OpenAI 的研究团队发现，伴随模型容量和训练数据量的增加，模型的性能潜力仍存在提升空间。基于这一认识，促使 OpenAI 研发了 GPT-3[42]，该模型参数量达到了 1750 亿，并且使用超大尺寸的隐向量维度与长上下文窗口。最终，在采用与前几代相同的预训练任务条件下，GPT-3 展现出了显著增强的通用能力和极为出色的零样本及少样本学习效果，为后续大语言模型开山之作 ChatGPT 奠定了坚实的基础。

中国知网　https://www.cnki.net

2.2.4 大语言模型

随着预训练语言模型研究的深入，研究者发现了一个重要现象：当模型参数量超过特定阈值时，会展现出一些在小规模模型中未曾观察到的特殊能力，这种现象被称为” 涌现”。基于这一发现，具有超大参数规模的预训练语言模型被称为大语言模型（Large Language Model, LLM），LLM 的提出标志着语言模型研究进入了一个新的发展阶段。

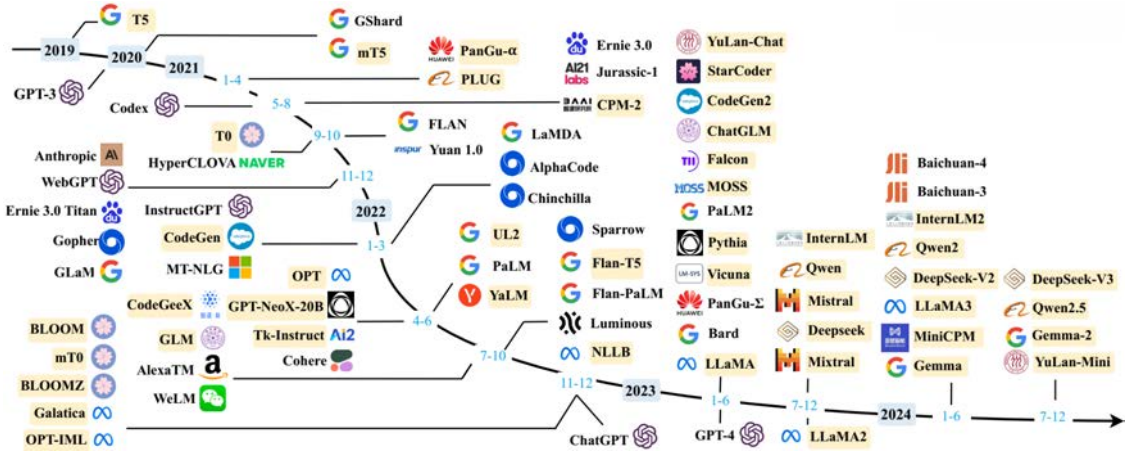


图 2.4 大语言模型的发展历程

Fig. 2.4 The development history of LLMs

基于仅解码器（decoder-only）架构的模型在文本生成方面具有显著优势，当前主流 LLM 普遍采用这一设计范式。在闭源模型阵营，最具代表性的是 GPT 系列后续模型，如 GPT-3.5、GPT-4 等迭代产品，不断取得 LLM 领域的新突破；而在开源模型阵营中，Llama 系列[43–45]、Qwen 系列[46–48] 与 DeepSeek 系列[49–52] 等同样展现出优秀的性能表现。这些不同路线的模型并行发展，共同推动了 LLM 领域的快速进步，图 2.4 展示了大语言模型的发展历程[53]。

2.3 交通信号控制经典算法

2.3.1 SOTL 算法

SOTL 是由 Cools 等人[3] 于 2008 年提出的一种启发式交通信号控制算法。该算法根据观测到的交通状况并结合预设的规则，来决定是继续保持当前相位还是切换至下一相位。

算法 2.1 展示了 SOTL 算法相位切换的具体逻辑。在该算法中，φ_i 为时间步计数器，用于记录自上一次相位切换以来经过的时间步数；$\varphi_{\min}$ 为最小时间步计数阈值；算法第 6 行表示如果当前时间步计数 φ_i 尚未达到 $\varphi_{\min}$，说明距离上次相位切换时间过短，系统将暂不进行新的相位切换，以防止过于频繁的切换。μ 为路口通行车辆数

中国知网 https://www.cnki.net

阈值，算法第 7 行表示如果当前绿灯相位下的通行车辆数 c_i^g 不小于 μ，则认为当前仍有较多车辆正在通过路口，不适合立即切换相位；反之，则说明当前车流量较小，具备切换相位的条件。θ 为排队车辆数阈值，若某一红灯相位 P 下的排队车辆数 c_i^r 超过阈值 θ，表明该方向交通压力较大，应激活该相位以缓解交通压力。

算法 2.1 SOTL 算法的相位切换逻辑

```
1:  for 每一时间步 τ_i do
2:      c_i^g = 绿灯相位下的正在通过路口的车辆数目;
3:      for 每一红灯相位 P do
4:          c_i^r = 红灯相位下的排队车辆数目;
5:          φ_i += 1;
6:          if (φ_i ≥ φ_min) then
7:              if not (c_i^g < μ) then
8:                  if (c_i^r ≥ θ) then
9:                      相位 P 激活，切换为绿灯;
10:                     φ_i = 0;
11:                 end if
12:             end if
13:         end if
14:     end for
15: end for
```

当以上三个条件均满足时，算法第 9 行执行激活红灯相位 P 并将其切换为绿灯，随后在第 10 行将时间步计数器 φ_i 清零，重新开始计数，进入下一个控制周期。

SOTL 算法通过预设规则实现交通信号控制，以低复杂度的简单策略应对城市交通管理问题，是一种提升交通效率的实用方法。然而，该算法存在一定的局限性：其规则是预先设定的，缺乏自适应能力，泛化性较差，难以有效应对多样化的交通状况；此外，该算法仅针对单一交叉口进行信号控制，未考虑多个交叉口之间的协同优化，限制了整体交通系统的运行效率。

2.3.2 MaxPressure 算法

MaxPressure 是由 Varaiya[3] 于 2013 年提出的一种启发式交通信号控制算法，旨在通过调整交通信号灯相位，最大化路网中的车辆通行能力，同时保持排队长度的稳定性。该算法定义了“压力”这一概念，用于衡量道路之间的交通状态差异，从而指导最优信号相位的选择，其具体定义如式 2.8 所示。

$$w(l,m)(X(t)) = x(l,m) - \sum_{p \in \text{Out}_m} r(m,p)x(m,p) \tag{2.8}$$

其中，$X(t)$ 是 t 时刻的交通状态，表示所有道路上的排队长度；$x(l,m)$ 是指从道

中国知网 https://www.cnki.net

路 l 驶向道路 m 的排队长度；$p \in \text{Out}_m$ 表示 p 是道路 m 的下游道路；$r(m,p)$ 是从道路 m 出发，选择驶向道路 p 的车流比例。那么 $\sum_{p\in\text{Out}_m} r(m,p)x(m,p)$ 相当于道路 m 下游各方向的平均排队长度，则压力 $w(l,m)\,(X\,(t))$ 反映了 t 时刻下，从道路 l 驶向道路 m 的上游排队长度与下游平均排队长度之间的差值。图 2.5 展示了车流在 t 时刻由道路 k 驶入，并在 $t+1$ 时刻由各方向驶出的示意图。

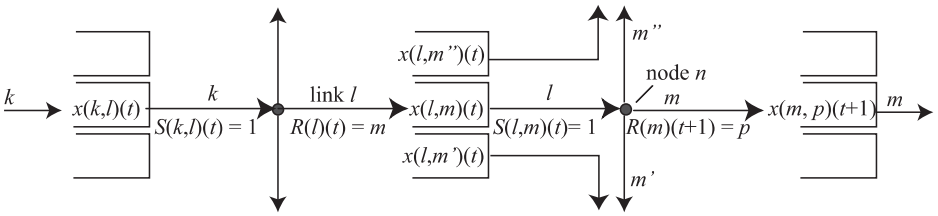


图 2.5　MaxPressure 算法在 t 时刻至 $t+1$ 时刻的运行示意图

Fig. 2.5　Operation Diagram of the MaxPressure Algorithm from Time t to $t+1$

在每个决策时间步，MaxPressure 算法根据当前交通状态 X，计算各个信号相位对应的总压力，并选择总压力最大的相位 S 作为下一时间步的信号配置。具体决策规则如式 2.9 所示。

$$u^{*}\,(X) = \arg\max_{S\in\mathcal{S}} \sum_{l,m} c\,(l,m)\,w\,(l,m)\,(X)\,S\,(l,m) \tag{2.9}$$

其中，$\mathcal{S}$ 是可选信号相位的集合；$c(l,m)$ 是从道路 l 驶向道路 m 的饱和流量；$S(l,m)$ 是一个布尔变量，若相位 S 允许驶向 (l,m) 的交通流，则取值为 1，否则为 0。

MaxPressure 算法的优势在于其不依赖于复杂的模型预测，仅通过计算上下游的排队长度即可进行决策，从而优化交通路网的吞吐量。该算法结构简单、易于实现，且具有严格的理论保障，是一种高效而实用的启发式方法。然而，其局限性也较为明显，该算法仅考虑单交叉口的优化，未能考虑多交叉口之间的协同效应，因此在复杂路网中的应用效果可能受限。

2.3.3　CoLight 算法

CoLight 是由 Wei 等人[8] 于 2019 年提出的一种基于强化学习的交通信号控制算法。CoLight 算法基于 DQN 架构实现，并创新性地引入注意力机制，能够有效融合邻近交叉口的交通信息，从而实现多个交叉口间的协同优化，是交通信号控制领域强化学习方法的代表作之一，对后续研究产生了深远影响。

此前的强化学习方法，大多未考虑邻居信息的融合，即使考虑的方法也只是将邻居状态直接拼接[54]，简单粗糙，不能很好的将邻居信息影响融入状态特征表达。CoLight 算法通过图注意力网络动态建模交叉口之间的时空依赖关系，每个交叉口决

中国知网　https://www.cnki.net

策时不仅关注自身状态，还通过注意力权重实时评估邻居的影响。

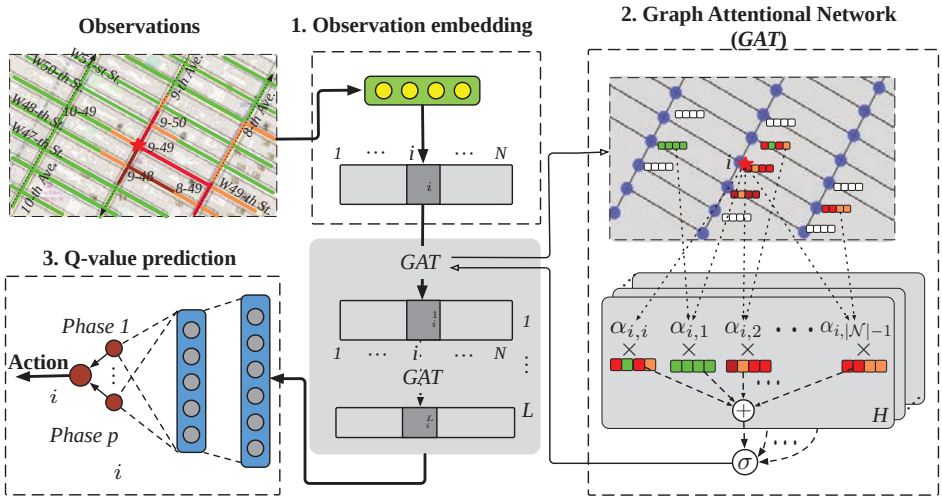


图 2.6　CoLight 算法框架图

Fig. 2.6　Framework diagram of the CoLight

图 2.6展示了 CoLight 算法的框架。框架中第一个模块是观测值编码网络，将目标交叉口及其相邻交叉口的车道车辆数与相位等信息转化为嵌入向量。第二个模块是图注意力网络，用于评估这些嵌入向量之间的交互作用。首先，根据公式 2.10，计算每个交叉口对之间的交互得分 e_{ij}^h；然后，按照公式 2.11，利用 softmax 函数转换这些得分以得到多头注意力权重 α_{ij}^h；最后，依据公式 2.12，通过对所有注意力头的结果进行加权平均聚合，生成最终特征表示 hm_i。

$$e_{ij}^h = (o_i W_t^h) \cdot (o_j W_s^h)^T \tag{2.10}$$

$$\alpha_{ij}^h = \text{softmax}(e_{ij}^h) = \frac{\exp(e_{ij}^h/\tau)}{\sum_{j\in\mathcal{N}_i}\exp(e_{ij}^h/\tau)} \tag{2.11}$$

$$hm_i = \sigma\left(W_q \cdot \left(\frac{1}{H}\sum_{h=1}^{H}\sum_{j\in\mathcal{N}_i}\alpha_{ij}^h(o_j W_c^h)\right) + b_q\right) \tag{2.12}$$

其中，h 为第 h 个注意力头，o_i 和 o_j 为目标交叉口 i 和与之交互的交叉口 j，W_t^h 和 W_s^h 是两个交叉口的线性变换矩阵，$\mathcal{N}_i$ 是目标交叉口与邻居交叉口组成的集合，τ 是温度参数，用于调整权重分布的尖锐程度，W_c^h 是交叉口嵌入层权重矩阵，W_q 和 b_q 是可训练参数，H 是总注意力头数，σ 是 ReLU 激活函数。

框架的最后一个模块是 Q 值预测网络，将经过图注意力机制计算后的特征作为输入，用于预测各个相位的 Q 值。智能体随后会选择具有最高 Q 值预测值的相位作为其动作，即决定哪个相位将被激活用于交通信号控制。

CoLight 算法是首个在强化学习中实现邻居信息深度融合的方法，有效克服了以

中国知网　https://www.cnki.net

往方法在处理邻居信息时过于粗糙的问题，并展现出优异的性能。然而，该算法仍存在一定局限性。无论交叉口类型如何，CoLight 均采用固定的四个邻居进行注意力计算。这种设计在处理路网边缘的交叉口时，将会引入二跳邻居参与计算，而模型本身无法识别这些邻居并非直接相邻，使得本应微弱的远程影响被过度放大，从而影响最终的决策性能，这也是本文后续将会改进和优化的一点。

2.4 本章小结

本章梳理了本文研究所涉及的基础理论与技术，为后续研究工作奠定理论基础。首先，在深度强化学习部分，详细介绍了 DQN 和 PPO 两大经典算法，为后续强化学习模型的构建提供指导。随后，围绕预训练语言模型的发展脉络，本章重点分析了 BERT 和 GPT 两大代表性模型体系，揭示了不同架构设计在语言理解与生成任务中的优势特点，并探讨了大语言模型的发展历程与现状。最后，本章详细介绍了交通信号控制领域中经典方法的具体技术实现，为本文后续章节中提出的新方法提供了重要的借鉴和参考。

中国知网 https://www.cnki.net

3 交通信号控制系统模型与问题定义

3.1 路网结构建模

路网是城市交通的骨架，承担交通流的分布与传输，连接不同区域，支持车辆和行人的移动。路网是以交叉口（Intersection）作为节点和道路（Road）作为边，相互连接形成一个反映交通拓扑结构的有向图：

$$\begin{cases} \mathcal{G} = (\mathcal{V}, \mathcal{E}) \\ \mathcal{V} = \{I_1, I_2, \ldots, I_n\} \\ \mathcal{E} = \{L_{ij} \mid (I_i, I_j) \in \mathcal{C}\} \end{cases} \tag{3.1}$$

其中，$\mathcal{G}$ 表示路网的图结构；$\mathcal{V}$ 是交叉口集合，每个交叉口 I_i 的几何结构由连接道路的拓扑关系唯一确定；$\mathcal{E}$ 是道路集合，连接路网中各交叉口；$\mathcal{C}$ 表示连通关系的集合，即路网中直接相连的交叉口对的集合；L_{ij} 特指从交叉口 I_i 指向 I_j 的单向道路段。图 3.1 以济南市东风街道为例，展示了该路网的拓扑结构，具体包括交叉口与道路结构、联通关系、驶入驶出道路以及车道结构等。

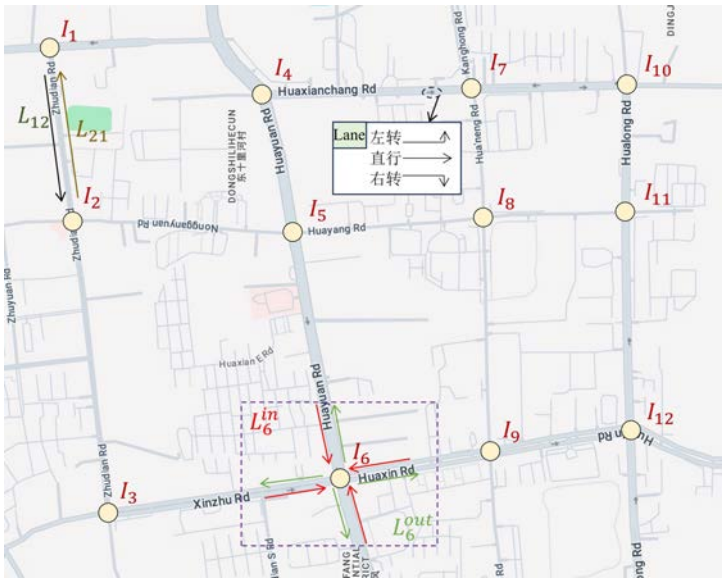


图 3.1 路网拓扑结构示意图

Fig. 3.1 Road network topology diagram

3.1.1 道路与车道建模

道路是路网中连接两个交叉口之间的线性交通设施，用于承载车辆在相邻交叉口之间运行。车道是道路的最小组成单元，具有明确的行驶方向和功能属性。

中国知网 https://www.cnki.net

对于任意道路 $L \in \mathcal{E}$，定义其车道集合为 $L = \{l_1, l_2, \ldots, l_n\}$，其中 $n \in \mathbb{N}^+$ 为车道总数。对于每条车道 $l_i \in L$，其属性可以定义为四元组 (v_i, d_i, f_i, g_i)。其中，v_i 为速度属性，表示车道 l_i 的限速情况；d_i 为方向属性，表示车道的行驶方向；f_i 为功能属性，表示车道属于普通车道或是紧急车道等特殊车道；g_i 为几何属性，包括车道的宽度、长度以及间距等信息。

设所有可能的行驶方向集合为 $D = \{\text{直行}, \text{左转}, \text{右转}\}$，并定义 $D_{\text{support}} \subseteq D$ 为当前道路所支持的实际可行驶方向集合。为了满足方向覆盖性约束，要求对于任意方向 $d \in D_{\text{support}}$，在车道 L 中至少存在一个车道 l_i 支持该方向，形式化表示如式 3.2 所示。

$$\forall d \in D_{\text{support}}, \exists l_i \in L \text{ s.t. } d_i = d \tag{3.2}$$

在本研究中，单条车道的交通状态定义为如式 3.3 所示的五元组。

$$S_{l_i} = \{s_q, s_v, s_{seg1}, s_{seg2}, s_{seg3}\} \tag{3.3}$$

其中，s_q 表示该条车道上的排队车辆数目，s_v 表示该条车道上的行驶中的有效车辆数目，s_{seg1} 表示该条车道距离交叉口前 100 米内的车辆数目，s_{seg2} 表示该条车道距离交叉口前 100 米至前 200 米之间的车辆数目，s_{seg3} 表示该条车道距离交叉口 200 米之后的车辆数目。

3.1.2 交叉口建模

交叉口是路网中多条道路的交汇点，其几何结构决定了车辆的通行方向和交通冲突关系。对于任意交叉口 $I_i \in \mathcal{V}$，定义其驶入道路集为：

$$L_i^{\text{in}} = \{L_{ji} \mid L_{ji} \in E, \forall I_j \in \mathcal{V}, j \neq i\} \tag{3.4}$$

其中，L_{ji} 表示从交叉口 I_j 指向 I_i 的道路，即所有以 I_i 为终点，并以其他交叉口 I_j（$j \neq i$）为起点的道路构成该交叉口的驶入道路集合。同理，可以定义其驶出道路集为：

$$L_i^{\text{out}} = \{L_{ij} \mid L_{ij} \in E, \forall I_j \in \mathcal{V}, j \neq i\} \tag{3.5}$$

交叉口作为路网图结构的顶点具有拓扑唯一性，可以通过分析每个交叉口 I_i 与其相连的驶入道路集合 L_i^{in} 和驶出道路集合 L_i^{out}，来唯一确定该交叉口的几何结构，具体如式 3.6 所示。

$$\forall I_i \in \mathcal{V},\ L_i^{\text{in}} \cup L_i^{\text{out}} \tag{3.6}$$

在路网中，车辆的旅行路径 $\text{TR} = \langle I_{i_0}, L_{i_0,i_1}, I_{i_1}, L_{i_1,i_2}, ..., I_{i_n} \rangle$ 定义为：车辆从起始

中国知网 https://www.cnki.net

交叉口 I_{i_0} 驶入路网，依次经过一系列道路与交叉口的连续通行后，最终从终止交叉口 I_{i_n} 驶出路网所形成的完整路径序列。其中，L_{i_{k-1},i_k} 表示连接交叉口 $I_{i_{k-1}}$ 与 I_{i_k} 的道路，I_{i_k} 表示旅行路径中的中间过渡交叉口。

旅行路径所包含的道路需满足连通性和合法性约束，即每一条道路 L_{i_{k-1},i_k} 必须是前一交叉口 $I_{i_{k-1}}$ 的驶出道路，同时也是后一交叉口 I_{i_k} 的驶入道路。该约束可形式化表示为：

$$\forall k, L_{i_{k-1},i_k} \in L^{out}(I_{i_{k-1}}) \cap L^{in}(I_{i_k}) \tag{3.7}$$

通过上述分析与建模，本节构建了一个完备的交通路网模型，深入探讨了路网中交叉口与道路的结构与约束，为交通信号控制系统的设计奠定了基础。

3.2 信号相位与持续时间建模

信号相位用于管理和协调来自不同方向的交通流，是信号控制策略的逻辑表达，旨在确保交通流的安全与有序运行。图 3.2 中展示了典型交叉口及其对应的信号相位集合示例。

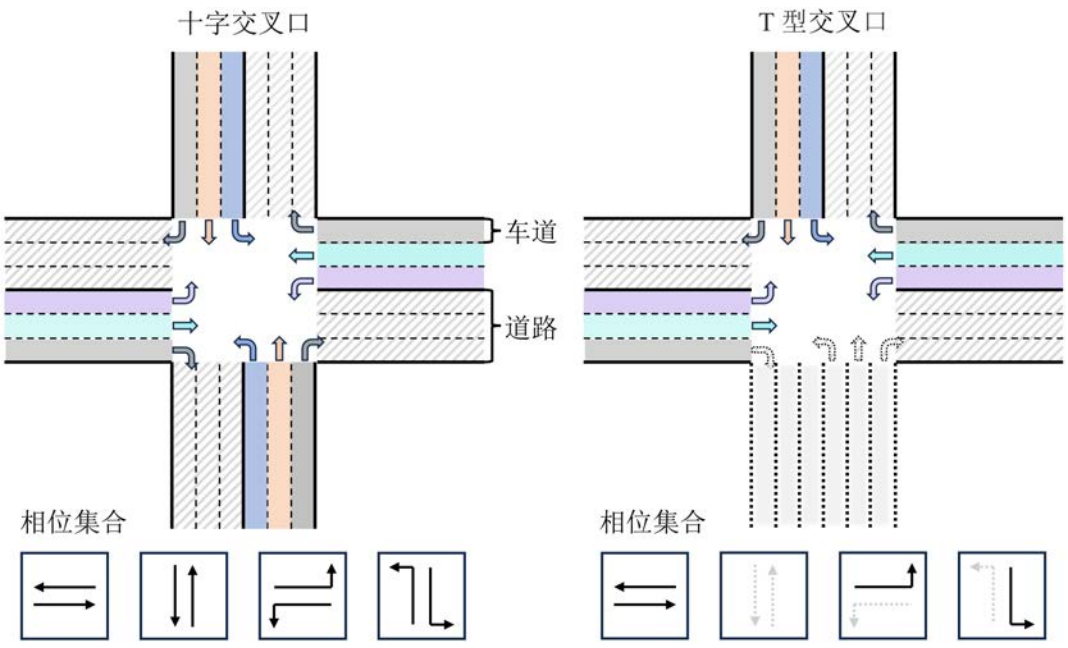


图 3.2　交叉口结构与相位示意图

Fig. 3.2　Illustration of the intersection structure and phase

本研究遵循常见的交通规则设定，假设车辆右转不受相位限制，可以忽略其对信号相位划分的影响。因此，交通流可划分为 $\mathcal{D}$ ={东西直行, 南北直行, 东西左转, 南北左转} 四种互不冲突的组合。定义信号相位集合 $P = \{p_1, p_2, p_3, p_4\}$，则相位与交通流

中国知网　https://www.cnki.net

的映射关系满足：

$$\phi(p_i) = \bigcup_{d_j \in \mathcal{D}} \delta_{ij} d_j,\ \delta_{ij} = \begin{cases} 1 & \text{在相位 } p_i \text{ 下 } d_j \text{ 方向可通行} \\ 0 & \text{否则} \end{cases} \tag{3.8}$$

为了确保信号控制的安全性与有效性，相位之间需满足互斥性约束，即在任意时刻 t，系统中至多仅有一种相位处于激活状态。该约束可形式化表示为：

$$\forall t \in T,\quad \sum_{p \in P} \text{active}(p,t) \le 1,\ \text{active}(p,t) = \begin{cases} 1, & \text{若相位} p \text{ 在时刻} t \text{ 被激活} \\ 0, & \text{否则} \end{cases} \tag{3.9}$$

其中，T 表示所有可能的时间点；$\text{active}(p,t)$ 为相位激活函数，用于描述相位 p 在时刻 t 的激活状态。

为了实现动态信号控制，并兼顾路网范围内各交叉口信号相位时间的协调与对齐，本研究采用固定的时间步长 Δt，将信号相位持续时间离散化为以 Δt 为基本单位的一组可选值，即相位持续时间集合定义如下：

$$\tau = \{ n\Delta t \mid n \in \mathbb{Z}^+,\ N_{\min} \le n \le N_{\max} \} \tag{3.10}$$

其中，$N_{\max}$ 和 $N_{\min}$ 分别为整数系数 n 的上下限。上限 $N_{\max}$ 用于防止某一相位占用时间过长而导致的其他方向交通流拥堵；下限 $N_{\min}$ 用于避免因相位持续时间过短而导致的相位频繁切换。

在相位切换时，设当前处于激活状态的相位为 p_{current}，其在时刻 t_{current} 被激活，且其持续时间为 $\tau_{\text{current}} \in \tau$，则在持续时间内，相位 p_{current} 始终处于激活状态，即：

$$\forall t \in [t_{\text{current}}, t_{\text{current}} + \tau_{\text{current}}),\ \text{active}(p_{\text{current}}, t) = 1 \tag{3.11}$$

当时间到达 $t_{\text{current}} + \tau_{\text{current}}$ 时，当前相位的持续时间结束，随后进入黄灯时间 τ_y，作为相位切换的缓冲期。设下一相位为 p_{next}，则在时间 $t_{\text{now}} = t_{\text{current}} + \tau_{\text{current}} + \tau_y$ 处触发相位切换操作。此时，原相位 p_{current} 停止激活，即 $\text{active}(p_{\text{current}}, t_{\text{now}}) = 0$，并且新相位 p_{next} 开始激活，即 $\text{active}(p_{\text{next}}, t_{\text{now}}) = 1$。

本节详细阐述了信号相位及持续时间的定义，明确了信号相位与交通流之间的映射关系，并描述了相位的激活与切换机制，为后续交通信号控制的优化提供理论支持。

中国知网 https://www.cnki.net

3.3 问题定义

交通信号控制本质上是一个动态决策优化问题，其核心在于构建路网交通状态空间 $\mathcal{S}$ 与信号控制动作空间 $\mathcal{A}$ 之间的映射关系。通过实时感知交通状态并动态调整控制策略 $\pi : \mathcal{S} \to \mathcal{A}$，系统旨在最小化路网中车辆的平均旅行时间，从而实现对交通流的智能调控。这种持续优化机制通过实时调节交通流量分布，不仅能有效缓解交通拥堵，更能在长期运行中显著提升整个交通系统的效率，最终在时空维度上达成优化目标。

从微观控制层面来看，路网中的每个交叉口 I_i 被视为基本控制单元，其状态向量 $S_i \in \mathbb{R}^n$ 包含各车道排队长度、分段车辆分布以及当前信号相位等关键交通参数。控制动作 $a_i = (a_i^p, a_i^d)$ 表示根据当前交通状态 S_i 所决策的下一时刻信号相位及其持续时间的时序控制方案，其中 a_i^p 表示相位选择动作，用于确定下一时间步的信号相位；a_i^d 表示相位持续时间选择动作，用于确定所选相位的持续时间。

将路网车辆平均旅行时间最小化问题形式化为具有时空约束的动态优化问题。设 $\mathcal{R}$ 为研究时段内所有车辆旅行路径的集合，$T_r(t)$ 表示某车辆在时刻 t 进入路网后，经由旅行路径 $r \in \mathcal{R}$ 所花费的实际旅行时间，由道路行驶时间与交叉口等待时间共同构成：

$$T_r(t) = \sum_{k=1}^{n} \frac{\|L_{i_{k-1},i_k}\|}{v_{i_{k-1},i_k}} + \sum_{k=1}^{n-1} \tau_{i_k}^{\text{wait}}(t) \tag{3.12}$$

式中，$\|L_{i_{k-1},i_k}\|$ 表示道路的几何长度，v_{i_{k-1},i_k} 为车辆在该道路上的平均行驶速度，二者之比用于计算车辆在道路 L_{i_{k-1},i_k} 上的行驶时间；$\tau_{i_k}^{\text{wait}}(t)$ 表示车辆在交叉口 I_{i_k} 处的等待时间。单个交叉口的等待时间受信号相位激活序列 $\{p^{(m)}\}_{m=1}^{M}$ 与持续时间序列 $\{\tau^{(m)}\}_{m=1}^{M_k}$ 的直接影响，其数学关系可表示为：

$$\tau_{i_k}^{\text{wait}}(t) = \sum_{m=1}^{M_k} \left[\mathbb{I}\left(d_r \not\subseteq \phi(p^{(m)})\right) \cdot (\tau^{(m)} + \tau_y)\right] \tag{3.13}$$

式中，M_k 为车辆在交叉口 I_{i_k} 经历的相位周期数，$\mathbb{I}(\cdot)$ 为指示函数，表示当车辆行驶方向 d_r 未被当前相位 $p^{(m)}$ 覆盖时，等待时间将增加 $p^{(m)}$ 对应的相位持续时间 $\tau^{(m)}$ 与固定黄灯时间 τ_y 之和。

最终交通信号控制任务的优化目标函数定义为：

$$\min_{\{a_i\}} \ \mathbb{E}_{t\sim T} \ \frac{1}{|\mathcal{R}|} \sum_{r\in\mathcal{R}} T_r(t) \tag{3.14}$$

其中，T 表示需进行优化的总时段。目标是通过交叉口级别的信号调控，实现路

中国知网 https://www.cnki.net

网平均旅行时间的最小化。

3.4 本章小结

本章围绕交通信号控制系统的建模与问题定义展开研究。首先构建了交通路网的多维度结构模型，通过交叉口与道路的拓扑关系与属性建模来描述路网结构。随后对信号相位与持续时间进行建模，将信号相位集合映射到互不冲突的交通流组合，并将相位持续时间进行离散化设计。最后将交通信号控制问题形式化为动态决策优化任务，提出以最小化车辆平均旅行时间为目标的优化函数。本章构建的模型为后续交通信号控制算法设计提供了理论框架，明确了交通流与控制策略之间的动态交互机制，为实现交通信号控制优化奠定基础。

中国知网 https://www.cnki.net

4 基于强化学习辅助训练的动态交通信号控制大模型方法

4.1 问题背景

在交通信号控制领域，基于强化学习的方法已展现出超越传统启发式算法的性能优势，但其仍面临若干关键挑战。现有方法[7–10]普遍采用为每个交叉口独立部署策略网络，未能充分考虑交叉口之间的异质性和信息交互对齐的问题，在可扩展性方面存在明显局限。图 4.1 中展示了标准网格型交叉口和异构交叉口示例图。此外，现有方法在迁移性与泛化性方面存在显著瓶颈。针对特定路网训练的模型难以直接迁移到其它路网，应用到新环境中会出现明显的性能损失。强化学习算法的“黑盒”特性也备受诟病，尽管可以观察到模型接收的输入和产生的输出，但其内部决策机制复杂且不透明，阻碍了对算法行为的可解释性分析以及对潜在错误或偏差的识别和修正。

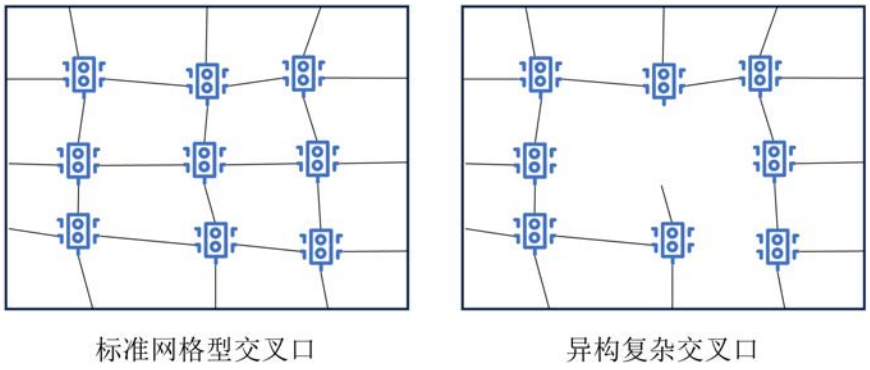


图 4.1 网格型交叉口和异构交叉口结构示意图

Fig. 4.1 Illustration of the grid intersection and heterogeneous structure

在控制策略层面，现有方法普遍采用固定相位持续时间的控制模式，即在每个决策周期内仅判断下一相位的选择，而相位持续时间被预设为固定值。这种控制机制无法根据实时交通流量动态调整相位持续时间，限制了系统的灵活性和动态调整能力，容易出现信号周期与实际通行需求不匹配的情况，进而降低路网整体通行效率。

近年来，一些研究[17–19]开始尝试将大语言模型引入交通信号控制领域，期望借助 LLM 卓越的泛化能力与类人的推理决策机制，构建更加高效且有理可循的信号控制系统。然而，这些研究普遍仍以强化学习算法作为决策主体，LLM 主要用于生成决策依据或处理紧急情况等辅助任务，尚未充分挖掘其作为信号控制主体的潜力。此外，尽管如 GPT-4[55]这类先进的 LLM 已展现出令人瞩目的强大能力，但由于它们在通用语料上训练而成，缺乏对交通信号控制领域的专业知识和经验，限制了通用 LLM 直接应用于该任务中的有效性。

上述局限共同构成了当前交通信号控制领域亟需解决的核心难题。为应对现有方

中国知网 https://www.cnki.net

法在控制粒度较粗、状态表征不足等问题，本章首先提出了一种融合邻居信息的动态交通信号控制强化学习算法，旨在更有效地刻画交通信号控制中复杂的交互关系以实现多交叉口信息协同优化控制，并设计了动态信号调控机制以实现细粒度信号控制。在此基础上，为进一步提升控制策略的泛化能力、决策质量与可信度，本章提出了一种基于强化学习辅助训练的动态交通信号控制大模型方法，设计了定制化的两阶段训练框架对本地基座模型进行深度优化，以上述设计的强化学习预训练模型作为辅助，在整个大语言模型训练与优化过程中提供策略评价引导，最终的大模型算法能够实现更有效且更可靠的信号控制策略。本章的整体研究框架如图 4.2所示。

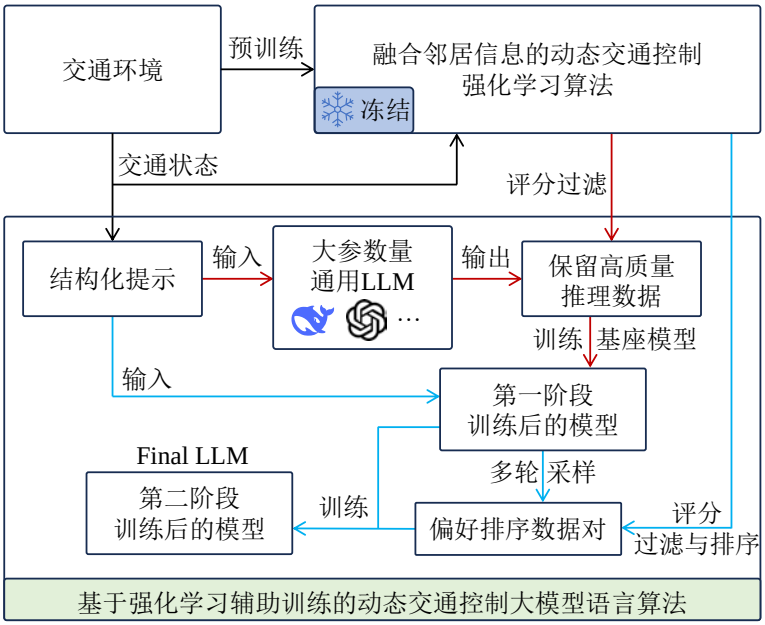


图 4.2　本章总体研究框架

Fig. 4.2　The overall research framework of this chapter

本章的主要贡献如下：（1）更精细化的交叉口观测值与邻居信息协同优化：本章对交叉口观测值进行了更精细化的定义，并在目标交叉口观测值的基础上，通过邻居信息的协同融合，进一步提升了智能体对全局交通状态的认知能力。（2）设计了动态交通信号控制机制：不同于传统的固定持续时间方法，本章提出的动态算法可以同时优化信号相位与相位持续时间的选择，增强了系统的灵活性和响应效率。（3）以 LLM 取代强化学习方法作为交通信号控制决策主体：本研究探索了将 LLM 作为交通信号控制决策主体的新颖应用与模式，以期发掘 LLM 在更细粒度实时交通流量优化中的潜力。（4）针对信号控制任务设计提示模板与训练框架：根据交通信号控制任务的背景与需求，设计了包含任务背景、路网状态以及推理思维链（Chain-of-Thought，CoT）[15] 的提示模板。此外，还设计了一种两阶段训练框架，通过监督微调与对齐微调优化本地模型的指令遵循与推理能力，从而可以更精准、高效地应对交通信号控制任务。

中国知网 https://www.cnki.net

4.2 融合邻居信息的动态交通信号控制强化学习算法

4.2.1 状态、动作及奖励定义

（1）状态空间定义

设交通系统路网 $\mathcal{G}$ 中待进行信号控制的交叉口为 $\mathcal{V}=\{I_1, I_2, \ldots, I_N\}$，交叉口与道路之间的拓扑结构建模见 3.1 节。对于任意交叉口 I_i，如图 4.3 所示，所有彩色车道构成式 3.4 定义的驶入车道集合 L_i^{in}，所有灰色车道构成代表式 3.5 定义的驶出车道集合 L_i^{out}。对于任意驶入车道 $l \in L_{in}^i$，其微观交通状态 S_l 可以通过式 3.3 定义的五元组 $S_l=\{s_q, s_v, s_{seg1}, s_{seg2}, s_{seg3}\}$ 表示。

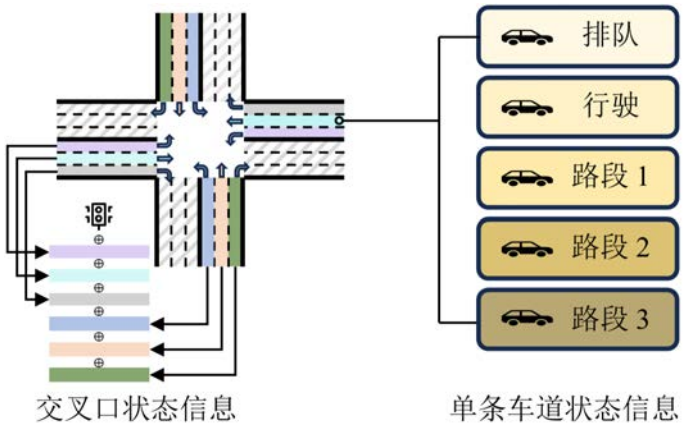


图 4.3　交叉口与车道的状态定义

Fig. 4.3　State definition of intersection and lane

交叉口 I_i 的状态 S_{I_i} 可以表示为其所有驶入车道状态与交叉口当前所处相位 P 的拼接，即

$$S_{I_i}=\text{Concat}(S_l | l \in L_{in}^i) \oplus P \tag{4.1}$$

其中，$\text{Concat}(\cdot)$ 和 $\oplus$ 代表拼接操作。路网总状态空间 $\mathcal{S}$ 则可以表示为各交叉口状态的笛卡尔积，即 $\mathcal{S}=\prod_{i=1}^{N} S_{I_i}$，其中 $\prod$ 表示笛卡尔积。

（2）动作空间定义

本研究针对交通信号控制任务设计了离散动作空间，具体由相位动作和相位持续时间动作两个子空间构成。相位动作空间对应于式 3.8 所定义的交通流通行映射关系的信号相位方案，即 $A^p=\{a_1^p, a_2^p, a_3^p, a_4^p\}$。

为确保异构交叉口的动作一致性与有效性，本研究引入了动作掩码机制。以图 3.2 为例，对于标准十字交叉口，其动作掩码为 $\text{MASK}=[1,1,1,1]$，表示所有相位动作均有效；对于 T 型交叉口，其动作掩码为 $\text{MASK}=[1,0,1,1]$，掩码值为 0 表示对应的相位动作在当前交叉口类型下无效且不可选取。

相位持续时间动作空间对应于式 3.10 定义的可选相位持续时间集合 τ，其中每个

中国知网 https://www.cnki.net

元素对应于一段预设的相位持续时间，可以根据任务场景与需求进行灵活调整。在本研究中，相位持续时间动作空间具体定义为 $A^d = \{a_1^d, a_2^d, a_3^d, a_4^d, a_5^d, a_6^d, a_7^d\}$，分别对应于 $\{10\text{s}, 15\text{s}, 20\text{s}, 25\text{s}, 30\text{s}, 35\text{s}, 40\text{s}\}$ 的持续时间，适用于所有类型的交叉口，具体实验分析见 4.6.1 节。

在每个决策周期中，智能体首先确定相位动作 a^p，然后根据所选相位确定相应的持续时间动作 a^d，表示在下一个时间步，信号将切换至 a^p 所对应的相位方案并持续 a^d 对应的时间，具体的相位切换与激活机制详见 3.2 节。

（3）奖励函数定义

本章遵循交通信号控制领域的经典设定，采用负交集队列长度 $R = -\sum s_q$ 作为基础奖励函数，旨在优化各交叉口的交通效率。然而，这样的奖励机制相当于寻求各目标交叉口的局部最优，但是局部最优策略的简单组合并不能保证达到全局最优。

当大量车辆从上游交叉口被释放至已处于拥堵状态的下游交叉口时，上游交叉口的通行效率虽然可以短暂提升，却也可能导致下游交叉口的拥堵加剧，以致于造成更严重的交通瘫痪。为解决上述问题，本章在设计奖励函数时引入对邻居交叉口状况的考量，以避免局部优化策略对整个网络产生负面影响。定义目标交叉口的奖励为自身的负交集队列长度与邻居交叉口平均负交集队列长度的加权和，即

$$R_{target} = R_{self} + \eta \frac{\sum_{i=1}^{k} R_{nbr}}{k} \tag{4.2}$$

其中，R_{target} 表示目标交叉口的最终奖励，R_{self} 表示目标交叉口自身的负交集队列长度，k 表示目标交叉口共有 k 个直接相连的邻居交叉口，R_{nbr} 表示各个邻居交叉口的负交集队列长度，η 为奖励平衡系数，用于平衡邻居交叉口与目标交叉口之间的相互影响。最终目标是实现式 3.14 对应的路网尺度下平均旅行时间的最小化。

4.2.2 邻居交叉口信息融合模块设计

在交通信号控制领域，之前的研究[8] 已经证实了融合邻居信息能有效提升系统性能。然而，现有融合邻居信息的方法大多是采用非参数共享方式，即对每个交叉口配置独立的智能体进行管理。这类方法通常非显式地粗略提供邻居信息，即不明确给定邻居交叉口与目标交叉口之间的相对交通关系，或是不指出哪些邻居交通相位会对目标交叉口产生影响，智能体仅通过在训练过程中依据经验积累隐式地学习邻居与目标交叉口之间的关联性。

不同于以往的研究，本章计划采用参数共享的方法来优化交通信号控制任务，即在整个系统内收集数据训练一个统一的策略网络，而非针对每个交叉口配置独立的策略网络。为了实现这一目标，本章明确地设计邻居交叉口与目标交叉口之间的关系，并确保其在整个系统中的对齐性和协调性，使智能体有效学习共享策略，并更精确地

中国知网 https://www.cnki.net

捕捉邻居交叉口对目标交叉口的影响，从而实现融合多交叉口信息的协同优化，最终提高系统的整体性能。本节将详细介绍本章关于邻居信息融合的两个模块设计。

（1）邻居关系特征融合模块

位于目标交叉口不同方位的邻居交叉口，当其处于不同的信号相位下，会对目标交叉口的交通状况产生不同程度的影响。图 4.4 中详细展示了不同方位邻居交叉口对目标交叉口的交互情况，图中红色交叉口代表目标交叉口，蓝色和绿色交叉口分别代表位于目标交叉口不同方位的邻居交叉口，它们对目标交叉口的影响为：

1）若邻居交叉口位于目标交叉口南北方向，当其处于第二相位和第三相位时，相应车道的交通流可以驶向目标交叉口，对应于图 4.4 中情况 1。

2）若邻居交叉口位于目标交叉口东西方向，当其处于第一相位和第四相位时，相应车道的交通流可以驶向目标交叉口，对应于图 4.4 中情况 2。

由此可见，不同方位的邻居交叉口对目标交叉口的影响模式存在差异，因此有必要根据不同方位来对邻居交叉口进行分组，从而正确区分不同模式对目标交叉口的影响。根据上述分析，本章将位于目标交叉口南北方向的邻居交叉口归为一组，将东西方向的邻居交叉口归为另一组。

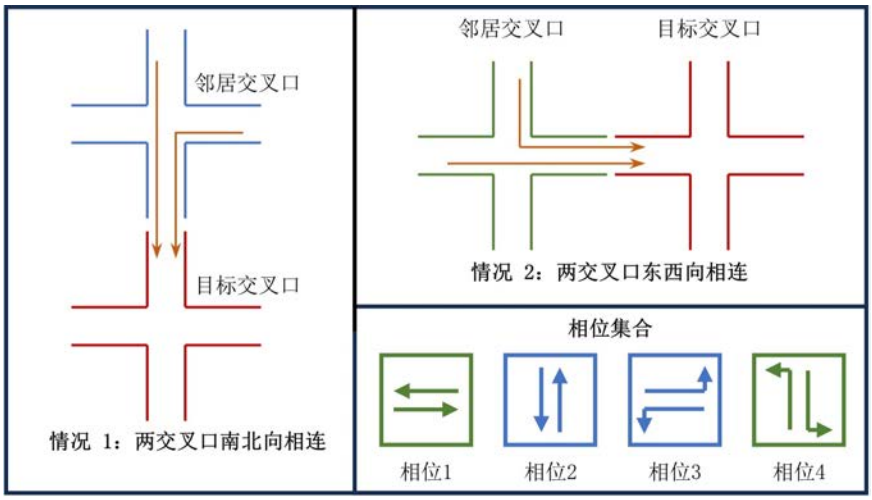


图 4.4　不同方位邻居对目标交叉口的影响

Fig. 4.4　Impact of neighboring intersections on the target intersection by direction

设目标交叉口为 I_x，其邻居交叉口集合为 $N(I_x)$，对于任意邻居 $I_y \in N(I_x)$，采用二元独热编码（One-Hot Encoding）$r(x,y)$ 表示目标交叉口 I_x 与邻居交叉口 I_y 之间的相对位置关系，如式 4.3 所示。

$$r(x,y)=\begin{cases}[0,1] & I_y \text{ 位于 } I_x \text{ 南北方向}\\ [1,0] & I_y \text{ 位于 } I_x \text{ 东西方向}\end{cases} \tag{4.3}$$

基于上述关系，本节设计了“邻居关系特征融合模块”，增强对邻居交叉口与目

中国知网 https://www.cnki.net

标交叉口之间复杂关系的表征能力。

在该模块中，首先将 $r(x,y) \in \mathbb{R}^{n\times 2}$ 通过线性变换映射到隐藏维度 $\mathbb{R}^{n\times h}$，其中 n 代表邻居交叉口的数目，h 表示隐藏维度。随后，采用交叉注意力层进行特征交叉，其中线性变换后的相对关系作为查询，邻居交叉口观测信息 $O_y \in \mathbb{R}^{n\times h}$ 作为键和值，从而将邻居观测信息映射到相对于目标交叉口的交通运动语义上。最后，经过交叉注意力处理后的特征再通过自注意力层进一步提炼特征。整个模块的计算过程如式 4.4 所示，具体结构如图 4.5 所示。

$$O_y^r = \text{Self-Att}^N\left(\text{Cross-Att}\left(\text{Linear}\left(r(x,y)\right), O_y\right)\right) \tag{4.4}$$

其中 $\text{Linear}(\cdot)$ 表示将相对关系 $r(x,y)$ 映射到隐藏维度 h 的线性变换，在本研究中设置 h=128，$\text{Cross-Att}(\cdot)$ 表示交叉注意力（Cross-Attention）层，$\text{Self-Att}(\cdot)$ 表示自注意力（Self-Attention）层，N 表示自注意力层堆叠了 N 层，在本研究中设置 N=2，$O_y^r \in \mathbb{R}^{n\times h}$ 表示经过邻居关系融合模块获得的输出并将用于后续计算。

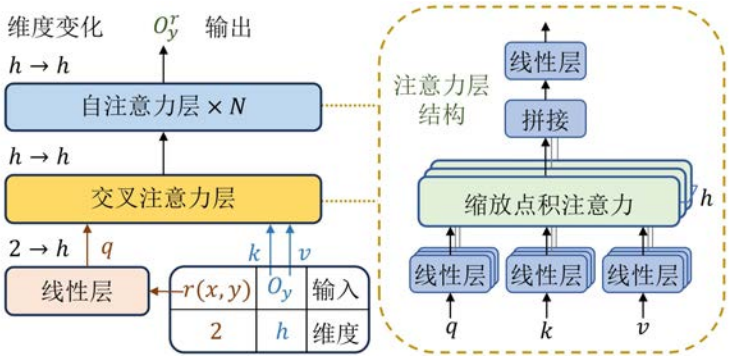


图 4.5　邻居关系特征融合模块结构

Fig. 4.5　Neighbor relation feature fusion module structure

（2）邻居作用强度评估模块

邻居交叉口的观测信息经过前一节中的邻居关系特征融合模块编码后，得到的观测信息隐含了邻居交叉口对目标交叉口的相对关系与影响模式。为了深入评估邻居交叉口对目标交叉口的具体影响，本节设计了“邻居作用强度评估模块”，整个模块的计算过程如式 4.5 到 4.8 所示，具体结构如图 4.6 所示。

模块的输入为经由邻居关系特征融合模块编码后的邻居交叉口观测信息 $O_y^r \in \mathbb{R}^{n\times h}$ 作为查询，目标交叉口观测信息 $O_x \in \mathbb{R}^{1\times h}$ 作为键和值。这些输入首先通过交叉注意力层进行交互，然后通过自注意力层进一步提炼特征，从而得到中间输出 $O_{xy}^i \in \mathbb{R}^{n\times h}$，计算过程如式 4.5 所示。

$$O_{xy}^i = \text{Self-Att}\left(\text{Cross-Att}\left(O_y^r, O_x\right)\right) \tag{4.5}$$

中国知网　https://www.cnki.net

随后，将 O_{xy}^{i} 作为多层感知机的输入，用于计算每个邻居交叉口对目标交叉口的作用与影响强度，MLP 输出为强度权重 $W \in \mathbb{R}^{n\times 1}$。考虑到不同方位邻居对目标交叉口的影响模式存在差异，依据前一节中提出的分组规则，将强度权重分为东西向和南北向两组，每组内计算 Softmax 函数，从而获得同一组内各个邻居交叉口对目标交叉口的作用与影响强度分数 score $\in (0,1)$，计算过程如式 4.6 所示。

$$\text{score} = \text{Softmax}\left(\text{MLP}\left(O_{xy}^{i}[\text{group1}]\right)\right) \oplus \text{Softmax}\left(\text{MLP}\left(O_{xy}^{i}[\text{group2}]\right)\right) \tag{4.6}$$

每个邻居的分数与其在 O_{xy}^{i} 中相应索引的子张量逐元素相乘（对应于图 4.6 中的 $\odot$ 符号）得到 O_{xy}^{w}，表示加权后的邻居交叉口对目标交叉口的作用强度，计算过程如式 4.7 所示。

$$O_{xy}^{w} = O_{xy}^{i} \odot \text{score} \tag{4.7}$$

式中，group1 和 group2 分别代表东西向邻居和南北向邻居对应的索引，$\oplus$ 代表拼接（Concat）操作，$\odot$ 代表逐元素相乘。

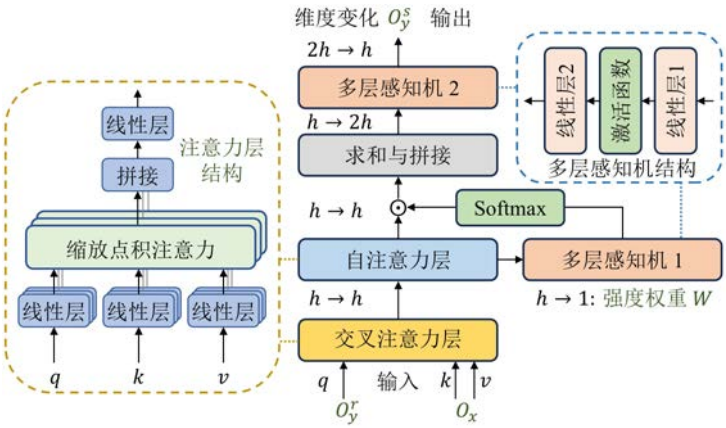


图 4.6　邻居作用强度评估模块结构

Fig. 4.6　Neighbor influence strength assessment module structure

为了表征异构路网结构，如 T 型交叉口或位于路网边缘的情况，引入邻居掩码机制，当某方位不存在实际邻居时，相应位置的掩码值设为 0；存在邻居时掩码值设为 1。在计算邻居作用强度分数时，通过 Softmax 函数处理后，缺失邻居方向的权重会自动归零，从而有效避免无效邻居信息的影响。

最后，对每个邻居分组内的加权作用强度求和，表征该分组对目标交叉口的总影响。求和后的两个分组值进行拼接，再经过一个多层感知机，得到最终输出 $O_y^s \in \mathbb{R}^{1\times h}$，表示所有邻居对目标交叉口总的综合作用与影响，计算过程如式 4.8 所示。

$$O_y^s = \text{MLP}\left(\sum O_{xy}^{w}[\text{group1}] \oplus \sum O_{xy}^{w}[\text{group2}]\right) \tag{4.8}$$

中国知网 https://www.cnki.net

4.2.3 强化学习模型总体框架

在交通信号控制任务中，强化学习智能体依据当前道路状态来决策信号相位选取等动作，并根据动作的执行结果获得即时奖励，其最终目标是使系统累积奖励最大化。考虑到本任务需要对信号相位和相位持续时间两类动作进行控制，并且信号相位属于离散动作空间，因此本章采用擅长处理离散动作空间的深度 Q 网络（Deep Q-Network，DQN）架构来实现对二者的控制。本章所提出的结合邻居信息的动态交通信号控制强化学习模型框架主要包含：交通环境、经验回放区（Replay Buffer）、特征提取网络、相位选择网络、持续时间选择网络等模块, 总体框架如图 4.7 所示。

交通环境在每次交互过程中，首先为智能体提供当前状态表示 S，随后接收智能体依据该状态所选择的动作 a^p 和 a^d 进行更新，更新后再向智能体反馈新的状态 S' 与奖励 R，循环往复保障整个系统的信息流动。

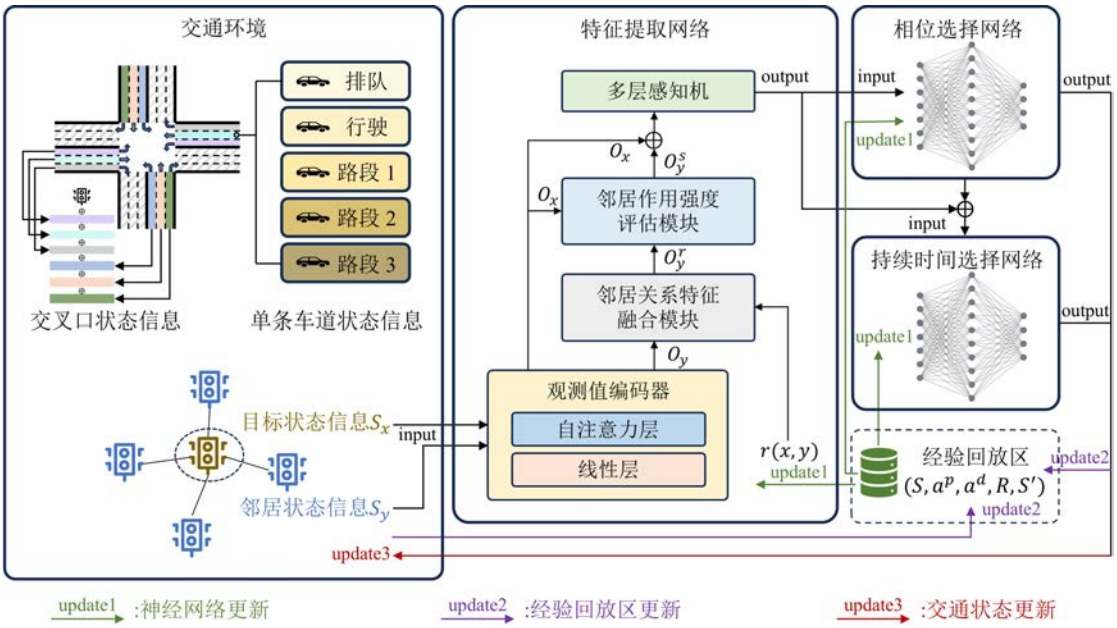


图 4.7 强化学习模型总体框架图

Fig. 4.7 Overall framework diagram of reinforcement learning model

经验回放区用于存储智能体与环境交互的经验，这些经验以元组 (S, a^p, a^d, R, S') 的形式存储，其中包括状态、动作、奖励以及下一时间步状态。在训练阶段，系统将从中随机抽取小批量样本作为训练数据，从而打破数据间的时序相关性，增强了学习过程的稳定性和鲁棒性。并且允许模型重复利用过往的经验，从而更充分地挖掘有价值的信息，提高数据的利用率。

特征提取网络主要用于编码目标交叉口的观测信息 S_x 与邻居交叉口的观测信息 S_y，并进行二者之间的特征交叉以最终凝练出富含语义信息的特征表示 $F_{x,y}$，网络具体结构如图 4.8 所示。特征提取网络以目标和邻居交叉口的道路状态作为输入，道路

中国知网 https://www.cnki.net

状体具体包括各车道排队车辆数、行驶车辆数、分段车辆数以及当前相位，经过以线性层和自注意力机制组成的观测值编码器模块，输出编码后的观测信息 O_x 和 O_y。

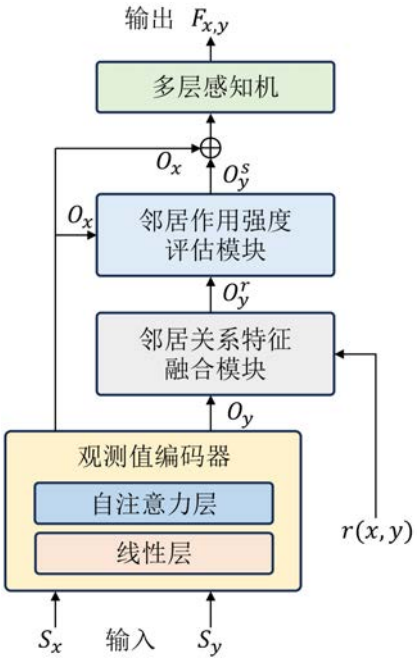


图 4.8　特征提取网络结构

Fig. 4.8　Feature extraction network structure

随后，邻居交叉口观测信息 O_y 连同与目标交叉口的相对位置关系 $r_{x,y}$ 输入邻居关系特征融合模块，输出蕴含与目标交叉口位置关系的邻居交叉口观测信息 O_y^r。之后，邻居关系特征融合模块的输出 O_y^r 和目标交叉口观测信息 O_x 输入至邻居作用强度评估模块，输出邻居对目标交叉口总的综合作用与影响 O_y^s。最后，将 O_x 和 O_y^s 进行拼接并输入进多层感知机，网络最终输出为同时考虑目标和邻居交叉口观测信息与相互作用影响的特征表示 $F_{x,y}$。特征提取网络运算过程如式 4.9 和式 4.10 所示。

$$O_x, O_y = \text{Encoder}\left(S_x\right), \text{Encoder}\left(S_y\right) \tag{4.9}$$

$$F_{x,y} = \text{MLP}\left(\text{NS}\left(\text{NR}\left(r\left(x,y\right), O_y\right), O_x\right) \oplus O_x\right) \tag{4.10}$$

其中，$\text{Encoder}\left(\cdot\right)$ 表示观测值编码器模块，$\text{NR}\left(\cdot\right)$ 表示邻居关系特征融合模块，$\text{NS}\left(\cdot\right)$ 表示邻居作用强度评估模块，$\text{MLP}\left(\cdot\right)$ 表示多层感知机，$\oplus$ 表示拼接操作。

相位选择网络是用于拟合相位动作 Q 值（Q-Value）的神经网络，接收由特征提取网络生成的特征表示 $F_{x,y}$ 作为输入，输出各个相位动作对应的 Q 值。Q 值表示采取某一特定动作后获得的预期回报，即从当前状态开始，执行某个动作后，智能体在未来期望累积奖励的估计值。由于特征提取网络已经将原始输入转换为富含语义信息的特征表示，相位选择网络可以直接利用这些特征进行高效的 Q 值预测。因此，相位选

中国知网　https://www.cnki.net

择网络设计上采用多层感知机结构，将特征提取网络生成的特征表示 $F_{x,y}$ 作为输入，输出维度对应于可选相位动作数目。

持续时间选择网络是用于拟合持续时间动作 Q 值的神经网络，在模型结构上与相位选择网络基本一致，同样采用多层感知机结构，但输入输出维度不同。持续时间选择网络在决策时，不仅需要考虑当前道路状态，还需结合由相位选择网络选定的相位动作，因此该网络的输入为道路特征表示与相位动作的拼接 $F_{x,y} \oplus a^p$，输出维度对应于可选持续时间动作数目。在训练过程中，两个动作选择网络将根据 ε-greedy 策略决定采取的动作，确保探索与利用之间的平衡；在推理过程中，两个动作选择网络选取具有最高 Q 值的动作以最大化预期收益。

4.3 智能交通信号控制大模型方法

本节仍将交通信号控制系统视为一个部分可观测马尔可夫决策过程，但在此基础上引入 LLM 作为智能体，取代传统强化学习智能体，旨在通过 LLM 来决定目标交叉口的相位与持续时间切换策略。

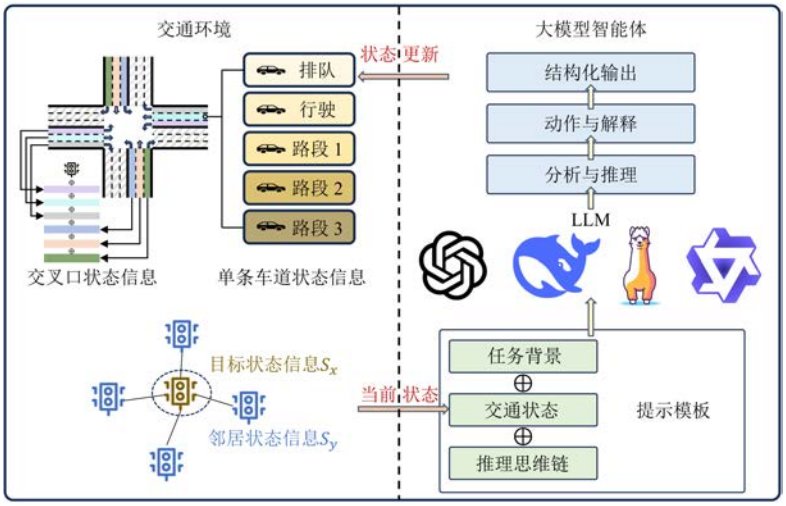


图 4.9 大模型工作流程图

Fig. 4.9 LLM workflow diagram

大模型方法具体工作流如下：首先，系统收集相关交叉口的状态信息，并结合任务背景与需求转换为自然语言提示作为 LLM 的输入。随后，LLM 基于提示中的信息进行推理，采用思维链方法引导模型在生成决策时能够充分考虑任务需求，并提供选择特定策略的解释。最后，系统根据 LLM 所选择的策略执行相应的动作，并将更新后的环境状态再反馈给 LLM 进行下一轮决策。如图 4.9 所示，工作流如此闭环循环往复，实现以 LLM 为核心的智能交通信号控制。接下来，本节将详细介绍本章所提出的大模型方法工作流程的主要模块：

（1）基座模型

中国知网 https://www.cnki.net

将 LLM 作为智能体管理交通信号控制任务时，可将其整体网络参数视为策略函数 π_θ，该函数定义了智能体在给定环境状态 s 时选择不同动作的概率分布。具体实现时，通过将相关任务信息与交通状态转化为自然语言提示 X，作为策略函数 π_θ 的输入。LLM 智能体基于提示 X 生成响应 Y，并从中解析出两个关键决策参数：相位动作 a^p 与持续时间动作 a^d。式 4.11 表达了这一决策过程。

$$\left(Y; a^p, a^d\right) = \pi_\theta\left(X; s\right) \tag{4.11}$$

针对在工作流中具体的交通信号控制任务，若使用 GPT-4 这类闭源模型，则采用 Few-shot 的方式提供少量参考示例，激发模型对于该任务的理解与推理能力。对于开源模型，本研究选用当前最具代表性的开源 SOTA 模型，Llama 系列[43–45] 和 Qwen 系列[47, 48]，并且综合考虑训练与推理成本，分别选用同一参数量级的 Llama3.1-8B[45] 和 Qwen2.5-7B[48] 作为基座模型。而为了实现针对交通信号控制任务的深度优化，本研究在后续还为开源基座模型设计了专门的训练流程。

（2）提示模板

提示词可以视作一种注入式指令，用于引导 LLM 遵循特定的思路进行问题分析和内容生成。在处理复杂的交通信号控制任务时，提示词 X 可以结构化为任务背景 x_{task}、交通状态 x_{state} 与推理思维链 $x_{\text{reasoning}}$ 三个关键模块，即 $X = (x_{\text{task}}, x_{\text{state}}, x_{\text{reasoning}})$，为 LLM 提供相关知识、参考信息与推理模式，为最终决策提供有力支撑。

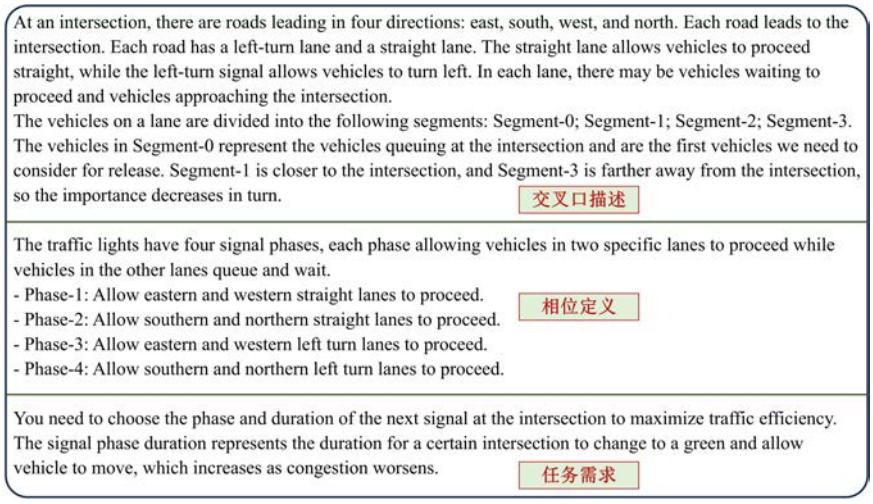


图 4.10　任务背景提示模板

Fig. 4.10　Prompt template for the task background

任务背景模块旨在为 LLM 提供必要的信号控制背景知识，其主要由交叉口描述、相位定义和任务需求三个要素组成。交叉口描述提供了交叉口各个方向道路与车道分段的详细信息，以及相关的基础交通规则。相位定义明确了可供选择的相位信息，以

中国知网　https://www.cnki.net

及各个相位所对应影响的车道。任务需求指出了模型需要执行的任务目标，以及在决策过程中应考虑的关键因素。图 4.10 中展示了任务背景模块具体的提示模板。

交通状态模块旨在为 LLM 提供决策所需的相关交叉口观测信息，主要关注待决策的目标交叉口以及与其邻接的邻居交叉口，观测信息涵盖了每条车道的排队车辆数目，车道前 100 米、100 至 200 米以及 200 米以外三分段上的车辆数目。排队车辆数目是智能体优化交通流的关键考虑因素，而不同分段的车辆数目可以使智能体更直观地感知车道交通压力，对二者的综合考量使决策更加全面与合理。

针对目标交叉口，系统将提供东西南北四个方向上左转与直行车道的观测信息；而针对邻居交叉口，则侧重于提供可能对目标交叉口产生影响的车道的观测信息。这些来自多个交叉口的信息将一并输入给 LLM，使其在进行单点控制的同时，能够考虑多交叉口之间的协同效应，从而实现更高效的全局交通管理。图 4.11 展示了针对目标交叉口和邻居交叉口观测信息的提示词模板示例，其中加粗标红部分代表从交通环境中提取并转化为自然语言的观测数据。

Now there is an intersection, and the following is the vehicle situation at this intersection. Each lane introduces four indicators: Segment-0 vehicles, Segment-1 vehicles, Segment-2 vehicles, and Segment-3 vehicles.
Western Straight Lane: **{Western Straight Lane State}**
Western Left Lane: **{Western Left Lane State}**
Southern Straight Lane: **{Southern Straight Lane State}**
Southern Left Lane: **{Southern Left Lane State}**
Eastern Straight Lane: **{Eastern Straight Lane State}**
Eastern Left Lane: **{Eastern Left Lane State}**
Northern straight Lane: **{Northern Straight Lane State}**
Northern Left Lane: **{Northern Left Lane State}**

{XX Lane State}: There are **xx** vehicles in Segment-0 are queuing up. There are **xx** vehicles in Segment-1, **xx** vehicles in Segment-2, and **xx** vehicles in Segment-3.

(a) 目标交叉口观测信息提示模板

The lane information of the neighboring intersections directly connected to the target intersection and their impact is as follows.

Eastern neighbor intersection: **{Eastern neighbor Affected Phase}**
The lane state that may impact the target intersection: **{Impacting Lane State}**

Western neighbor intersection: **{Western neighbor Affected Phase}**
The lane state that may impact the target intersection: **{Impacting Lane State}**

Southern neighbor intersection: **{Southern neighbor Affected Phase}**
The lane state that may impact the target intersection: **{Impacting Lane State}**

Northern neighbor intersection: **{Northern neighbor Affected Phase}**
The lane state that may impact the target intersection: **{Impacting Lane State}**

{XX Affected Phase}: The vehicles at this neighbor intersection will drive towards the center intersection from the east, which will affect **Phases-X** and **Phase-Y** of center intersection in the future.

{XX Lane State}: There are **xx** vehicles in Segment-0 are queuing up. There are **xx** vehicles in Segment-1, **xx** vehicles in Segment-2, and **xx** vehicles in Segment-3.

(b) 邻居交叉口观测信息提示模板

图 4.11　交通状态提示模板
Fig. 4.11　Prompt template for the traffic state

推理思维链模块旨在为 LLM 提供一个结构化的思考路径，引导模型遵循一定的

中国知网　https://www.cnki.net

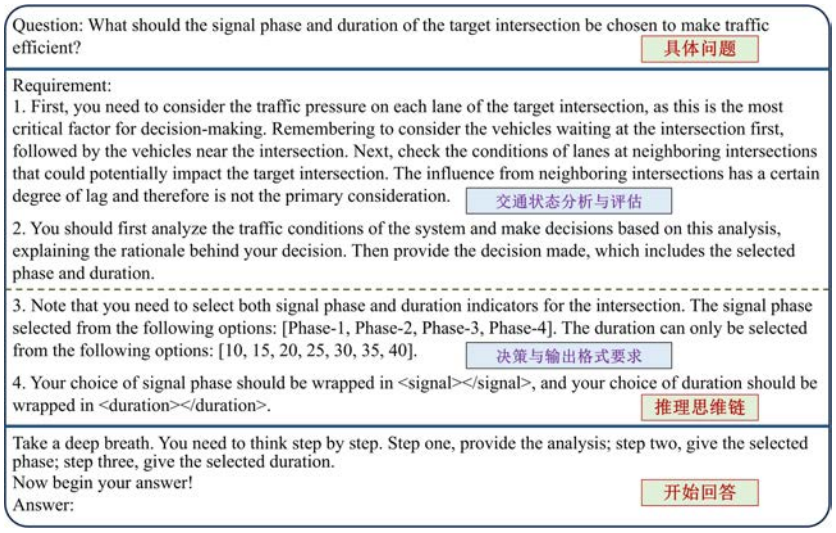


图 4.12　推理思维链提示模板

Fig. 4.12　Prompt template for the reasoning and Chain-of-Thought

逻辑顺序来考虑问题，确保其在处理交通信号控制任务时能够有条理地进行分析和决策。具体而言，该模块首先要求模型考量目标交叉口各车道的排队车辆以及各分段内的状态，以分析哪些车道存在潜在的拥堵风险需要优先考虑。随后评估相邻交叉口的影响，考虑上下游交通流的交互关系，从而避免局部优化的负面影响，并分析可能的协同效应以提高整个系统的效率。最终，模型将对整个系统的交通状况进行全面分析总结，并据此做出决策和提供合理解释。此外，模块中还声明了可选动作范围，确保与第三章中强化学习方法的动作空间保持一致，为后续训练和对比提供了基准，保证不同方法之间的可比性。同时也约束了具体的输出格式，为后续处理指明方向。图 4.12 中展示了推理思维链模块具体的提示模板。

4.4　强化学习模型辅助的两阶段高效微调训练框架

相较于通用 LLM，经过特定领域数据训练的模型能展现出更专业的知识和能力，在特定任务上的性能得到显著提升，这一过程可以帮助模型学习到该领域内更为细致的模式与规律。然而，对于交通信号控制任务而言，其数据量级相对较小，与预训练通用数据的分布存在较大差距，并且考虑计算资源有限等因素，进行全参数微调（Full Fine-Tuning）可能并不现实。

基于上述考虑，本研究选用参数高效微调（Parameter-Efficient Fine-Tuning，PEFT）方法，通过仅调整模型的一小部分参数，达到降低计算成本、提升训练效率以及加速模型对新任务适应的效果。而在具体技术的选择上，本研究采用低秩适应（Low-Rank Adaptation，LoRA）[56] 方法。LoRA 方法的核心思想是，在微调过程中通过优化某些密集层（Dense Layer）中变化的低秩分解矩阵，来间接地对神经网络中这些密集层进

中国知网　https://www.cnki.net

行训练，训练过程仅需专注于优化低秩矩阵，大幅减少了所需训练的参数量。这一过程能够在保留预训练模型原有知识的基础上，实现对下游交通信号控制任务的适配。

本节设计了一种强化学习模型辅助的两阶段高效微调训练框架，如图 4.13 所示。第一阶段是基于大参数量模型推理数据的监督微调（Supervised Fine-Tuning，SFT），使用大参数量模型与交通环境不断交互获取数据，强化学习模型辅助数据过滤后用于监督微调基座模型。第二阶段是基于强化学习模型排序的对齐微调（Alignment Fine-Tuning，AFT），使用第一阶段训练后的 LLM 与交通环境交互并多次采样获取数据，强化学习模型辅助数据过滤并排序后用于对齐微调经第一阶段训练后的 LLM。

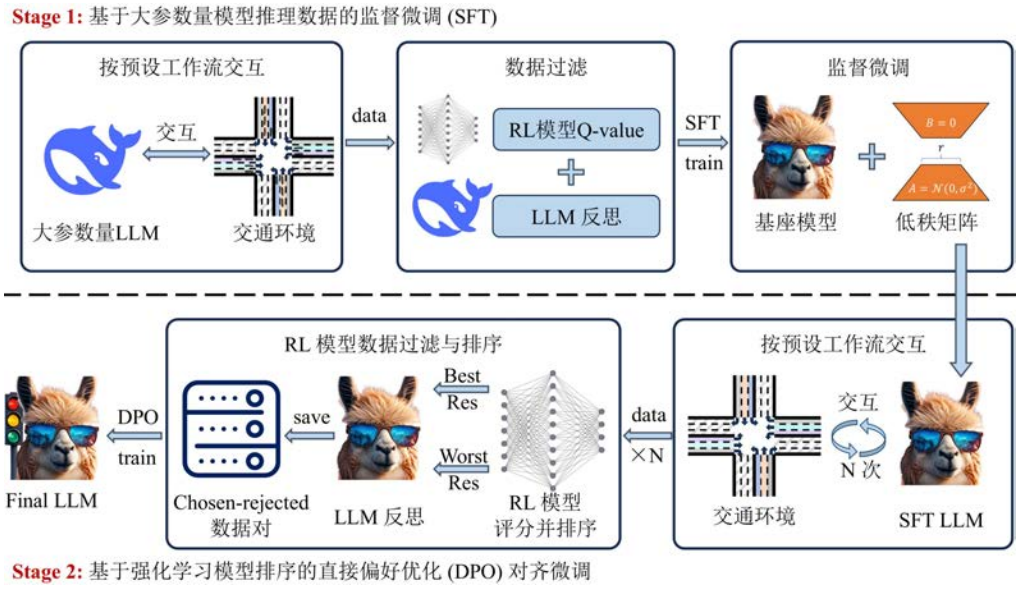


图 4.13　大模型方法两阶段高效微调训练框架

Fig. 4.13　Two-stage PEFT training framework for LLM method

4.4.1　基于大参数量模型推理数据的监督微调

本章所提出的训练框架第一阶段聚焦于大参数量模型推理数据的收集与过滤，并利用这些数据对本地基座模型进行监督微调。其中，大参数量模型选用 DeepSeek-V3[51]，在目前大模型主流榜单中，DeepSeek-V3 与当前最先进的闭源模型 Claude-3.5 和 GPT-4o 性能相当，具备领先的语言理解、生成以及推理能力。采用 CityFlow[57] 模拟器回放真实世界行车记录作为交通环境。同时，遵循前一节提出的提示构造方法，将任务背景与当前时间步 t 下的交通状态等信息以自然语言的形式构造为提示词 X_t。将提示词作为输入使 DeepSeek-V3 与仿真交通环境交互来获取回复 Y_t，从而构成指令-回答数据对 (X_t, Y_t)，遵循这一流程收集不同时间步数据以备后用。

正如前文所述，通用 LLM 在专有领域知识方面存在欠缺，可能影响其在特定专业任务上的表现。若直接让本地基座模型学习大参数量模型的回答模式，可能会由于大参数量模型对交通信号控制任务缺乏深入理解，导致选择了次优甚至不正确的策

中国知网　https://www.cnki.net

略，进而干扰与误导本地基座模型的学习与判断，因此有必要针对大参数量模型生成的推理数据进行过滤。

数据过滤流程具体分为两步。第一步利用 4.2 节所设计的强化学习模型预训练并冻结作为辅助模型，对 LLM 生成的动作决策进行评分。该强化学习模型首先对当前时间步的交通状态进行特征提取，随后通过两个 Q 值预测网络分别输出相位和持续时间对应的 Q 值，其反映了从当前状态采取特定动作后的长期奖励期望值。通过将 LLM 输出的相位和持续时间动作映射到相应的 Q 值作为决策得分，系统能够有效筛选掉那些被强化学习模型判定为低价值的 LLM 推理数据。

为确定具体的过滤标准，本章在包含 16 个交叉口的仿真交通环境中，对一小时的随机模拟交通流情况展开测试。采用本地基座模型与强化学习模型以 30 秒为固定间隔，与仿真交通环境进行周期性交互。收集 LLM 依据当前交通状态所决策的相位动作以及强化学习模型所预测的相位 Q 值，共获得 1920 条数据，筛去无效回答与交通流初始阶段无车辆的情况，共剩余 1564 条有效数据。如式 4.12 所示，将强化学习模型所预测的 Q 值进行归一化，LLM 所选相位动作对应的归一化 Q 值即为该动作的分数。表 4.1 中展示了随机数据上 LLM 所选相位动作的分数分布。

$$\text{Norm}\,(Q) = \frac{Q - Q_{min}}{Q_{max} - Q_{min}} \tag{4.12}$$

由于交通环境存在动态变化、信息不完全可观测等不确定性因素，且深度 Q 网络通过拟合 Q 值函数进行决策，这一过程存在近似误差与训练数据有限等问题，因此强化学习模型所选择的动作无法保证最优，单纯采用 argmax 的方式筛选数据可能有所缺陷。同时，考虑到持续时间的调整相对来说只是在已确定相位下的一种补充手段，相位优化才是提升交通信号对不同交通需求适应性的关键因素，因此本阶段主要以相位 Q 值作为过滤首要考虑因素，持续时间 Q 值则次要考虑。

表 4.1　1920 条随机数据上 LLM 所选相位动作的分数分布

Tab. 4.1　The score distribution of LLM selected phase action on 1920 random data

分数区间	=0.0	(0.0,0.7]	(0.7-0.8]	(0.8-0.9]	(0.9-1.0)	=1.0
数据条数	223	505	70	39	55	672

基于表 4.1 中的分数分布情况，为了避免错过最优策略并有效筛除较差策略，本研究以 0.8 作为相位动作分数阈值。当 LLM 所选相位动作对应的归一化 Q 值分数低于 0.8 时，该条数据被筛除；归一化 Q 值分数大于 0.8 时，该条数据予以保留。随后，检查经过相位动作过滤之后的持续时间动作的 Q 值排序情况，若相应的持续时间动作排序位于前两名，该条数据会被保留，反之则将被筛除。式 4.13 表示了经过第一步

中国知网 https://www.cnki.net

过滤最终保留的数据集合。

$$\left\{\left(X_t, Y_t, a_t^p, a_t^d\right) | \text{Norm}\left(Q^p\left(S_t, a_t^p\right)\right) > 0.8, \text{Rank}\left(Q^d\left(\left(S_t, a_t^p\right), a_t^d\right)\right) \in \{1, 2\}\right\} \quad (4.13)$$

其中，t 表示任意时间步，S_t 表示当前时间步的交通状态，X_t 表示依据任务背景与当前状态构造的提示，Y_t 表示 LLM 基于提示 X_t 生成的响应，a_t^p 和 a_t^d 表示当前时间步 LLM 所选相位与持续时间动作，$Q^p\left(S_t, a_t^p\right)$ 和 $Q^d\left(\left(S_t, a_t^p\right), a_t^d\right)$ 用于计算当前时间步强化学习模型预测的 LLM 所选相位动作与持续时间动作 Q 值，$\text{Norm}(\cdot)$ 表示归一化函数，$\text{Rank}(\cdot)$ 表示排序函数。

在数据过滤第二步中，采用 LLM 自身反思进行筛选，将第一步筛选后保留的指令提示与推理数据进行拼接，形成新的提示词。随后，基于新提示词，引导 LLM 对之前做出的决策进行合理性分析，以此判断决策是否恰当。这一步旨在防止当强化学习模型选取明显不合理的决策时，导致的本地基座模型学习到错误的推理模式，保证 LLM 学习过程的准确性和有效性。

在获取到充足的高质量推理数据后，下一步是利用这批数据对本地基座模型进行监督微调。设待优化的本地基座模型参数为 θ，用 $\pi_\theta(y|x)$ 表示在给定输入 x 的情况下，参数为 θ 的大语言模型生成响应 y 的概率。训练采用 LoRA 方法，仅在预训练模型的指定密集层添加可训练的低秩矩阵。使用经过强化学习模型筛选后的提示-响应数据对 (X, Y) 作为训练数据，将提示 X 作为指令输入本地基座模型，大参数量模型生成的响应 Y 作为监督信号，采用负对数似然（Negative Log-Likelihood, NLL）损失函数计算本地基座模型响应与标签的偏差，其具体公式如式 4.14 所示。

$$\mathcal{L}_{\text{SFT}}\left(\pi_\theta\right) = -\sum_{i=1}^{N} \log\left(\pi_\theta\left(y_i | X, Y_{<i}\right)\right) \quad (4.14)$$

其中，N 为响应 Y 的序列长度，y_i 表示第 i 个生成的 token，$Y_{<i}$ 表示生成第 i 个 token 时所依赖的此前所有已生成的信息。通过监督微调的优化过程，策略模型 π_θ 逐渐向大参数量模型高质量推理数据的条件概率分布逼近，从而学习到经过强化学习模型验证的有效决策模式。

4.4.2 基于强化学习模型排序的偏好对齐微调

在第一阶段训练流程中，本地基座模型可以学习到大参数量模型的回答模式与推理思路，进而提升其生成高质量策略的概率。然而，这一阶段的训练并未减少低质量策略出现的概率，也就意味着模型在某些情况下仍可能生成出不理想的推理结果。因此，第二阶段的训练目标在于，通过对齐微调引导 LLM 提高对优秀策略的采样概率，同时降低对较差策略的采样概率，从而调整模型生成策略的概率分布，使模型输出更

中国知网 https://www.cnki.net

符合任务的预期要求。

常用的 LLM 对齐方法[28, 58–61] 如基于人类反馈的强化学习（Reinforcement Learning from Human Feedback，RLHF）等，通常涉及复杂的多阶段训练流程。以 RLHF 中的近端策略优化（Proximal Policy Optimization，PPO）算法为例，其首先训练奖励模型来评估生成内容的即时反馈，然后通过评论家模型估计当前策略的优势，最后通过强化学习优化策略模型。这类方法需要多阶段训练，训练效率低且收敛难度大，最终模型性能高度依赖奖励模型的准确性和稳定性。同时，也有研究工作[19] 指出 RLHF 方法在交通信号控制任务上收敛困难，效果不佳。

考虑到上述因素，本阶段在训练方法上采用带有正则项的直接偏好优化（Direct Preference Optimization，DPO）[62] 算法，其核心思想是通过对 LLM 多次采样数据进行偏好排序来直接优化策略模型，而不依赖于传统的显式奖励与优势估计，避免了复杂的多阶段训练流程与奖励模型评估偏差，简化了对齐训练的中间环节，使得训练更加直接和高效。

DPO 算法基于 Bradley-Terry 偏好模型构建损失函数，其核心目标是在保持模型生成多样性的同时，使偏好响应获得更高的生成概率。具体而言，对于给定提示 X 及其对应的两组响应 Y_w 和 Y_l，假设 Y_w 的偏好程度更高，则 DPO 算法的目标即为调整 LLM 的参数 π_θ，使得模型在给定输入 X 时，提升偏好响应 Y_w 的生成概率 $\pi_\theta(Y_w|X)$，同时降低不偏好响应 Y_l 的生成概率 $\pi_\theta(Y_l|X)$。

在第二阶段训练流程中，首先使用经过第一阶段监督微调后的本地模型与仿真交通环境不断交互，每次交互会进行多次采样生成一批响应，记为 $\{(X,Y_1),...,(X,Y_n)\}$，表示针对同一交通状况生成 n 对提示-响应数据对。考虑到计算资源与生成效率的平衡，本研究设定 $n=6$，即每个提示对应生成 6 组响应。

与第一阶段训练流程类似，引入 4.2 节所设计的强化学习模型作为辅助模型，分别计算相位动作与持续时间动作的归一化 Q 值，依据 LLM 所选动作对每一组数据计算得分并排序。正如前文所分析，相位决策才是提升交通信号对不同交通需求适应性的关键因素，因此为相位动作分数分配 0.9 的权重，持续时间动作分数分配 0.1 的权重，即 LLM 的决策总得分为：

$$\text{score} = 0.9\text{Norm}\left(Q^p\left(S_t, a_t^p\right)\right) + 0.1\text{Norm}\left(Q^d\left(\left(S_t, a_t^p\right), a_t^d\right)\right) \in (0,1) \tag{4.15}$$

经过第一阶段的监督微调后，LLM 在处理交通任务时已有更为出色的表现，经其多次采样生成并排序的数据，可能会出现得分普遍较高，或者得分差距不明显等情况，这类数据无法满足对齐训练目的，因此仍需进行一定的过滤处理。

在包含 16 个交叉口的仿真交通环境中，对一小时的随机模拟交通流情况展开测试。采用经过监督微调训练的模型与强化学习模型以动态持续时间间隔，与仿真交通

中国知网 https://www.cnki.net

环境进行周期性交互。在这个过程中，LLM 每轮交互采样 4 次，记录 LLM 每次采样所决策的动作以及强化学习模型相应的评分，共获得 3116 组数据，筛去无效回答与交通流初始阶段无车辆的情况，共剩余 2568 条有效数据。表 4.2 中展示了随机数据上 LLM 决策得分的最高分与最低分差值分布情况。

考虑到本阶段的训练目标是要提高对优秀策略的采样概率，同时降低对较差策略的采样概率。为实现上述目标，同一组采样数据内的分数需有较大差距，并且最高得分也应该大于某一阈值，这样才能保证学习到好的策略并原理差的策略。因此，基于表 4.2 中的分数差值分布情况，设定当同一组采样数据内，最高分与最低分差值大于 0.5，且最高分高于 0.8 时，该组数据予以保留，反之则将被筛除。

表 4.2　随机数据上 LLM 决策得分的最高分与最低分差值分布

Tab. 4.2　Distribution of the difference between the highest and lowest scores of actions decided by LLM on random data

差值区间	[0.0,0.3]	(0.3-0.5]	(0.5-0.7]	(0.7-1.0]
数据条数	1336	509	431	292

保留的数据再经过一轮 LLM 反思检查，在通过检查后的每一组采样数据中，挑选出最高分响应与最低分响应，构造成选择-拒绝（Chosen-rejected）数据对 (X, Y_w, Y_l)，其中 X 代表选择与拒绝样本共用的提示，Y_w 代表选择样本对应的响应，Y_l 代表拒绝样本对应的响应。其中，最高分响应被视为模型应该接受并学习的 chosen 样本，而最低分响应则被视为模型应该拒绝并远离的 rejected 样本。

经过数据过滤与排序流程后，当收集到足够多本地模型生成的选择-拒绝数据对时，接下来是利用这批偏好数据对经过第一阶段监督微调后的本地模型进行对齐微调。设待优化的本地模型参数为 θ，用 $\pi_\theta(y|x)$ 表示其在给定输入 x 的情况下生成输出 y 的概率。定义经过第一阶段监督微调后冻结参数的 LLM 为参考模型（Reference model），用 $\pi_{ref}(y|x)$ 表示参考模型在给定输入 x 的情况下生成输出 y 的概率。

训练过程同样采用 LoRA 方法，在预训练模型的指定密集层添加可训练的低秩矩阵。使用经过强化学习模型筛选后的的选择-拒绝数据对 (X, Y_w, Y_l) 作为训练数据，将提示 X 作为指令输入待优化模型和参考模型，分别计算待优化模型针对选择样本 Y_w 的解码概率 $\pi_\theta(Y_w|X)$ 与拒绝样本 Y_l 的解码概率 $\pi_\theta(Y_l|X)$，以及参考模型针对二者的解码概率 $\pi_{ref}(Y_w|X)$ 和 $\pi_{ref}(Y_l|X)$。DPO 损失函数的优化目标是使待优化模型在不偏离参考模型太远的基础上，最大化选择样本与拒绝样本的相对概率比，提高前者生成概率，降低后者生成概率，其具体定义如式 4.16 所示。

$$\mathcal{L}_{\text{DPO}}\left(\pi_\theta; \pi_{ref}\right) = -\log\sigma\left(\beta\log\frac{\pi_\theta\left(Y_w|X\right)}{\pi_{ref}\left(Y_w|X\right)} - \beta\log\frac{\pi_\theta\left(Y_l|X\right)}{\pi_{ref}\left(Y_l|X\right)}\right) \tag{4.16}$$

中国知网　https://www.cnki.net

其中，$\sigma(\cdot)$ 表示 sigmoid 函数，β 为超参数，用于控制模型在优化过程中对偏好数据的敏感度，值越大表示对偏离参考模型的惩罚越大。

此外，为防止模型在优化过程中过度降低拒绝样本的生成概率，从而连带影响选择样本的生成概率，本研究引入了针对选择样本的负对数似然损失函数作为正则项，如式 4.17 所示。总损失如式 4.18 所示，其中，NLL 损失系数 λ 为超参数，用于平衡负对数似然损失占比，稳定训练过程。

$$\mathcal{L}_{\text{NLL}}(\pi_\theta) = -\sum_{i=1}^{N} \log\left(\pi_\theta\left(y_{w,i}|X, Y_{w,<i}\right)\right) \tag{4.17}$$

$$\mathcal{L}_{\text{total}}(\pi_\theta; \pi_{ref}) = \mathcal{L}_{\text{DPO}}(\pi_\theta; \pi_{ref}) + \lambda \mathcal{L}_{\text{NLL}}(\pi_\theta) \tag{4.18}$$

通过基于强化学习模型偏好排序的对齐微调优化过程，策略模型 π_θ 逐渐提升生成选择样本 Y_w 的条件概率，同时抑制生成拒绝样本 Y_l 的条件概率，进一步强化了 LLM 选择同长远目标更契合决策的能力。

4.5 实验设置与准备

4.5.1 数据集

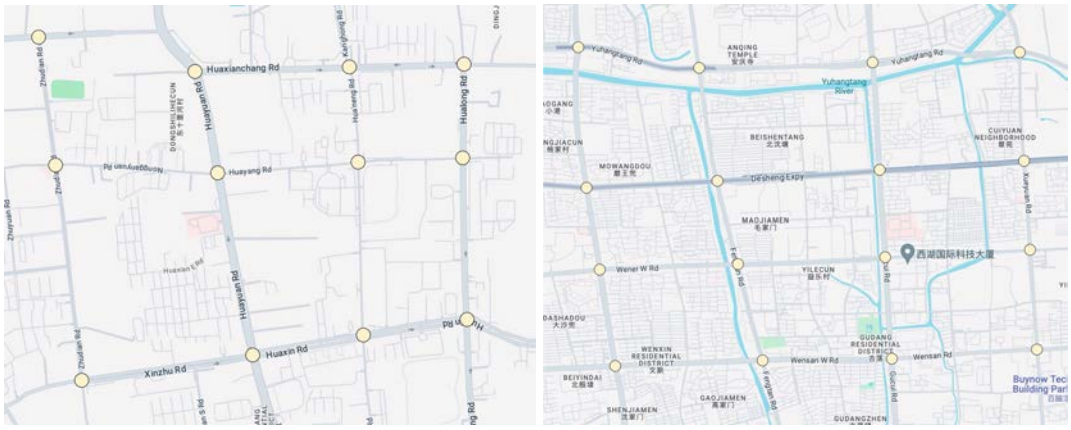
在交通信号控制研究中，实验数据通常采集于现实世界道路网络的交通流量记录。本研究选用了该领域内广泛认可的五组数据集[63]，其中三组数据采集于中国济南市东风街道，两组数据采集于杭州市古荡街道。每组数据集均详细记录了特定路网下一小时内的完整交通流信息。表 4.3 总结了每个数据集的具体信息，包括路网交叉口数量、路段跨度、车辆总数目以及平均有效流量等。图 4.14 展示了济南和杭州数据集路网的具体结构。

表 4.3 数据集具体信息
Tab. 4.3 Dataset details

数据集	交叉口数	总车辆数	南北向跨度 (m)	东西向跨度 (m)	平均流量 (每 5min)
JN-1	12	6295	800	400	523.67
JN-2	12	4365	800	400	362.83
JN-3	12	5494	800	400	456.92
HZ-1	16	2983	600	800	247.67
HZ-2	16	6984	600	800	581.08

此外，为评估模型在极端交通状况下的性能表现，本研究基于济南和杭州真实数据集的路网结构，通过随机生成车流的方式合成了极端高流量模拟数据集。模拟数据集的时间跨度同样设置为 1 小时，其交通流量约为真实数据集的 4 倍，旨在检验模型

中国知网 https://www.cnki.net



(a) 济南数据集路网　　(b) 杭州数据集路网

图 4.14　济南和杭州数据集路网

Fig. 4.14　The road network of Jinan and Hangzhou datasets.

在高负荷交通压力下的处理能力与鲁棒性。表 4.4 详细列出了极端高流量模拟数据集的具体信息。

表 4.4　极端高流量模拟数据集具体信息

Tab. 4.4　Extreme high-traffic flow synthetic dataset details

数据集	交叉口数	总车辆数	南北向跨度 (m)	东西向跨度 (m)	平均流量 (每 5min)
JN-EX	12	24000	800	400	1999.08
HZ-EX	16	32000	600	800	2663.67

4.5.2　评价指标

交通信号控制任务的核心目标是优化路网通行效率，并且考虑到本领域内的常见评价指标[10]，本研究主要关注三个能反映交通流效率的评价指标：

（1）平均旅行时间（Average Travel Time，ATT）

平均旅行时间表示路网中所有车辆从出发地到目的地的所需时间平均值，计算公式如式 4.19 所示。其中，N 表示总车辆数，t^i_{start} 表示第 i 辆车的出发时间，t^i_{end} 表示第 i 辆车的抵达时间。

$$\text{ATT} = \frac{\sum_{i=1}^{N} (t^i_{\text{end}} - t^i_{\text{start}})}{N} \tag{4.19}$$

（2）平均等待时间（Average Waiting Time，AWT）

平均等待时间表示路网中所有车辆等待通行所需的排队时间平均值，计算公式如式 4.20 所示。其中，N 表示总车辆数，t^i_{wait} 表示第 i 辆车等待通行的排队时间。

中国知网　https://www.cnki.net

$$\mathrm{AWT} = \frac{\sum_{i=1}^{N} t_{\mathrm{wait}}^{i}}{N} \tag{4.20}$$

（3）平均排队长度（Average Queue Length，AQL）

平均排队长度表示路网中各交叉口排队等待的车辆数目平均值。计算时按预设的时间周期统计路网中总的排队车辆数，对所有周期的统计值取平均值，即为平均排队长度。计算公式如式 4.21 所示。其中，t 表示当前周期，T 表示总周期数，l_i 表示第 i 个交叉口的排队车辆数。

$$\mathrm{AQL} = \frac{\sum_{t=1}^{T} (\sum_{i} l_i)}{T} \tag{4.21}$$

以上三个指标从不同维度刻画了路网交通流的状态，其数值均与交通流效率呈负相关关系，即各项指标数值越低表明交通流运行越高效。通过这些指标能够全面、有效地评估相关模型的性能表现。其中，ATT 作为交通信号控制领域最核心的评价指标，是衡量模型性能的首要考量因素，AQL 和 AWT 作为辅助评价指标，可进一步反映交通信号控制的效果。

4.5.3 基线方法

本研究系统性地对比了五类交通信号控制方法的性能表现，具体包括：（1）基于规则或启发式的传统交通工程方法；（2）固定时间强化学习方法；（3）动态时间强化学习方法；（4）大语言模型提示工程方法；（5）大语言模型微调方法。表 4.5 列举了本研究主要比较的基线方法及其相关信息。

表 4.5　本研究主要比较的基线方法

Tab. 4.5　Baseline methods primarily compared in this study

方法	类型	发表年份	发表刊物
Random	传统交通工程	-	-
FixedTime[2]	传统交通工程	2008	-
Maxpressure[3]	传统交通工程	2013	Transp. Res. Part C
PressLight[7]	固定时间强化学习	2019	KDD
CoLight[8]	固定时间强化学习	2019	CIKM
MPLight[5]	固定时间强化学习	2020	AAAI
AttendLight[6]	固定时间强化学习	2020	NIPS
Efficient-CoLight[9]	固定时间强化学习	2021	预印本
Advanced-CoLight[10]	固定时间强化学习	2022	ICML
DynamicLight[11]	动态时间强化学习	2024	预印本
LLMLight[19]	大语言模型微调	2025	KDD

中国知网 https://www.cnki.net

传统交通工程方法主要依赖预设规则进行信号相位的调控。固定时间强化学习方法采用固定相位周期，在每个决策时刻仅对相位动作进行选择。动态时间强化学习方法则在每个决策时刻同时决定相位动作与持续时间动作的选择。

在大语言模型方法中，本研究主要关注提示工程方法与微调方法。提示工程方法直接利用基座模型的自身能力，通过提供少量参考示例以激发模型对任务的理解与推理能力，而不对模型进行额外训练。微调方法则通过收集与目标任务相关的标注数据，对大规模预训练模型进行针对性训练，以提升其在领域任务中的理解与推理能力。

目前，仅有 LLMLight 这一研究开创性地将 LLM 作为信号控制决策的主体。而本研究在大模型作为信号控制决策主体的基础上，实现了更细粒度以及更全面的动态信号控制。因此，本研究将与 LLMLight 进行重点对比分析，以深入评估大语言模型在交通信号控制中的应用价值与性能表现。

4.5.4 实验设置

本研究实验环境搭建于高性能计算服务器，硬件配置包括 2 块 NVIDIA A100 80GB GPU 与 Intel Xeon Gold 6248 CPU。软件环境采用 Python 3.10 编程语言，并基于 PyTorch 2.4.0 深度学习框架进行模型训练与测试。

在强化学习模型的训练过程中，所有模型均使用 Adam 优化器进行参数优化，初始学习率设定为 1×10^{-3}；经验回放区容量设定为 12000，每批次采样规模为 3000；折扣因子 γ 设定为 0.8。采用分周期（episode）策略，每个训练周期包含 100 个训练轮次（epoch），总训练周期数为 100。对于本研究提出的结合邻居信息的动态强化学习方法，奖励平衡系数 η 设定为 0.2，注意力层头数设置为 8。

在大语言模型的两阶段训练过程中，均采用 LoRA 方法进行参数更新，选取模型 Transformer 层中的所有线性层参与训练，其中低秩分解矩阵的秩（rank）设置为 16，缩放因子 α 设置为 32，批次大小设置为 8，训练轮次设置为 3。在优化策略方面，两阶段训练中均采用 AdamW[64] 优化器进行参数优化，并在训练初期引入 10% 的学习率预热比例，同时结合余弦退火学习率调度算法。在监督微调阶段，目标学习率设置为 5×10^{-5}。在对齐微调阶段，为避免过大的参数扰动，本阶段采用更为保守的目标学习率 1×10^{-6}；DPO 损失函数中的超参数 β 设置为 0.1；总损失函数中的 NLL 损失系数 λ 设置为 0.2。对于推理时的采样策略，top-p 采样参数设置为 1.0，top-k 采样参数设置为 20，温度（temperature）设置为 0.1。

在模型部署方面，对于 Qwen2.5-7B 和 Llama3.1-8B 两个大语言模型以及强化学习模型，均采用本地服务器部署进行训练和推理；而对于参数量较大的 DeepSeek-V3 模型，考虑到本地计算资源限制，采用云服务厂商提供的 API 接口进行远程调用。

中国知网 https://www.cnki.net

4.6 实验结果与分析

4.6.1 相位持续时间敏感性实验

本节中进行了相位持续时间敏感性实验，旨在确定固定时间强化学习方法的最优相位持续时间，并为动态时间强化学习与大模型方法选取合适的相位持续时间集合。

实验首先采用固定时间强化学习 SOTA 方法 Advanced-CoLight 作为基准模型，在 JN-1 和 JN-3 数据集上分别设定不同的相位持续时间进行训练，以系统性地评估不同相位持续时间对模型性能的影响。具体实验结果如表 4.6 所示，其中各指标的最优性能以加粗字体标注。

表 4.6　不同相位持续时间下模型性能比较

Tab. 4.6　Comparison of model performance under different phase duration

相位持续时间	JN-1 数据集性能			JN-3 数据集性能		
	ATT(s)	AQL(veh)	AWT(s)	ATT(s)	AQL(veh)	AWT(s)
10	260.59	113.67	**38.92**	243.66	79.31	36.44
15	**255.05**	**105.90**	39.01	**237.61**	**72.28**	**33.23**
20	266.27	129.22	44.97	245.43	90.04	44.04
30	274.67	160.85	49.30	260.66	127.83	43.54

实验结果表明，当相位持续时间设置为 15 秒时，Advanced-CoLight 取得了综合最优的性能表现。因此，本研究后续实验中需要固定相位持续时间的方法均设定相位持续时间为 15 秒，以确保实验比较的公平性。

表 4.7　不同相位持续时间集合下模型性能比较

Tab. 4.7　Comparison of model performance under different phase duration set

相位持续时间集合	济南数据集性能		
	ATT(s)	AQL(veh)	AWT(s)
{10,20,30,40}	235.77	70.01	32.14
{10,20,30,40,50,60}	236.19	70.37	33.63
{10,15,20,25,30}	233.63	69.56	<u>31.38</u>
{10,15,20,25,30,35,40}	<u>232.50</u>	**67.52**	**29.71**
{10,15,20,25,30,35,40,45,50,55,60}	**232.43**	<u>68.83</u>	31.76

为确定动态相位持续时间集合，采用 4.2 节所设计的模型在同一数据集上分别设定不同的持续时间集合进行训练，具体实验结果如表 4.7 所示，其中各指标的最优性能以加粗字体标注，次优性能以下划线标识。实验结果表明，当相位持续时间集合设

中国知网 https://www.cnki.net

定为 {10s,15s,20s,25s,30s,35s,40s} 时，模型取得了综合最优的性能表现，因此将上述相位持续时间集合设定为后续实验中动态强化学习与本章大模型方法的标准配置。

4.6.2 主实验结果与分析

为验证本章所提出方法的有效性，本研究选取 Llama3.1-8B 和 Qwen2.5-7B 两个基座模型作为实验对象，采用本章提出的两阶段训练流程进行模型训练。实验数据来源于济南和杭州两个城市的五组真实历史交通数据集，通过与现有基线方法的对比实验，对所提方法进行了全面的性能评估和分析。

表 4.8 各方法在济南数据集上的总体表现

Tab. 4.8 Overall performances of all methods on Jinan datasets

方法	JN-1			JN-2			JN-3		
	ATT (s)	AQL (veh)	AWT (s)	ATT (s)	AQL (veh)	AWT (s)	ATT (s)	AQL (veh)	AWT (s)
Random	575.48	608.06	53.47	509.95	354.34	50.44	525.02	470.60	50.80
FixedTime	461.69	451.42	54.55	403.66	239.10	50.10	412.07	330.39	51.77
Maxpressure	274.99	132.75	**32.79**	246.40	56.33	**23.28**	244.62	79.65	**27.15**
MPLight	301.17	179.92	60.58	274.21	81.77	56.09	268.06	112.91	53.27
AttendLight	285.43	148.87	52.71	256.47	66.48	45.47	249.78	85.63	38.30
PressLight	280.99	148.74	42.28	258.21	66.74	37.25	249.77	83.31	37.42
CoLight	276.19	141.32	48.72	253.26	63.39	47.66	246.22	80.96	38.01
Efficient-CoLight	258.73	108.52	33.98	248.23	50.98	23.39	242.40	75.80	29.85
Advanced-CoLight	255.05	105.90	39.01	246.31	49.08	31.33	237.61	72.28	33.23
DynamicLight	251.42	102.98	35.83	236.67	49.22	27.13	233.11	68.78	30.85
Our RL	248.73	100.65	35.16	233.96	46.61	24.54	232.50	67.52	29.71
Llama3.1-8B	374.16	237.47	70.41	298.33	154.06	65.86	314.39	187.91	60.63
DeepSeek-V3	323.88	195.72	58.06	285.74	126.10	52.32	280.17	150.36	50.11
LLMLight	253.61	102.29	37.52	235.90	49.23	28.04	235.26	71.92	28.63
本章方法-Qwen	250.40	100.41	38.06	234.04	44.21	24.56	231.47	66.33	30.68
本章方法-Llama	**248.29**	**99.06**	35.07	**231.81**	**42.95**	24.88	**230.49**	**64.63**	28.64

表 4.8 和表 4.9 展示了不同方法在济南和杭州数据集上的性能表现，表中各评价指标的最优性能以加粗字体标注，排名第二性能以双下划线标注，排名第三性能以单下划线标注。其中，“Our RL”表示 4.2 节提出的融合邻居信息的动态强化学习方法；“Llama3.1-8B”和“DeepSeek-V3”分别表示基于这两个通用大语言模型，仅采用本章设计的提示模板进行提示工程而未经微调的方法；“本章方法-Qwen”和“本章方法-Llama”分别表示在 Qwen2.5-7B 和 Llama3.1-8B 基座模型上，通过本章提出的两阶段训练流程进行微调的方法。

中国知网 https://www.cnki.net

表 4.9　各方法在杭州数据集上的总体表现

Tab. 4.9　Overall performances of all methods on Hangzhou datasets

方法	HZ-1			HZ-2		
	ATT(s)	AQL(veh)	AWT(s)	ATT(s)	AQL(veh)	AWT(s)
Random	571.52	245.80	49.00	463.86	361.57	84.30
FixedTime	497.87	192.82	36.83	418.31	290.97	78.90
Maxpressure	299.55	32.64	23.52	359.85	207.32	70.53
MPLight	326.57	53.37	50.52	364.68	233.17	71.09
AttendLight	327.19	52.59	32.70	359.65	210.10	71.96
PressLight	308.91	46.19	60.24	348.29	219.84	143.42
CoLight	314.21	42.70	67.05	350.32	188.80	77.52
Efficient-CoLight	296.57	30.51	**21.32**	334.88	178.32	69.65
Advanced-CoLight	288.72	26.42	32.34	320.51	169.55	82.96
DynamicLight	287.29	24.85	25.53	322.88	165.21	77.54
Our RL	285.53	23.51	23.80	317.71	165.75	75.89
Llama3.1-8B	309.66	48.46	52.33	329.16	178.94	74.27
DeepSeek-V3	297.49	38.71	41.13	327.29	161.08	70.14
LLMLight	284.31	27.96	27.94	318.16	169.61	68.75
本章方法-Qwen	287.32	31.98	30.94	310.19	157.62	79.00
本章方法-Llama	**275.36**	**19.20**	22.36	**308.92**	**139.69**	**65.88**

实验结果表明，本章提出的融合邻居信息的动态强化学习方法在综合性能上优于所有基线强化学习方法和启发式算法。更为突出的是，通过本章设计的两阶段训练策略对 Llama3.1-8B 基座模型进行微调后，在多个真实数据集上的测试中均展现出卓越的性能表现，在核心评价指标 ATT 与次要指标 AQL 上均达到了最优性能，而在另一次要指标 AWT 上也取得了平均前三名的优异表现。接下来将详细对比基于 Llama3.1-8B 微调的本章方法相较于基线方法在各项性能指标上的具体提升情况。

在三组济南数据集的测试中，基于 Llama3.1-8B 微调的本章方法相较于传统交通工程代表性方法 Maxpressure，在 ATT 指标上实现了 7.73% 的综合性能提升，在 AQL 指标上实现了 29.47% 的显著提升，在 AWT 指标上出现 6.04% 的性能下降。相较于固定时间强化学习代表性方法 Advanced-CoLight，本章方法在 ATT、AQL 和 AWT 三个指标上分别实现了 4.02%、11.00% 和 17.73% 的综合性能提升。相较于动态时间强化学习代表性方法 DynamicLight，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 1.50%、8.33% 和 6.31% 的综合性能提升。相较于 4.2 节所提出的融合邻居信息的动态强化学习方法，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 0.66%、4.87% 和 0.88% 的综合性能提升。相较于使用通用大模型 DeepSeek-V3 并结合本章所设计的提示模板的方法，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 25.09%、196.39%

中国知网　https://www.cnki.net

和 125.73% 的综合性能提升。相较于同样基于大模型微调的方法 LLMLight，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 1.99%、9.72% 和 6.55% 的综合性能提升。相较于使用 Qwen2.5-7B 作为基座模型，基于 Llama3.1-8B 微调的本章方法在 ATT、AQL 和 AWT 指标上分别实现了 0.75%、2.31% 和 4.79% 的综合性能提升。

表 4.10　本章方法相较于各基线方法的性能提升或下降情况
Tab. 4.10　The performance improvement or decline of the proposed method compared to various baseline methods

对比方法	JN 数据集综合对比			HZ 数据集综合对比		
	ATT(%)	AQL(%)	AWT(%)	ATT(%)	AQL(%)	AWT(%)
Random	126.52↑	622.33↑	77.52↑	78.85↑	669.52↑	73.55↑
FixedTime	79.62↑	407.87↑	79.22↑	58.11↑	506.28↑	42.24↑
Maxpressure	7.73↑	29.47↑	-6.04↓	12.64↑	59.21↑	6.12↑
MPLight	18.63↑	82.24↑	94.73↑	18.32↑	122.44↑	66.92↑
AttendLight	11.32↑	45.85↑	55.60↑	17.62↑	112.16↑	27.74↑
PressLight	10.97↑	44.81↑	33.64↑	12.46↑	98.97↑	143.55↑
CoLight	9.10↑	38.51↑	54.40↑	13.76↑	78.78↑	108.77↑
Efficient-CoLight	5.49↑	15.18↑	-1.62↓	8.05↑	43.28↑	0.54↑
Advanced-CoLight	4.02↑	11.00↑	17.73↑	4.30↑	29.49↑	35.28↑
DynamicLight	1.50↑	8.33↑	6.31↑	4.43↑	23.85↑	15.94↑
OurRL	0.66↑	4.87↑	0.88↑	3.27↑	20.55↑	10.82↑
Llama3.1-8B	38.60↑	196.39↑	125.73↑	9.51↑	90.25↑	73.39↑
DeepSeek-V3	25.09↑	141.27↑	83.60↑	6.99↑	58.46↑	37.62↑
LLMLight	1.99↑	9.72↑	6.55↑	3.12↑	33.52↑	14.66↑
本章方法-Qwen	0.75↑	2.31↑	4.79↑	2.38↑	39.70↑	29.14↑
本章方法-Llama	-	-	-	-	-	-

在两组杭州数据集的测试中，基于 Llama3.1-8B 微调的本章方法相较于传统交通工程代表性方法 Maxpressure，在 ATT、AQL 和 AWT 三个指标上分别实现了 12.64%、59.21% 和 6.12% 的综合性能提升。相较于固定时间强化学习代表性方法 Advanced-CoLight，本章方法在 ATT、AQL 和 AWT 三个指标上分别实现了 4.30%、29.49% 和 35.28% 的综合性能提升。相较于动态时间强化学习代表性方法 DynamicLight，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 4.43%、23.85% 和 15.94% 的综合性能提升。相较于 4.2 节所提出的融合邻居信息的动态强化学习方法，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 3.27%、20.55% 和 10.82% 的综合性能提升。相较于使用通用大模型 DeepSeek-V3 并结合本章所设计的提示模板的方法，本章方法在 ATT、AQL 和 AWT 指标上分别实现了 6.99%、58.46% 和 37.62% 的综合性能提升。相较于同样基于大模型微调的方法 LLMLight，本章方法在 ATT、AQL 和 AWT 指标上分别

中国知网 https://www.cnki.net

实现了 3.12%、33.52% 和 14.66% 的综合性能提升。相较于使用 Qwen2.5-7B 作为基座模型，基于 Llama3.1-8B 微调的本章方法在 ATT、AQL 和 AWT 指标上分别实现了 2.38%、39.70% 和 29.14% 的综合性能提升。

表 4.10 量化了基于 Llama3.1-8B 微调的本章方法相较于基线方法在各评价指标上性能提升或下降情况，采用百分比形式呈现对比结果，其中向上箭头（↑）表示本章方法在特定指标上相较于对比方法的性能提升百分比，向下箭头（↓）则表示性能下降的百分比。实验对比结果充分证明了本章方法的优越性，在济南和杭州真实数据集上，本章方法均取得了极具竞争力的表现。

4.6.3 可迁移性实验与分析

在城市交通信号控制领域，由于路网拓扑结构存在显著差异以及交通流量模式具有高度异质性，模型的跨城市路网应用面临严峻挑战。传统的强化学习方法通常依赖于特定城市路网的大量历史数据进行训练，这些数据深刻反映了该区域的交通特征。然而，当这类模型迁移到新的路网环境时，由于数据分布的差异，模型往往难以有效泛化，从而导致性能的显著下降。

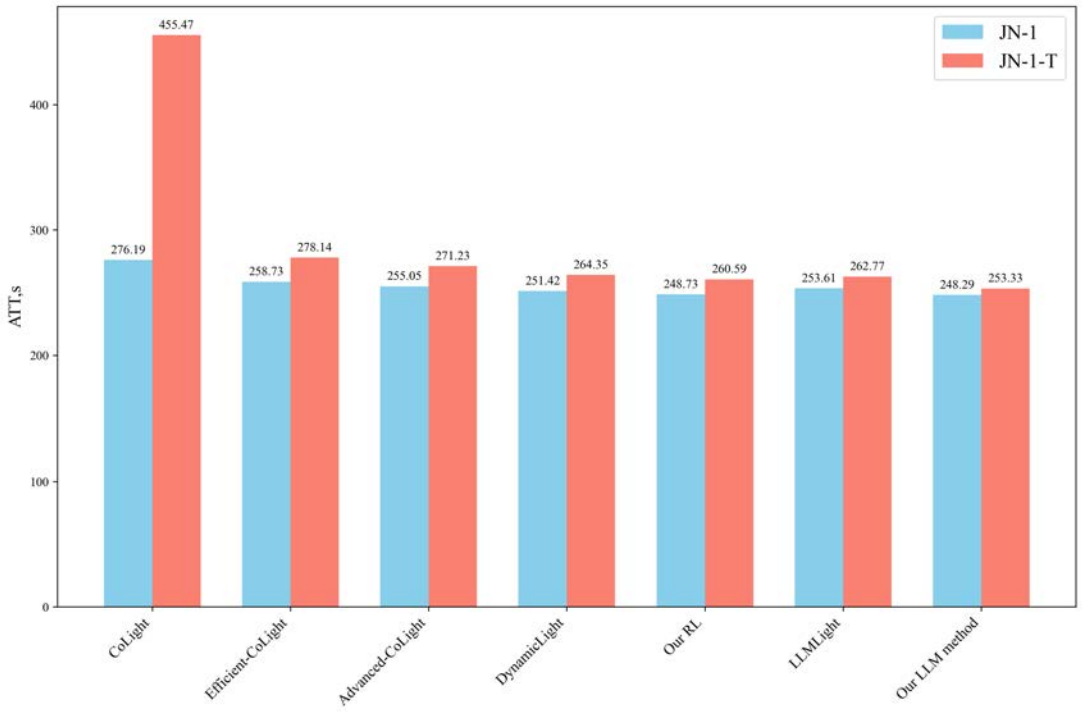
表 4.11 主流方法可迁移性实验

Tab. 4.11 Transferability experiment of mainstream methods

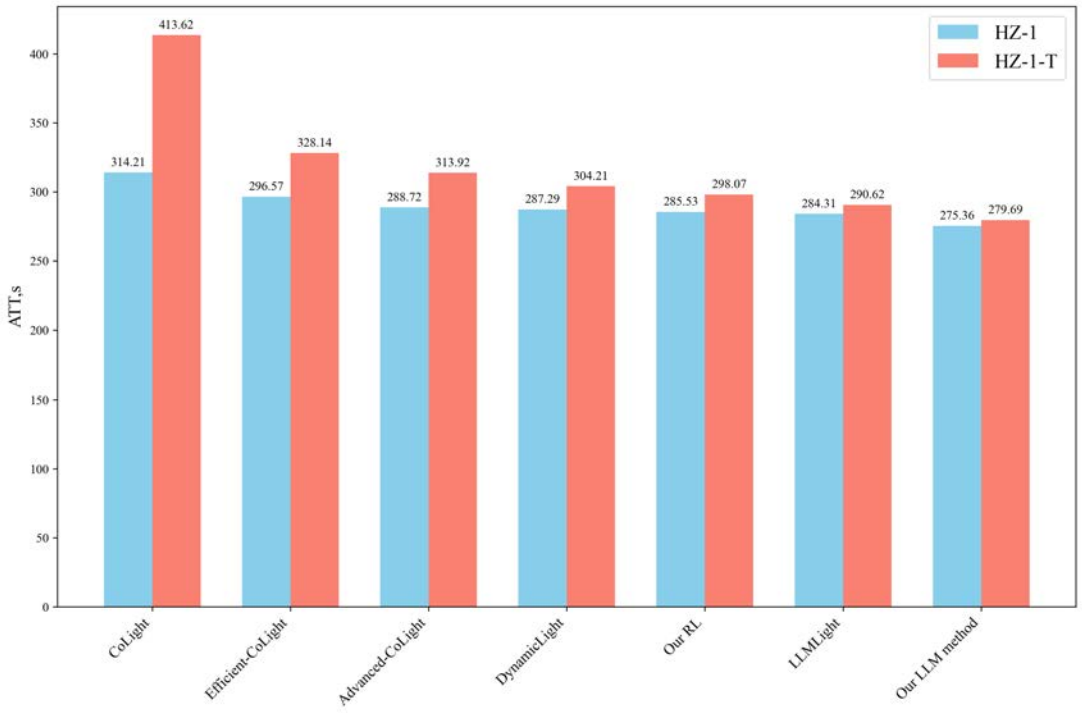
方法	JN→HZ			HZ→JN			总变化
	ATT(s)	AQL(veh)	AWT(s)	ATT(s)	AQL(veh)	AWT(s)	
CoLight	413.62	126.75	57.71	455.47	418.37	49.79	79.62%↓
Efficient-CoLight	328.14	40.60	25.33	278.14	140.33	39.34	19.19% ↓
Advanced-CoLight	313.92	36.46	51.14	271.23	118.65	33.81	18.32%↓
DynamicLight	304.21	32.78	43.82	264.35	113.73	36.22	21.02%↓
Our RL	298.07	29.85	46.31	260.59	115.13	38.20	25.62% ↓
LLMLight	290.62	31.61	32.93	262.77	110.45	42.79	9.79%↓
本章方法-Llama	**279.69**	**23.45**	**25.03**	**253.33**	**102.51**	**37.16**	**7.85%↓**

相比之下，大语言模型通过大规模预训练过程，已经学习到了丰富的语义表示和通用知识，具有高度的普适性和可迁移性特征。尽管不同城市的路网结构存在差异，但交通领域的基本概念和控制逻辑具有内在一致性，例如交通拥堵的形成机制、信号控制的优化原则等。大语言模型能够有效利用这些共性知识，在新环境中最大限度地降低性能损失，这种特性使得大模型方法在跨路网交通信号控制任务中展现出更强的鲁棒性和可迁移性。

中国知网 https://www.cnki.net



(a) 各方法迁移前后在 JN-1 数据集上的 ATT 指标对比



(b) 各方法迁移前后在 HZ-1 数据集上的 ATT 指标对比

图 4.15　各方法迁移前后 ATT 指标对比图

Fig. 4.15　Comparison of ATT metrics for different methods before and after transfer

为深入探究各类模型的可迁移性，本节中首先在特定路网环境中对模型进行预训

中国知网　https://www.cnki.net

练，随后将其直接迁移至具有不同特征的另一路网进行性能评估。表 4.11 详细展示了主流强化学习方法与本章提出的大模型方法的可迁移性实验结果，其中，“JN→HZ”表示使用在济南数据集 JN-1 上预训练的模型来评估其在杭州数据集 HZ-1 上的性能，“HZ→JN”表示使用在杭州数据集 HZ-1 上预训练的模型来评估其在济南数据集 JN-1 上的性能，“总变化”表示迁移前后模型性能总的下降幅度。图 4.15 以核心性能指标 ATT 为例，直观展示了在 JN-1 和 HZ-1 数据集迁移前后的模型性能对比，图例中“-T”表示进行迁移测试的模型。

实验结果显示，基于强化学习的方法在迁移后的性能同比迁移前下降均超过 20%。相比之下，基于大模型微调的方法性能退化均控制在 10% 以内，仍展现出卓越的性能，充分证明了大模型方法优越的泛化能力与可迁移性。

4.6.4 极端高流量实验与分析

现有交通数据集主要涵盖常规流量场景，难以反映极端高交通流量的现实需求。为评估不同方法在极端高流量场景下的有效性，本研究基于济南和杭州城市路网的拓扑结构，采用随机生成方式合成了极端高流量模拟数据集 JN-EX 和 HZ-EX，其总交通流量约为真实数据集的 4-5 倍，数据集具体信息详见 4.5.1 节。

本节实验采用在 JN-1 数据集上预训练的模型，迁移至极端高流量模拟数据集上进行测试与评估。针对城市交通拥堵场景的核心优化需求，其优化目标是最大化出行效率与驾驶体验，因此本节实验选取平均旅行时间 ATT 和平均等待时间 AWT 作为评价指标，对模型在极端场景下的性能表现进行评估，相关实验结果如表 4.12 所示。

表 4.12　极端高流量场景下主流方法性能

Tab. 4.12　The performance of mainstream methods in extreme high-traffic scenarios

方法	JN-EX		HZ-EX	
	ATT(s)	AWT(s)	ATT(s)	AWT(s)
CoLight	1354.40	722.68	782.86	337.71
Efficient-CoLight	1362.06	848.84	784.42	263.80
Advanced-CoLight	1320.76	802.12	819.44	210.01
DynamicLight	818.13	529.84	775.63	199.33
Our RL	692.59	565.90	692.58	195.54
LLMLight	625.61	441.02	683.22	180.94
本章方法-Llama	**527.72**	**245.96**	**655.65**	**131.09**

实验结果表明，当交通流量显著增加时，传统强化学习方法难以有效应对训练数据分布之外的复杂交通状况，其性能出现显著衰减。这种现象可能源于强化学习方法

中国知网 https://www.cnki.net

的奖励设计通常更侧重于优化排队车辆总数，但这种优化策略是以部分排队车辆较少的队列长时间堵塞为代价，从而导致系统整体的旅行时间和等待时间均被延长。而在实际交通场景中，尽量减少等待时间并提高出行效率至关重要，长时间的等待不仅会引发驾驶员的焦虑情绪，还会对交通系统的公平性造成负面影响。相比之下，本章方法在高流量场景下仍保持稳定表现，充分证明了本章方法在极端交通条件下的鲁棒性和适用性。

4.7 消融实验

4.7.1 邻居信息融合模块的影响

为了深入评估邻居信息融合模块对本章提出的强化学习算法性能的影响，本节中设计了消融实验，通过模块逐步叠加，定量分析各组件对模型性能的影响。

第一组实验移除了全部的邻居信息融合模块作为基础模型。目标交叉口和邻居交叉口编码信息直接进行拼接，不进行任何特征融合或特征交叉计算。

第二组实验在基础模型上增加了邻居关系特征融合模块。邻居交叉口编码信息通过邻居关系特征融合模块进行更丰富的语义建模，但不进行作用强度的计算。

第三组实验即完整的强化学习模型，同时整合了邻居关系特征融合模块和邻居作用强度评估模块。邻居交叉口首先与关系特征融合后，再通过邻居作用强度评估模块进行和目标交叉口的特征交叉，并计算每个邻居交叉口对目标交叉口的作用强度并进行加权融合，加权融合后的特征输入多层感知机计算最终特征表示。

本节在三组济南数据集上开展开了上述实验，通过计算每组实验模型的平均性能表现，能够有效评估每个邻居信息融合模块对模型性能的影响，具体实验结果如表 4.13 所示。

表 4.13　邻居信息融合模块对模型性能的影响

Tab. 4.13　The influence of the neighbor information fusion module on model performance

模型	ATT(s)	AQL(veh)	AWT(s)
基础模型	249.44	80.46	35.86
+ 特征融合模块	246.97	78.01	33.38
+ 特征融合模块 + 作用强度评估模块	**238.39**	**71.59**	**29.80**

实验结果表明，基础模型直接将目标交叉口与邻居交叉口信息拼接计算路网特征表示时，模型性能出现显著下降。这说明简单的信息拼接方式难以有效捕捉邻居交叉口与目标交叉口之间的空间关联，导致邻居信息利用率低下。

当仅采用邻居信息交叉模块时，模型性能较基础模型综合提高 3.65%，证明了邻

中国知网　https://www.cnki.net

居关系特征融合模块能够有效建模交叉口间的相对位置关系，提升了模型对邻居信息的理解与利用能力。

当同时集成两种邻居信息融合模块时，即本章所提出的完整模型，对比基础模型性能提高 10.78%，模型性能达到最优水平。这一结果说明邻居作用强度评估模块可以准确量化不同邻居交叉口对目标交叉口的影响权重，使模型既能充分理解邻居信息，又能动态识别关键邻居节点，从而实现对路网特征的精准建模。

4.7.2 奖励平衡系数 η 的影响

奖励函数作为智能体与环境交互的核心机制，通过提供行为反馈引导智能体学习最优策略，从而直接影响其决策过程。在交通信号控制领域，传统奖励函数通常仅计算目标交叉口的负交集队列长度，这种设计虽然能够实现局部交通流效率的优化，但可能对相邻交叉口的交通状况产生负面影响，进而降低全局交通流效率。为解决这一问题，本研究在奖励函数设计中引入了奖励平衡系数 η，用于调节目标交叉口与相邻交叉口之间的相互影响，防止模型陷入局部最优解。

表 4.14　奖励平衡系数 η 对模型性能的影响

Tab. 4.14　Effect of the reward balance coefficient η on model performance

η	ATT(s)	AQL(veh)	AWT(s)
0	243.95	75.66	34.82
0.1	240.25	73.04	31.96
0.2	**238.39**	**71.59**	**29.80**
0.3	238.54	72.93	30.13
0.5	241.02	74.94	32.97

为探究奖励平衡系数 η 对模型性能的影响，本小节进行了相关消融实验，通过对比不同 η 取值下本章所提出方法在济南数据集上的综合性能表现，揭示了该超参数选值对模型性能的具体影响情况。

表 4.14 展示了奖励平衡系数 η 在不同取值下对本章模型性能的影响。实验结果表明，当奖励平衡系数 η 为 0 时，即未考虑目标交叉口与相邻交叉口之间的相互影响时，模型容易陷入局部最优，导致性能显著下降。当奖励平衡系数 η 为 0.2 时，模型性能达到最优，表明此时目标交叉口与相邻交叉口之间的相互影响达到了相对平衡的状态，系统整体性能有所提升。然而，当奖励平衡系数 η 取值较低或较高时，模型性能均出现不同程度的下降，这可能是由于目标交叉口与相邻交叉口之间的相互影响未能得到有效平衡或出现失衡现象所致。

中国知网 https://www.cnki.net

4.7.3 两阶段训练流程有效性验证

为验证本章提出的强化学习模型辅助的两阶段训练流程的有效性，本节设计了相关消融实验。实验以杭州数据集为评估基准，以通用大参数量模型 DeepSeek-V3 作为基线模型，对比分析了四种不同训练策略下的模型性能：1）未经训练的原始基座模型 Llama3.1-8B；2）基座模型仅进行第一阶段监督微调；3）基座模型仅进行第二阶段对齐微调；4）基座模型完整进行两阶段训练。通过这种对比实验设计，能够有效评估每个训练阶段对模型性能的独立贡献及其协同效应，实验结果如表 4.15 所示。

实验结果表明，采用本章提出的两阶段微调策略后，LLM 在交通信号控制任务中的性能得到了显著提升。对比通用大参数量模型 DeepSeek-V3，未经训练的原始基座模型 Llama3.1-8B 综合性能逊色 12.34%；而仅进行第一阶段监督微调的基座模型性能综合提升了 14.74%；仅进行第二阶段对齐微调的基座模型性能综合提升了 4.48%；完整进行两阶段训练的基座模型性能综合提升了 28.87%。

分析实验结果可以发现，经过监督微调后的 Llama3.1-8B 模型在模仿 DeepSeek-V3 的推理轨迹后，展现出优于 DeepSeek-V3 的性能表现。这一发现有力证实了预训练语言模型所具备的强大固有能力与泛化性能，在引入交通领域专业知识与经过严格筛选的高质量数据后，基座模型在交通信号控制任务中取得了优于更大规模通用模型的出色表现。并且，通过对齐微调流程，能够有效的引导和修正 LLM 的推理轨迹和决策过程，使其学习优秀策略而远离劣势策略，从而在监督微调的基础上实现了显著的性能突破。

表 4.15 两阶段训练流程有效性实验

Tab. 4.15 Effectiveness experiment of the two-stage training process

方法	HZ-1			HZ-2			性能综合提升
	ATT(s)	AQL(veh)	AWT(s)	ATT(s)	AQL(veh)	AWT(s)	
DeepSeek-V3	297.49	38.71	41.13	327.29	161.08	70.14	-
Llama3.1-8B	309.66	48.46	52.33	329.16	178.94	74.27	-12.34%↓
+SFT	279.68	24.45	29.82	312.26	146.04	67.20	14.74%↑
+DPO	280.62	26.32	34.89	309.23	150.46	79.78	4.48%↑
+SFT+DPO	**275.36**	**19.20**	**22.36**	**308.92**	**139.69**	**65.88**	**28.87%↑**

本研究所提出的两阶段微调方法在所有测试数据集上均达到了 SOTA 或具有竞争力的性能水平，其效果显著超越了 DeepSeek-V3 模型。这一结果充分证明了本章方法能够有效提升 LLM 对交通信号控制任务的理解与执行能力，展现了 LLM 面向智能交通领域具有广阔的发展前景和应用潜力。

中国知网 https://www.cnki.net

4.7.4 对齐微调损失函数中 NLL 损失函数系数 λ 的影响

直接偏好优化对齐微调通过直接利用人类偏好数据来优化策略模型，其核心目标是最大化正负例样本之间的偏好差异。然而，当模型完成第一阶段监督微调后，已初步具备信号控制任务处理能力，这可能导致负例策略被选择的概率显著降低，进而使得负例样本的总概率和处于较低水平。

从数学角度分析，DPO 损失函数的导数与正负例概率成反比关系。因此，当负例概率较低时，由负例产生的导数值可能较大，这会使模型的优化目标倾向于降低拒绝样本出现的概率。而在本任务中，正负例样本在整体构造上比较相似，可能导致模型在降低拒绝样本概率的同时，也降低了选择样本的出现概率，从而使模型生成概率偏离监督数据的原始分布，最终导致模型生成内容的质量和准确性显著下降，影响整体性能表现。

为解决上述问题，本章在构建对齐微调损失函数时，在 DPO 损失函数的基础上引入了负对数似然损失函数作为正则项，旨在确保模型优化偏好差异的同时，能够在正例数据上保持正确的生成能力，从而避免模型在优化过程中偏离基本的任务目标。为探究 NLL 损失函数权重系数 λ 对模型性能的影响，本研究设计了消融实验，通过调整 λ 取值分析其作用效果，具体实验结果如表 4.16 所示。

实验结果表明，NLL 损失函数系数 λ 的取值对模型性能具有显著影响。当系数 $\lambda = 0$ 时，即不引入 NLL 正则项的情况下，模型性能相较于仅采用监督微调的方法出现了轻微退化，这一现象表明单纯的对齐微调可能产生负面效果。通过对训练过程中正负例样本奖励变化趋势的分析发现，二者奖励均呈现下降趋势，这验证了前文所述的假设，在缺乏 NLL 正则项约束的情况下，模型在降低负例样本出现概率的同时，也抑制了正例样本的出现概率，从而导致模型性能不可避免地出现退化。

表 4.16 NLL 损失函数系数 λ 对模型性能的影响

Tab. 4.16 Effect of NLL loss function coefficient λ on model performance

λ	HZ-1			HZ-2		
	ATT(s)	AQL(veh)	AWT(s)	ATT(s)	AQL(veh)	AWT(s)
0	282.58	23.12	28.35	316.87	149.10	72.53
0.1	277.06	20.94	22.80	311.65	140.18	**65.72**
0.2	**275.36**	**19.20**	**22.36**	**308.92**	**139.69**	65.88
0.5	278.57	19.74	26.98	311.25	144.69	66.35

当系数 $\lambda = 0.2$ 时，模型表现出最优性能。这一结果表明，引入适当权重的 NLL 损失作为正则项能够有效引导模型提高对正例样本的奖励与生成概率。这种平衡策略

中国知网 https://www.cnki.net

使模型在保持对正例数据学习能力的同时，也能够通过偏好对齐优化有效降低负例数据的采样概率，实现了性能的显著提升。

然而，当系数 $\lambda = 0.5$ 时，模型表现出过度拟合正例数据的倾向，导致偏好优化效果减弱。这种失衡使得模型难以有效学习选择样本与拒绝样本之间的关键差异，同时增加了对正例样本过拟合的风险，导致其无法有效降低负例样本的生成概率，最终使得模型性能下降。

本实验揭示了对齐微调中 NLL 损失函数系数取值的重要性，过低和过高的权重都可能破坏模型在偏好对齐和预期生成能力之间的平衡。

4.8 本章小结

本章针对现有交通信号控制方法存在的状态表征不足、可扩展性差以及控制不灵活等关键问题，首先提出了一种融合邻居信息的动态交通信号控制强化学习算法。该算法通过邻居掩码与动作掩码机制对齐了异构交叉口特征，通过多交叉口信息协同融合实现更精确的特征表达；将传统的固定相位时间控制拓展为相位及其持续时间的动态控制，显著提升控制灵活性；共享策略网络设计增强了模型的可扩展性。

进一步地，针对强化学习方法在实际应用中普遍存在的迁移能力弱、性能优化空间有限以及决策过程缺乏可解释性等问题，本章提出了一种基于强化学习辅助训练的动态交通信号控制大模型算法。该算法基于自然语言交互机制实现交通状态语义表征与动态调控，同时提升决策可解释性；通过利用强化学习模型辅助两阶段的训练数据收集过程，并借助强化学习模型进行偏好排序，在特定领域数据上对 LLM 进行微调，隐式引导其学习多交叉口信息协同与动态信号控制的内在逻辑，有效解决通用 LLM 在领域知识上的匮乏问题。

实验结果表明，本章提出的动态交通信号控制大模型算法在常规交通场景和极端交通条件下均表现出卓越的性能，在模型的可迁移性方面也展现出显著优势，充分证明了本章算法的有效性。

中国知网 https://www.cnki.net

5 基于大语言模型的智能体系统实现

5.1 问题背景

近年来，以 ChatGPT 为代表的大语言模型在自然语言处理领域取得了突破性进展，其卓越的常识推理和复杂规划能力为城市交通管理与控制领域带来了新的发展机遇。然而，将 LLM 直接应用于交通领域仍面临严峻挑战：首先，LLM 在处理高精度数值数据方面存在固有局限性，难以满足交通系统对数据准确性的严格要求；其次，LLM 缺乏与交通系统进行直接交互的能力，难以应对复杂的交通优化与决策问题。

相比之下，交通领域专业工具如仿真软件[57, 65–67] 与特定训练的 AI 模型[68–71] 等，已在交通数据分析、预测与优化等方面展现出优异性能。然而，这类专业工具普遍存在使用门槛高、学习成本大、输入-输出交互有限等问题，导致普通用户在应用并组合多个工具以解决复杂交通任务时面临较大困难。

上述挑战为整合大语言模型的能力与交通工具的专业特性提供了充满前景的发展机遇。随着 LLM 技术的发展，以 LLM 作为智能体核心的智能系统[72–76]，逐渐成为解决复杂任务的重要研究方向。作为具有智能的实体，智能体能够通过感知环境获取信息，并基于自主理解进行决策规划，最终凭借记忆和行动完成各类复杂任务。这一研究方向不仅为实现更通用的人工智能系统提供了重要思路，同时也为 LLM 在交通领域的应用带来了新的启发。

基于上述研究背景，本章首先构建了一个基于大语言模型的交通信号控制智能体系统。该系统以本文第四章构建的“基于强化学习辅助训练的动态交通信号控制大模型算法”为核心，结合仿真软件交互 API，构建了一个闭环的信号控制系统，从而实现交通信号控制与优化。

进一步地，本章围绕 LLM 为核心，集成多种专业工具，构建了一个面向智能交通领域的通用智能体系统，旨在拓展其在更广泛交通场景中的应用能力。该系统以 LLM 作为中央控制器，同时整合了多种交通领域专用工具，其中就包括前述交通信号控制智能体系统。通过任务分解、推理规划与工具调用，智能体能够高效处理各类复杂的交通问题，显著提升了系统在交通环境中的适应性与智能化水平。

5.2 交通信号控制智能体系统

5.2.1 系统总体框架

智能体系统旨在基于本文第四章提出的动态交通信号控制大模型，实现对交通信号的高效控制与优化，从而提升路网通行效率。整个系统框架分为后端和前端两部分，

中国知网 https://www.cnki.net

二者通过一系列 API 接口和数据处理流程协同工作，系统结构详见图 5.1。

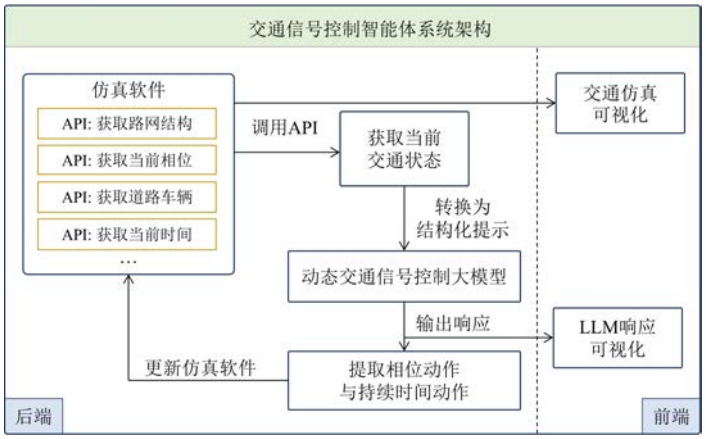


图 5.1　交通信号控制智能体系统框架

Fig. 5.1　System framework of the traffic signal control agent

在后端部分，首先是仿真软件模块，其提供了多种 API 接口，用于获取路网结构、当前相位、道路车辆以及当前时间等关键信息。这些接口是感知外部交通环境的重要途径，确保系统能够实时掌握交通运行状态。当需要进行信号控制时，系统会调用相关接口来获取当前交通状态，并将原始数据转换为结构化提示，以便于后续分析和处理。随后，这些包含交通状态信息的结构化提示将输入至动态交通信号控制大模型中。该模型是系统的核心组件，经过在特定领域数据上的微调训练，具备对交通数据进行深度分析与推理的能力，从而生成最优的交通信号控制策略。模型输出的响应包括具体的相位动作和持续时间动作，即具体的信号灯调整指令及执行时长，指导信号控制系统实现交通流的管理与优化，并附带相应的决策解释。

在前端部分，主要包括两个可视化模块。首先是交通仿真可视化模块，负责将从后端获取的交通状态信息以动画的形式直观展示，帮助用户实时了解当前道路运行状况。其次是 LLM 响应可视化模块，用于展示动态交通信号控制大模型的输出结果，使用户能够清晰地看到系统推荐的信号控制策略及其背后的合理解释，增强决策的透明性与可信度。

通过前后端的紧密协作，智能体系统实现了从数据采集、智能分析到控制决策与可视化的全流程闭环管理，为现代城市交通信号控制提供了高效、智能的解决方案。

5.2.2　系统前后端搭建

系统采用了前后端分离的架构设计，以实现高效的数据处理与用户交互。后端基于 Python 语言的 Flask 框架构建，主要负责获取每一时间步的交通模拟器状态和大模型的决策响应数据，并通过 API 接口与前端进行数据交互，其中交通模拟器支持 SUMO 与 CityFlow。前端则采用 Bootstrap 开源框架搭建，利用其响应式设计特性快

中国知网　https://www.cnki.net

速构建可视化界面，并通过 JavaScript 实现与后端的实时通信和数据渲染。

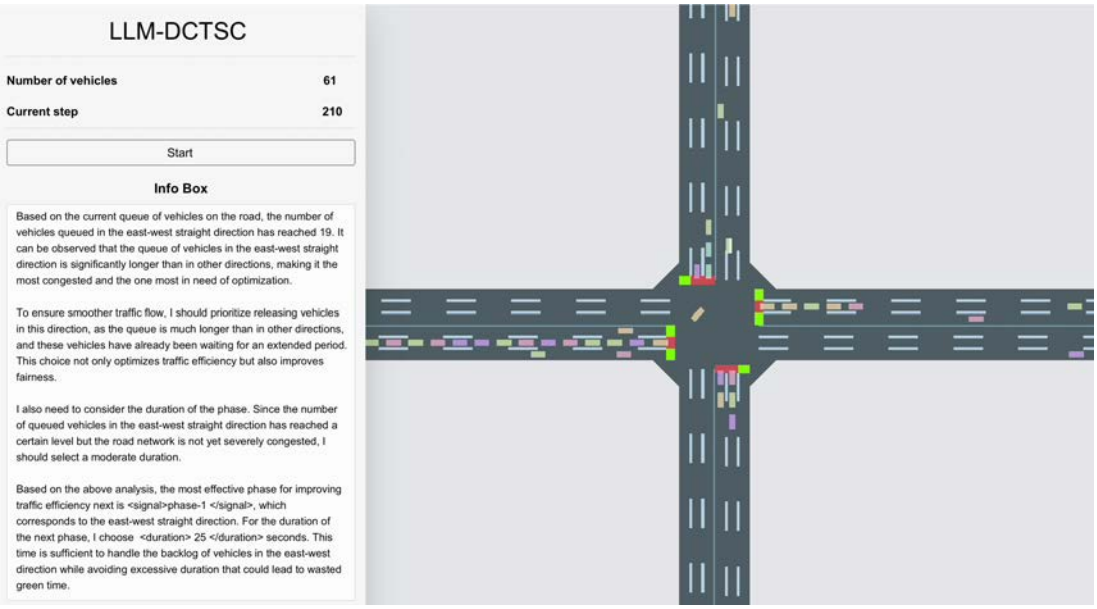


图 5.2　基于大语言模型的交通信号控制智能体系统可视化

Fig. 5.2　Visualization of traffic signal control agent system based on LLM

如图 5.2所示，系统前端界面采用了左右分栏式布局，直观呈现交通信号控制的实时仿真与决策过程。右侧区域为交通仿真可视化模块，动态展示路口信号灯状态、车辆排队情况以及行驶轨迹等关键路况信息。左侧区域分为上下两个模块：上方显示本研究算法的英文全称（LLM for Dynamic and Coordinated Traffic Signal Control，简称 LLM-DCTSC），并实时更新当前仿真时间步和道路车辆总数；下方则展示大语言模型的决策过程，包括对当前交通状况的分析评估，以及针对下一时间步所生成的相位切换决策与相位持续时间选择。

5.3　智能交通智能体系统

5.3.1　系统总体框架

本研究提出的面向智能交通领域的智能体系统框架如图 5.3 所示，其主要由交互主体、多源数据和工具模块三个核心组件构成。下面将详细介绍框架每一部分部分的组成与原理。

交互主体模块是系统的核心功能单元，位于框架左侧，由用户界面、主智能体和摘要智能体三部分组成。用户界面负责接收用户查询（Query）作为系统输入。主智能体作为中央控制单元，将对用户查询进行解析，根据解析结果进行任务规划与分解，随后调用相关工具和子智能体完成各项子任务，并接收子任务执行完毕后的反馈信息，最后对任务完成情况进行评估与反思，这一过程将循环往复，直至主智能体确

中国知网　https://www.cnki.net

认所有任务均已完成。各项任务执行前后的关键信息均将存储至记忆管理区。

当主智能体确认所有子任务均已完成时，系统将调用摘要智能体。摘要智能体负责整合记忆管理区中的用户查询、交互记录、推理过程和工具反馈等关键信息，并对这些信息进行分析与归纳，最终生成完整的响应内容，并返回至用户界面呈现给用户。



图 5.3　智能体总体框架图

Fig. 5.3　Holistic framework diagram of agent

多源数据模块位于系统框架右下方，主要负责根据不同工具的需求提供多样化的数据支持。例如为仿真软件工具提供路网文件和行车记录；为信号控制智能体提供目标交叉口道路状况数据；为数据分析与可视化工具提供车流分布信息等，同时也可以将工具模块更新后的相关数据进行保存。通过这种针对性的数据交换机制，多源数据模块有效确保了工具模块的顺畅运行。

工具模块位于系统框架右上方，是系统处理专业交通任务的核心组件。主智能体可以根据任务需求调用其中的工具进行专业任务处理，并将任务输出与执行结果等信息反馈给主智能体。通过这种协同工作机制，不仅实现了对交通任务的高效精准处理，还有效规避了大语言模型直接处理复杂交通任务可能面临的困难。

5.3.2　智能体工作流程

在智能交通智能体系统中，主智能体作为整个系统的控制核心，采用 Qwen2.5-7B 作为基座模型，并进行了专门的监督微调，以提升 LLM 对任务分解与工具调用能力。依托于 LLM 强大的语义理解与推理能力，主智能体承担了用户查询理解、任务规划、工具调用、逻辑推理以及评估反思等关键功能，确保整个系统的高效稳定运行。主智能体具体工作流程如图 5.4 所示。

工作流的第一步是自然语言输入，用户在前端界面输入任务需求，随后传递至下游的提示管理模块进行结构化处理。

中国知网　https://www.cnki.net

第二步是提示管理，其核心作用是为 LLM 智能体制定明确的操作规范。提示管理主要涵盖用户任务请求、系统前缀、可用工具、推理历史和对话历史等关键要素，共同为智能体提供了执行任务所需的完整上下文和指导信息，有效支持了任务的规划与执行过程。

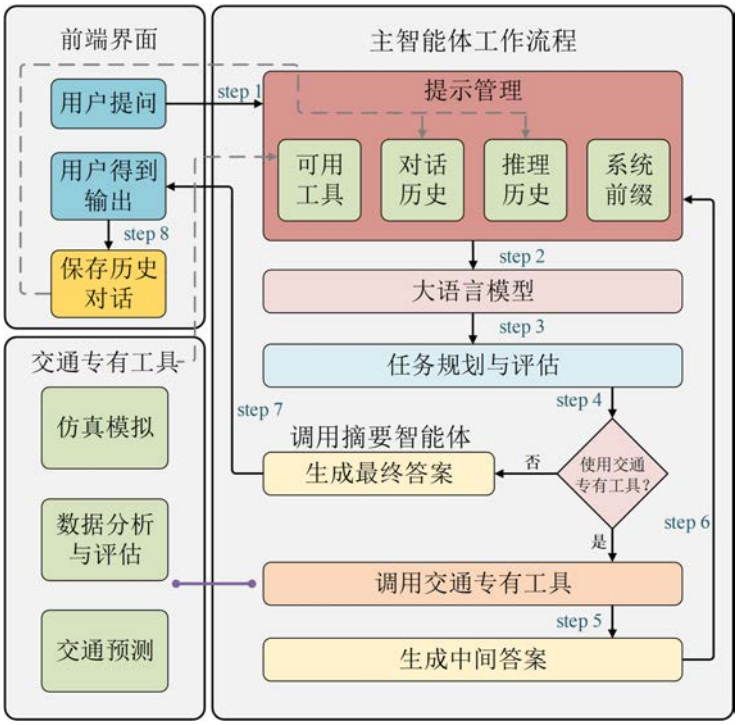


图 5.4　基于大语言模型的智能交通智能体工作流程图

Fig. 5.4　LLM-based intelligent traffic agent workflow diagram

第三步是任务规划，为充分发挥 LLM 卓越的认知能力，采用思维链方法逐步规划与设计任务解决方案。智能体首先解析用户输入的任务需求，随后综合考虑可用工具特性与历史交互数据，最终生成逻辑严谨且高度可行的任务分步执行方案。

第四步是工具调用，智能体将根据前一步推理思维链确定所需调用的工具或子智能体，并依据工具定义中的先决条件制定参数。这些工具分别负责执行交通模拟仿真、数据库检索增强生成、交通信号控制优化、数据可视化与分析等不同任务，工具的输出结果将反馈给智能体进行后续处理。

工具调用在本质上是基于提示工程对 LLM 生成过程与格式进行精确控制而实现的。为此，本研究精心设计了主智能体提示模板来实现推理思考与工具调用，模板具体内容如图 5.5 所示。该提示模板不仅明确定义了各阶段生成任务的具体内容要求，还严格规范了具体的输出格式标准，为后续的提取与处理流程提供了便利。

第五步是工具输出与中间应答，当工具执行完毕后，智能体将接收并处理工具反馈的输出结果作为中间答案，并将其转化为自然语言形式存储至记忆管理区，为后续的任务规划提供参考。在存在多模态输出的场景中，对于表格等结构化数据将以

中国知网　https://www.cnki.net

Markdown 格式呈现，而对于可视化图像或特定类型文件等非文本内容则通过文件路径的形式加以引用。

```
PREFIX = """
[!Role Play!]
You are a transportation domain expert, skilled in addressing users' professional transportation-related queries. You can utilize specialized transportation tools to perform tasks such as traffic simulation control, professional knowledge Q&A, signal timing optimization, transportation decision-making, and providing traffic analysis reports.
[!Action Constraints!]
1. You must first determine whether the user's question is a professional traffic issue or a general one. If it is a general question, directly call the summary agent without additional analysis; otherwise, analyze the question and plan the tools required.
2. When the question involves traffic tasks, you should attempt to answer it by calling the appropriate tools. You can use the following tools:
{tool_list}
3. You must accurately remember the user's question. Your sole purpose is to complete the task explicitly stated in the user's message.
4. Whenever you prepare to think, first review the user's question to confirm whether you have sufficient information to provide a final answer. If so, you should not infer or fabricate additional requirements or questions based on your own assumptions.
5. Remember the tools already used and avoid repeating the same tool. Strive to use the minimum number of tools necessary.
6. If no suitable tool is found to complete the task, the issue may be too vague, requiring you to rethink and deduce the necessary tools; alternatively, the task may not require further tools, in which case you should directly call the summary agent.
7. When encountering tabular content in observation results, ensure the table is output in Markdown format in the final answer.
8. If you find that existing tools cannot solve the current problem, generate a thought requesting more information from the user, then call the summary agent.
[!Prohibitions!]
Do not fabricate tool names!
Do not falsify input parameters when calling tools!
"""
```

(a) 前缀提示模板

```
FORMAT_INSTRUCTIONS = """
[!Format Instructions!]
Strictly adhere to the following format:
<Q>Question</Q>: The input question to be answered
<T>Thought</T>: Analyze the current question and consider the next steps
<A>Action</A>: The action to be executed, which must be one of {tool_names}
<I>Input</I>: The input passed to the tool
<O>Observation</O>: The execution result returned by the tool
... (The sequence of Thought/Action/Input/Observation may repeat multiple times)
<T>Thought</T>: I have resolved the problem and reached the final conclusion
<Final>Summary Agent</Final>: I have completed the task and now need to call the summary agent to summarize the task

Note! If the question does not require calling any tools, directly output
<Final>Summary Agent</Final>.
"""
SUFFIX = """
Now, the task begins!

{chat_history}
<Question>{user_input}<\Question>
{agent_scratchpad}
"""
```

(b) 格式规范与后缀提示模板

图 5.5　主智能体提示模板

Fig. 5.5　Main agent prompt template

第六步是任务评估，智能体会对用户原始请求与当前中间应答进行比对分析，以评估任务完成度。若判定任务尚未完成，则返回至第二步到第五步继续迭代，直至任务得到完整解决。

第七步是最终答案生成，经过上一步的任务评估，当主智能体确认任务已完整解决后，将调用摘要智能体整合记忆管理区中的关键信息，包括用户原始查询、工具调用记录与反馈数据、主智能体推理路径等核心内容。这些信息经过深度整合与凝练后，形成最终响应并通过前端交互界面准确返回给用户。

中国知网　https://www.cnki.net

第八步是对话历史存储，通过存储用户输入和大语言模型输出，构建了完整的对话历史记录。经过结构化处理后，这些历史数据将被整合到提示管理模块中，在后续交互过程中为智能体提供连续的会话上下文，从而使智能体具有了记忆能力。

5.3.3 工具模块

工具模块主要包括面向各类交通复杂任务的函数、软件、模型及子智能体等组件。每项工具都有明确的功能定位，专注于解决特定类型的任务。在系统运行过程中，主智能体负责统筹规划，根据任务需求调用相应的工具，并将工具执行结果进行整合和处理。

为确保主智能体能够准确识别并高效调用各项工具，需对每项工具关键信息进行规范设计，包括其名称、功能、输入和输出等内容。名称是工具调用的入口，只有当主智能体生成内容准确匹配工具名称时，才会触发对应的调用流程。功能描述用于阐明工具的具体用途与适用场景，帮助主智能体理解其作用。输入定义了工具接受的输入参数及格式要求，输出定义了工具执行完毕后将返回的结果形式。

在工具模块中，信号控制智能体负责交通信号控制与优化任务，相关内容已在前文第 5.2 节中详述。除信号控制智能体外，本研究框架中所涵盖的其它主要工具，以及其功能与具体实现如下：

（1）仿真软件工具

仿真软件工具负责执行交通仿真任务，输入为需要执行仿真的路网与车流文件数据，以及指定的时间步长，输出为仿真任务的执行结果或生成的文件。

本研究采用 SUMO[65] 和 CityFlow[57] 两款主流交通仿真软件作为该部分工具。SUMO 是当前最知名与流行的开源微观交通仿真软件，其具有以下特点，采用连续仿真模式，能够处理大规模路网；支持包含行人在内的联合仿真；提供丰富的场景构建功能。SUMO 适合需要精细建模、复杂场景还原以及多方交通要素联动的仿真需求。CityFlow 则是专为大规模城市交通场景设计的微观仿真软件，其具有以下特点，采用精心优化的数据结构和多线程仿真算法，具有卓越的运算效率；支持灵活的道路网络和交通流定义；能够以车辆为单位进行精细行为模拟。相较于 SUMO，CityFlow 在保持高细节度的同时具有更快的仿真速度，更适合需要快速实现的轻量级仿真任务。

以上两款仿真软件均提供了友好的 Python API 接口，便于将仿真功能封装为智能体可调用的工具，可以满足用户从高精度复杂场景到大规模快速仿真的多样化需求，减轻用户对仿真软件的学习成本，采用自然语言便可以轻松完成指定任务。

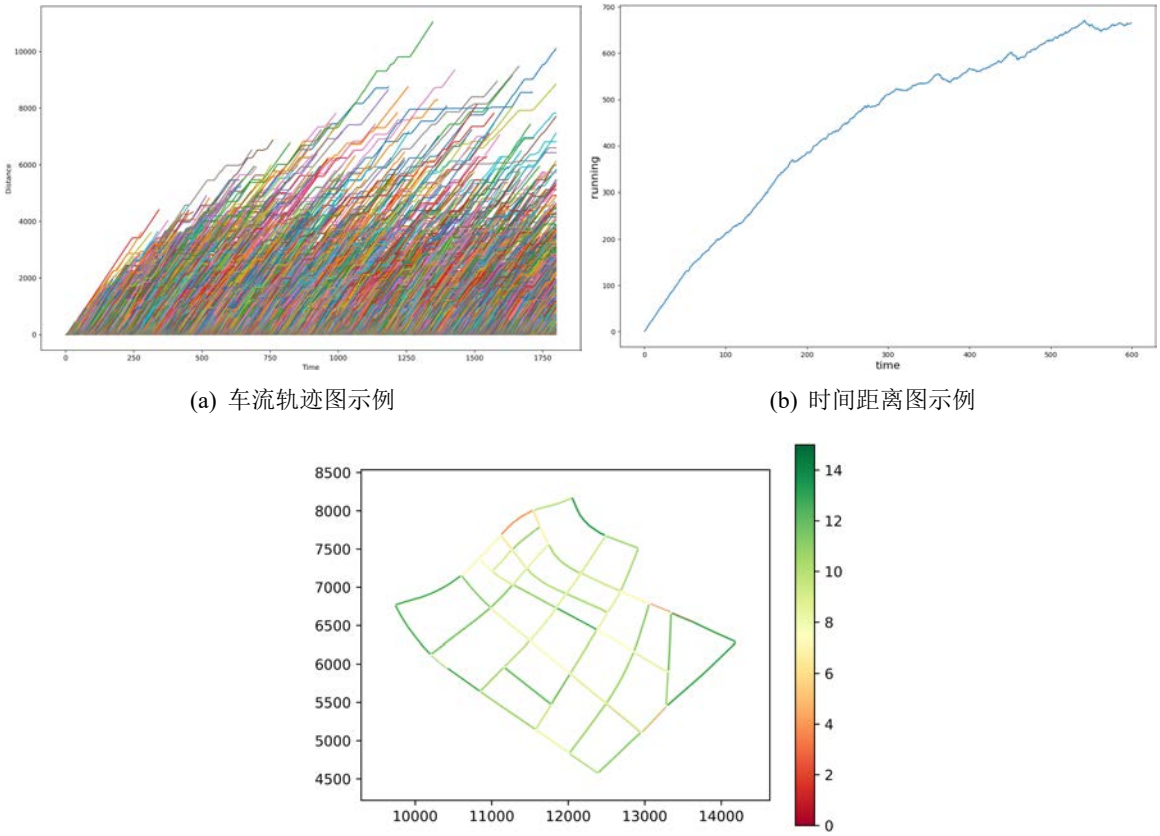
（2）数据分析与可视化工具

数据分析与可视化工具负责交通流信息的处理与呈现，输入为采集的交通流数据或仿真软件的模拟结果，输出为结构化分析结果或可视化图表。

以交通仿真软件的模拟结果分析为例。在数据分析方面，可计算系统整体的平均

中国知网 https://www.cnki.net

旅行时间、平均排队长度、平均等待时间等关键性能指标，并深入分析这些指标的统计特征与分布规律；在可视化呈现方面，可通过绘制车流轨迹图、流量热力图、时间距离图以及道路速度图等多种可视化图表，直观展示交通流的时空分布特征与运行状态，可视化示例如图 5.6 所示。通过数据分析与可视化相结合的方式，能够全面评估交通系统的运行效率和服务水平。



(a) 车流轨迹图示例　　(b) 时间距离图示例

(c) 道路速度图示例

图 5.6　可视化示例

Fig. 5.6　Visualization examples

（3）交通问答智能体

交通问答智能体负责交通专业领域知识问答，输入为自然语言形式的交通专业问题，输出为对这一问题的回复。

交通问答智能体通过构建检索增强生成（Retrieval-augmented Generation，RAG）系统来实现。基座模型同样选用 Qwen2.5-7B，通过 RAG 系统检索外部知识库提升了针对交通专业问题响应的准确性和时效性，同时可以大幅减轻 LLM 的幻觉问题，图 5.7 展示了本研究所设计的交通问答智能体工作流程图。

本研究采用 Neo4j[77] 图数据库存储交通专业知识作为知识库。相较于传统的表结构数据库，Neo4j 的核心优势在于：采用图结构存储数据，能够直观地呈现复杂关系

中国知网　https://www.cnki.net

网络，其中节点表示实体，边表示实体间的关系；支持为节点和边添加键值对属性，提供了更灵活的数据建模能力；能够同时存储文本信息及其向量嵌入，为引入多链路检索提供便利。

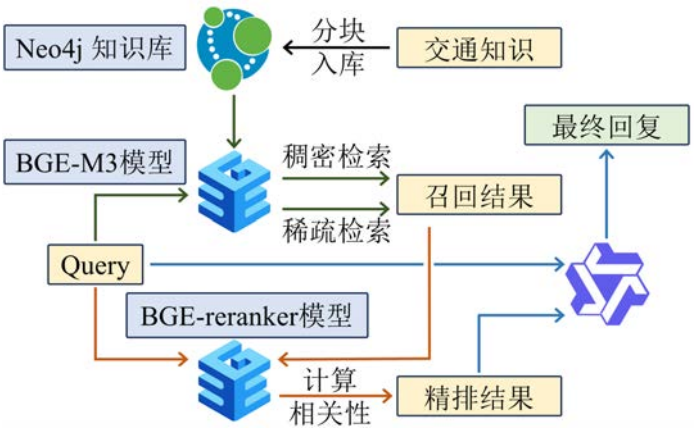


图 5.7　交通问答智能体工作流程图

Fig. 5.7　Traffic question-answering agent workflow diagram

在知识库构建过程中，本研究选用 TransGPT 数据集[78] 作为基础数据源。该数据集涵盖交通领域研究报告、专利标准、政府公开数据、科研文献、行业统计数据、基建资料、智库报告、专业术语以及工程建设知识等多维度的专业信息。在数据处理环节，以数据集中每条数据的标题作为主节点，对于缺失标题的数据，则采用 DeepSeek-V3 模型对正文内容进行理解并生成标题。数据正文内容将进行分块（Chunk）处理，设置分块大小为 512 个 token，重叠（Overlap）区域为 50 个 token，并将这些分块作为子节点关联到相应主节点下。这种处理方式在保证信息完整性的同时，有效避免了信息割裂问题。经过上述处理，最终构建的知识库共收录约 3.6 万条高质量的专业交通数据，确保了知识库内容的全面性和权威性，为智能体提供了坚实的领域知识支撑。

在检索过程中，本研究采用两阶段检索策略以确保知识库的高效召回和精准匹配。在召回（Recall）阶段，采用双路混合检索机制，一路是基于语义向量的密集检索，利用神经网络嵌入模型捕捉用户查询的深层语义特征，并在知识库中匹配语义相近的内容；另一路是基于关键词的稀疏检索，通过匹配专业术语和实体名称，保证关键信息的准确命中。为提高信息质量，在召回阶段后进行一轮精排（Fine Ranking），采用相关性评分模型对召回结果进行排序，筛选出与用户查询最相关的前三条知识。最终，LLM 综合用户查询和精排后的专业知识，生成兼具准确性和专业性的回答。

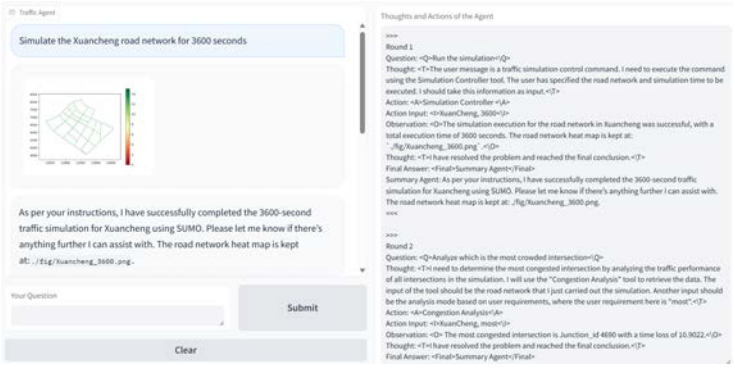
在本研究中，采用 BGE-M3[79] 模型作为召回阶段检索器，该模型的优势在于同时支持密集检索和稀疏检索，能够兼顾语义相似性和关键词匹配度，从而全面召回与用户查询相关的内容。在精排阶段，采用 BGE-reranker-base[80] 模型对召回结果进行重排序，将用户查询与每个召回结果成对输入模型，计算二者的相关性得分，最终选

中国知网　https://www.cnki.net

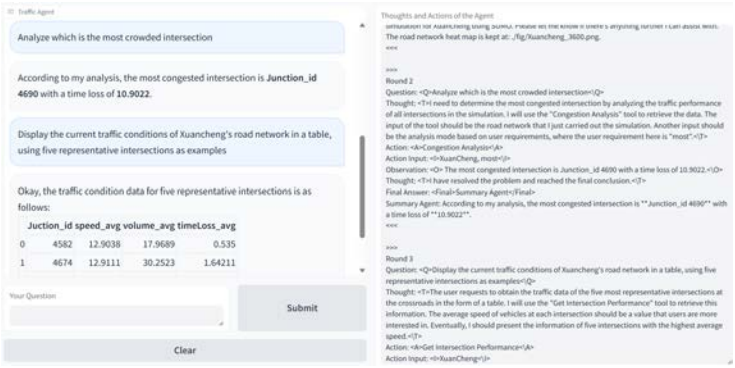
取得分最高的前三个结果作为精排输出，为 LLM 生成回答提供高质量的参考依据。

5.3.4 系统前后端搭建

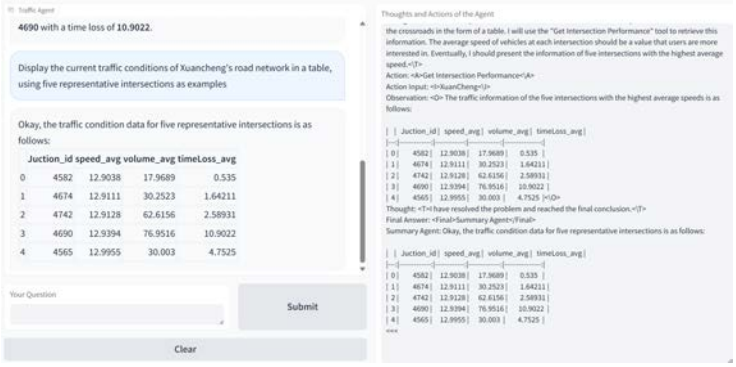
本文提出的智能交通智能体系统基于 LangChain 框架实现。作为当前大语言模型应用开发中最受欢迎的框架之一，LangChain 旨在简化由大型语言模型驱动的应用程序开发过程，提供便捷的工具管理能力，能够有效协调语言模型与其他工具的交互，同时采用模块化设计理念，具备强大的资源整合能力，可以无缝集成各类外部资源。



(a) 执行仿真示例



(b) 数据分析示例



(c) 数据可视化示例

图 5.8 智能交通智能体系统前端交互界面展示

Fig. 5.8 Front-end interactive interface display of intelligent traffic agent system

中国知网 https://www.cnki.net

前端交互界面基于 Gradio[81] 框架实现。Gradio 是一个开源的 Python 前端框架，专为机器学习应用场景优化，能够将复杂的机器学习模型、Python 函数或数据处理流程快速转化为交互式 Web 界面，使开发者无需具备专业的前端开发经验即可构建功能完善的 Web 应用。

本研究所设计的智能交通智能体系统前端交互界面主要包含三个功能区域，实现了用户与智能体的完整交互闭环，具体示例如图 5.8 所示。其中，左侧区域为用户与智能体的交互区，分为上下两部分。左上部分为用户与智能体的对话历史展示区，实时展示用户的查询请求和智能体的响应内容；左下部分为查询输入区，包括文本输入框、查询提交按钮以及对话历史清空功能按钮。右侧区域为智能体思维过程可视化区，完整呈现智能体的任务处理流程。该区域动态展示智能体从接收用户查询开始的完整推理过程，包括查询输入、问题理解与思考、工具选择决策、输入参数生成、执行结果获取与分析等关键环节，并在任务完成后调用摘要智能体生成总结，最终将输出结果反馈至用户交互区。

5.4 实验与分析

相比于 DeepSeek-V3 和 GPT-4 等大规模模型，本地部署的小参数量模型在指令遵循与理解能力方面通常表现较弱。因此，为了提升本地模型的推理能力和工具调用能力，有必要进行针对性的训练。本节将设计包括数据收集、训练和测试在内的完整流程，用于评估本章提出的智能交通智能体在各类交通任务中的表现。

5.4.1 训练数据集收集

为此，本研究设计了一个两阶段的数据集构建方法：首先，将任务背景和可用工具信息输入 DeepSeek-V3，要求其围绕这些信息生成相关问题列表；然后，将这些问题作为用户查询，并按照图 5.5 所示的提示模板构造完整提示，再通过 DeepSeek-V3 生成对应的思考推理和工具调用过程。最终，经过人工和模型校验后的生成数据可作为训练数据使用。

经过上述数据收集和过滤流程，最终获得约 800 条高质量的思考推理与工具调用专项数据集。为进一步提升模型的逻辑推理能力，同时保持其通用性能不退化，本研究还从 GSM8K[82] 开源数据集中随机选取了 1000 条思维链推理数据，并与工具调用数据打乱混合，最终构建了一个包含约 1800 条样本的监督微调数据集用于后续训练。

5.4.2 实验设置与准备

本研究实验环境搭建于高性能计算服务器，硬件配置包括 2 块 NVIDIA A100 80GB GPU 与 Intel Xeon Gold 6248 CPU，操作系统为 Ubuntu22.04，软件环境采用 Python 3.10 编程语言，并基于 PyTorch 2.4.0 深度学习框架进行模型训练与测试。

中国知网 https://www.cnki.net

在监督微调训练过程中，主智能体选取 Qwen2.5-7B 作为基座模型，并采用 LoRA 方法进行参数更新，选取模型 Transformer 层中的所有线性层参与训练，其中低秩分解矩阵的秩设置为 8，缩放因子 α 设置为 16，批次大小设置为 8。在优化策略方面，采用 AdamW 优化器进行参数优化，目标学习率设置为 1×10^{-5}，并采用包含 10% 训练步数的线性学习率预热，以及通过余弦退火调度算法动态调整学习率。

考虑到主智能体需要掌握特殊格式遵循能力，并且专项数据集与通用数据存在显著分布偏差，因此采用两阶段训练方案：第一阶段聚焦于思考推理和工具调用专项数据集，通过单轮次训练重点强化模型对特殊格式指令的理解与生成能力；第二阶段采用混合数据集训练，通过单轮次微调着重提升模型的逻辑推理性能。

在实验对比方面，本研究选取了三组模型进行对比分析：1）经过相同微调流程的 Llama3.1-8B 模型；2）未经微调的 Qwen2.5-7B 和 Llama3.1-8B 原始模型；3）性能优异的 DeepSeek-V3 模型。在评估阶段，将上述模型分别作为主智能体控制核心，测试模型在由易至难的不同任务上的表现，重点考察其指令遵循能力以及工具调用的正确性，即是否能准确理解用户意图并选择合适的工具。通过系统性地比较各模型在不同复杂度交通任务中的表现，全面评估本文提出的智能体系统在处理专业交通任务方面的优势。

5.4.3 任务执行能力实验

在任务执行能力实验中，本研究从通用问答、明确任务、模糊任务三个维度构建测试任务，以系统评估模型表现。通用问答测试分为基础问答和交通专业问答两类，基础问答不涉及交通知识与任务，无需调用工具；交通专业问答则仅需调用交通问答智能体。这一测试任务重点评估模型能否区分无需调用工具的普通查询以及能否准确识别交通领域查询，同时避免因工具误调用而影响回答质量。

在明确任务测试中，查询指令显式的包含了需要调用的工具，例如“执行一次交通仿真”、“优化某个路口的信号控制方案”等。这类任务直接指明了智能体所需调用的工具，任务难度相对较低，主要评估模型能否准确识别任务需求，以正确调用工具并避免调用无关工具。

相比之下，模糊任务测试则更具挑战性。这类任务要求智能体准确解析查询的隐含需求，并通过逻辑推理来规划工具调用序列。以“生成某城市道路网络交通报告”为例，这一查询没有显示指明所需工具，智能体必须推测完整的任务执行流程，包括首先需要提取路网信息或执行交通仿真来获取基础数据，随后通过多次不同维度的数据分析与可视化来获取交通指标，最终整合各环节输出并调用摘要生成工具形成综合性报告。这类测试任务重点评估智能体的任务解构能力、工具编排能力以及多步执行协调能力，充分检验智能体在复杂场景下的综合性能。

本研究通过模型生成与人工标注相结合的方式构建了多维度测试数据集，包括

中国知网 https://www.cnki.net

230 条通用问答测试数据、65 条明确任务测试数据和 35 条模糊任务测试数据，用于对不同 LLM 驱动的智能体系统进行综合对比评估。测试具体评估了不同 LLM 驱动的智能体在不同提示样本场景与是否经过特定微调训练条件下的通用问答、明确任务和模糊任务三类测试中的成功率，测试结果如表 5.1。从表 5.1 中不同 LLM 智能体系统任务成功率对比可以发现，在零样本（Zero-shot）提示场景下，未经特定微调训练的模型整体表现欠佳，尤其是在处理模糊任务时问题更为突出。由于缺乏相关先验知识和案例参考，模型往往容易产生理解偏差，从而难以准确分解和规划任务，最终导致工具调用方案错误。此外，由于模糊任务通常需要多轮执行，模型在后续轮次中容易出现指令跟随错误，生成错误的格式最终导致系统崩溃。

在少样本（Few-shot）提示场景下，通过提示词为模型提供了复杂任务的推理轨迹、标准的生成格式以及工具调用示例，使得未经特定微调训练的模型性能得到明显改善。在具体的测试数据表现上，模型指令遵循错误大幅减少，格式生成准确性显著提升。然而，在模糊任务上的表现仍存在较大提升空间，表明仅依靠提示工程难以完全解决复杂任务的处理问题，需要进一步探索更有效的优化方法。

表 5.1　不同 LLM 智能体系统任务成功率对比

Tab. 5.1　Comparison of task success rates among different LLM agent systems

基座模型	提示样本	通用问答	明确任务	模糊任务
Llama3.1-8B	Zero-shot	79.57%	73.85%	34.29%
	Few-shot	93.48%	86.15%	71.43%
Qwen2.5-7B	Zero-shot	83.48%	87.69%	42.86%
	Few-shot	92.17%	92.31%	74.29%
DeepSeek-V3	Zero-shot	95.22%	93.85%	45.71%
	Few-shot	96.52%	98.46%	82.86%
Llama3.1-8B+SFT	Zero-shot	97.83%	98.46%	94.29%
Qwen2.5-7B+SFT	Zero-shot	98.70%	100.00%	97.14%

经过特定微调训练的模型展现出卓越的性能表现，这主要得益于训练数据中隐含的正确生成格式与思维链信息，使得模型无需额外提示样本也可出色完成任务。在通用问答任务处理方面，模型对于专业知识问答任务，能够完全正确地进行工具调用；而对于简单问答任务，存在的少量错误集中在对交通问答智能体调用判定的模糊性上，即仅涉及是否调用工具的决策层面，对最终输出几乎不造成影响。

在明确与模糊任务处理方面，经过微调的模型能够从训练数据中习得复杂任务的推理模式。当遇到类似问题时，模型能够进行有效的推理与思考，并按照合理的顺序

中国知网　https://www.cnki.net

调用工具，从而基本解决此类任务。其中，经过微调的 Qwen2.5-7B 表现尤为突出，在明确任务中取得了 100% 的任务成功率，证明模型能够很好地处理简单明确的交通专业任务。在模糊任务中，模型同样展现出较强的适应能力，仅当面对表述过于简略且高度开放的非常规任务时，才可能出现偶发性的工具调用偏差。

此外，本研究还考察了智能体在所有任务中的指令遵循与工具输入格式生成准确率，重点验证智能体生成格式的准确性，测试结果如图 5.9 所示。从图 5.9 中不同 LLM 智能体系统生成格式准确率对比可以发现，通过提供少量样本示例，模型能够提升指令遵循能力，生成更符合要求的输出格式，而经过特定微调训练的模型表现更加优秀，在格式生成测试上实现了百分百的准确率。

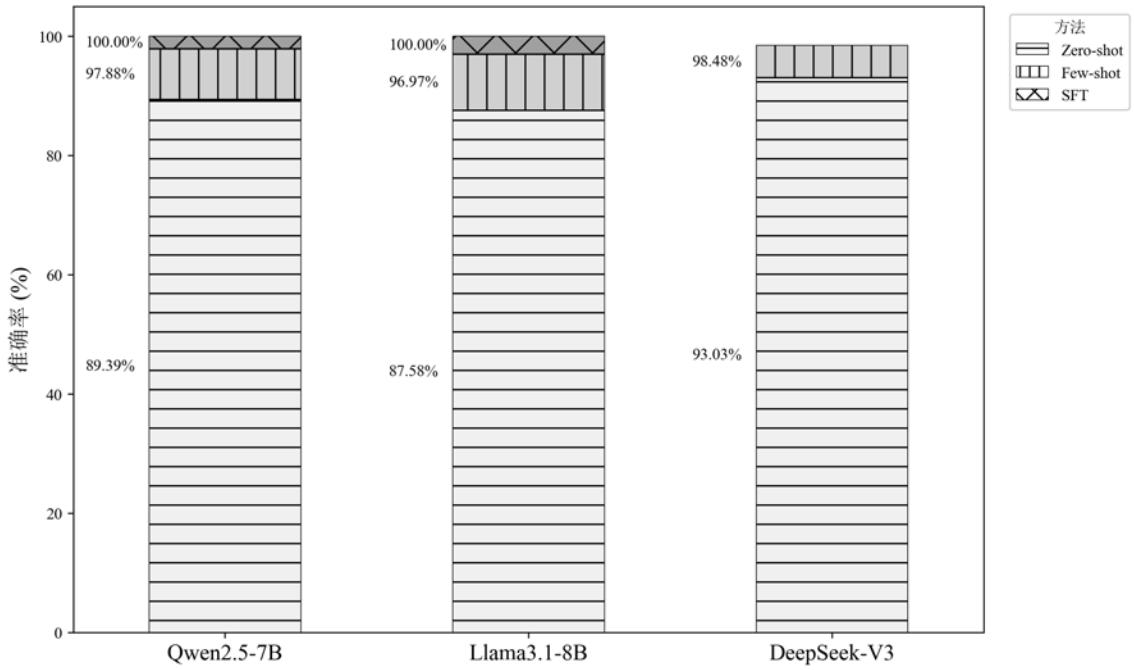


图 5.9　不同 LLM 智能体系统生成格式准确率

Fig. 5.9　Accuracy of different LLM agent systems in generating correct formats

实验结果表明，通过合理的提示工程和针对性微调能够显著提升模型在格式生成方面的准确性，有效解决了模型在指令遵循和格式规范方面的问题。并且，本研究提出的 LLM 驱动智能体系统经过针对性训练后，能够有效处理包括通用问答、明确任务和模糊任务在内的多维度任务需求，在逻辑推理与专业任务处理上均展现出优异的性能，为城市智能交通控制领域提供了全新的技术解决方案。

5.5　本章小结

本章围绕大语言模型在智能交通领域的应用展开深入研究，构建了具备任务执行与决策能力的智能体系统，主要研究成果可概括为以下两方面：

中国知网　https://www.cnki.net

首先，以本文第四章提出的动态交通信号控制大模型为核心，构建了一个闭环的交通信号控制智能体系统。该系统通过集成交通仿真软件 API 接口，实现了交通状态感知、LLM 智能决策、信号控制指令执行以及交通状态更新的完整闭环控制流程。同时，本章还开发了集成交通状态监测与决策过程可视化的前端交互界面，为城市交通信号控制提供了智能化解决方案。

在此基础上，本章进一步提出了一个面向智能交通领域的通用智能体系统框架。该系统以 LLM 作为核心控制器，整合了交通仿真、数据分析与可视化、信号控制智能体以及专业问答智能体等工具模块，并设计了针对性的训练流程，充分发挥 LLM 在任务分解、推理规划与工具调用方面的优势。实验结果表明，经过训练的智能体系统在指令遵循、格式生成与多步任务处理等方面均表现优异。通过搭建智能体前后端系统并进行多场景案例验证，充分证明了系统在交通仿真执行、多维度数据分析与可视化生成等场景中的实用价值。

中国知网 https://www.cnki.net

6 结论与展望

6.1 结论

随着城市交通拥堵问题日益严峻，如何优化信号相位与配时的交通信号控制策略，以提升城市交通流的运行效率，已成为当前智能交通领域的重要研究方向。本文围绕城市交通信号控制展开深入研究，具体工作总结如下：

（1）本文对交通信号控制进行系统建模，构建了交通路网、交叉口及道路的结构模型，设计了排队车辆与车道分段结合的状态表示，提升对交通环境的刻画能力。随后，将信号相位集合映射为互不冲突的交通流组合，并对相位持续时间进行离散化处理，将原本连续的动作空间转化为离散动作空间，有效缩小问题求解的搜索空间，为实现动态信号控制奠定基础。最后，将交通信号控制问题形式化为动态决策优化问题，提出以最小化车辆平均旅行时间为目标的优化函数，为后续研究提供理论基础。

（2）本文在对交通信号控制的系统建模与问题定义基础上，提出了一种基于强化学习辅助训练的动态交通信号控制大模型方法。首先设计了一种改进的动态控制强化学习算法，提出注意力机制驱动的邻居信息融合模块，以实现多交叉口信息的协同融合，提升交叉口状态表征能力；并提出动态相位调控机制，实现了相位与持续时间的联合优化，提高信号控制的灵活性。随后设计了强化学习辅助的两阶段微调训练框架，以上述强化学习算法指导 LLM 的训练全过程，解决了通用 LLM 领域知识匮乏难以直接应用于信号控制的问题，使 LLM 理解多交叉口信息协同与动态信号控制的内在逻辑，最终获得性能优越的动态交通信号控制大模型。实验结果表明，经过训练的信号控制大模型在真实世界交通数据集的测试中表现优异，与主流强化学习方法相比，本文方法实现了 6.84%-50.53% 的综合性能提升；与同为大模型方法的 LLMLight 相比，本文方法取得了 11.59% 的综合性能提升，充分证明了本文大模型方法的有效性。在可迁移性实验与极端高流量实验中，本文方法性能更是大幅度领先于所有其它方法，充分证明了本文大模型方法具有良好的扩展性和泛化能力。

（3）本文在所提出的交通信号控制大模型方法基础上，构建了一个包括交通状态感知、信号控制决策和交通状态更新在内的闭环交通信号控制智能体系统，能够直观呈现 LLM 的决策过程并动态展示交通状况的演变情况。进一步地，为探索 LLM 在交通领域的广泛应用潜力，本文设计了一个面向智能交通领域的通用智能体系统。该系统集成了前述交通信号控制智能体在内的多种交通专业工具，实现对复杂交通任务的有效处理，充分展示了 LLM 在城市交通智能控制领域的广阔应用前景。实验结果表明，本文设计的智能体系统在经过特定任务规划与工具调用的训练后，在模糊任务测试中达到了 97.14% 的任务成功率，充分验证了所提出系统的有效性与实用性。

中国知网 https://www.cnki.net

6.2 创新点

本研究的创新点总结为以下三方面：

（1）本文针对交通信号控制现有强化学习方法在状态特征表达不充分、控制粒度较粗糙等问题，提出了一种融合邻居信息的动态交通信号控制强化学习算法，设计了邻居信息融合模块，实现更精细的多交叉口协同观测特征表达；设计了动态信号控制机制，实现信号相位与持续时间的共同优化与调控。该方法有效优化了智能体对邻域信息的应用以及对细粒度信号控制。

（2）本文针对交通信号控制强化学习方法在迁移性、拓展性和泛化能力等方面的固有局限，探索将 LLM 引入交通信号控制领域，提出了一种基于强化学习辅助训练的动态交通信号控制大模型方法，构建了以 LLM 为决策主体的信号控制系统。针对通用 LLM 在专业领域知识不足的问题，提出了一种两阶段微调框架。采用预训练并冻结的强化学习模型作为辅助模型，隐式引导 LLM 的监督微调与对齐微调两阶段训练，使 LLM 掌握交通信号控制的基础知识、邻域信息的协同优化以及动态调控机制的内在逻辑，最终获得性能优异且迁移性、拓展性与泛化能力均良好的动态交通信号控制大模型，并且 LLM 还能为所做决策提供充分的自然语言解释，提高了深度学习模型在交通信号控制中的可信度。

（3）本文进一步探索了 LLM 在智能交通系统中更广泛的应用场景，构建了一个面向智能交通领域的通用智能体系统框架，通过集成交通领域专用工具模块，使智能体具备对复杂交通任务的分解、规划与执行能力。智能体系统通过调用相应的交通工具或子系统模块，能够完成诸如信号控制、仿真模拟、数据分析等多维度的交通任务，为未来智慧城市的交通管控提供新思路。

6.3 展望

本文方法在交通信号控制任务中已取得了良好的性能表现，但仍存在一些局限和不足，未来研究改进方向主要有以下两方面：

首先，当前研究主要集中在信号相位及其持续时间的控制上，未来可拓展至更多专业参数的综合优化，例如引入“绿信比”等关键指标，构建多维参数协同调控的交通信号控制系统。该系统可将路口几何特征、交通流组成、行人通行需求等多维度因素纳入决策变量范畴，同时建立具有差异化的参数模型，以克服单一控制策略在复杂场景下泛化能力不足的问题。

其次，现阶段的交通信号控制多聚焦于单个交叉口的局部优化。未来的一个重要研究方向是引入多智能体系统，设计高效的协同通信机制与分层控制架构，从而实现从单一交叉口到整个路网范围的全局协同优化，提升交通系统整体的运行效率与响应能力。

中国知网 https://www.cnki.net

参 考 文 献

[1] Dimitrakopoulos G, Demestichas P. Intelligent transportation systems [J]. IEEE Vehicular Technology Magazine, 2010, 5 (1): 77–84.

[2] Koonce P, et al. Traffic signal timing manual [R]. United States. Federal Highway Administration, 2008.

[3] Varaiya P. Max pressure control of a network of signalized intersections [J]. Transportation Research Part C: Emerging Technologies, 2013, 36: 177–195.

[4] Cools S-B, Gershenson C, D' Hooghe B. Self-organizing traffic lights: A realistic simulation [J]. Advances in applied self-organizing systems, 2008: 41–50.

[5] Chen C, Wei H, Xu N, et al. Toward a thousand lights: Decentralized deep reinforcement learning for large-scale traffic signal control [C]. In Proceedings of the AAAI conference on artificial intelligence, 2020: 3414–3421.

[6] Oroojlooy A, Nazari M, Hajinezhad D, et al. Attendlight: Universal attention-based reinforcement learning model for traffic signal control [C]. In Advances in Neural Information Processing Systems, 2020: 4079–4090.

[7] Wei H, Chen C, Zheng G, et al. Presslight: Learning max pressure control to coordinate traffic signals in arterial network [C]. In Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining, 2019: 1290–1298.

[8] Wei H, Xu N, Zhang H, et al. Colight: Learning network-level cooperation for traffic signal control [C]. In Proceedings of the 28th ACM international conference on information and knowledge management, 2019: 1913–1922.

[9] Wu Q, Zhang L, Shen J, et al. Efficient pressure: Improving efficiency for signalized intersections [J]. arXiv preprint arXiv:2112.02336, 2021.

[10] Zhang L, Wu Q, Shen J, et al. Expression might be enough: representing pressure and demand for reinforcement learning based traffic signal control [C]. In International Conference on Machine Learning, 2022: 26645–26654.

[11] Zhang L, Zhang Y, Xie S, et al. DynamicLight: Two-Stage Dynamic Traffic Signal Timing [J]. arXiv preprint arXiv:2211.01025, 2024.

[12] Zeng J, Yu C, Yang X, et al. CityLight: A Universal Model Towards Real-world City-scale Traffic Signal Control Coordination [J]. arXiv preprint arXiv:2406.02126, 2024.

[13] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J]. Advances in neural information processing systems, 2017, 30.

[14] Kaplan J, McCandlish S, Henighan T, et al. Scaling laws for neural language models [J]. arXiv preprint arXiv:2001.08361, 2020.

[15] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language

中国知网 https://www.cnki.net

models [J]. Advances in neural information processing systems, 2022, 35: 24824–24837.

[16] Feng G, Zhang B, Gu Y, et al. Towards revealing the mystery behind chain of thought: a theoretical perspective [J]. Advances in Neural Information Processing Systems, 2023, 36: 70757–70798.

[17] Da L, Gao M, Mei H, et al. Prompt to Transfer: Sim-to-Real Transfer for Traffic Signal Control with Prompt Learning [C]. In Proceedings of the AAAI Conference on Artificial Intelligence, 2024: 82–90.

[18] Pang A, Wang M, Pun M-O, et al. iLLM-TSC: Integration reinforcement learning and large language model for traffic signal control policy improvement [J]. arXiv preprint arXiv:2407.06025, 2024.

[19] Lai S, Xu Z, Zhang W, et al. LLMLight: Large Language Models as Traffic Signal Control Agents [C]. In Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1, 2025: 2335–2346.

[20] Zhang S, Fu D, Liang W, et al. Trafficgpt: Viewing, processing and interacting with traffic foundation models [J]. Transport Policy, 2024, 150: 95–105.

[21] Li S, Azfar T, Ke R. ChatSUMO: Large Language Model for Automating Traffic Scenario Generation in Simulation of Urban MObility [J]. arXiv preprint arXiv:2409.09040, 2024.

[22] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning [J]. nature, 2015, 518 (7540): 529–533.

[23] Van Hasselt H, Guez A, Silver D. Deep reinforcement learning with double q-learning [C]. In Proceedings of the AAAI conference on artificial intelligence, 2016.

[24] Wang Z, Schaul T, Hessel M, et al. Dueling network architectures for deep reinforcement learning [C]. In International conference on machine learning, 2016: 1995–2003.

[25] Hessel M, Modayil J, Van Hasselt H, et al. Rainbow: Combining improvements in deep reinforcement learning [C]. In Proceedings of the AAAI conference on artificial intelligence, 2018.

[26] Hester T, Vecerik M, Pietquin O, et al. Deep q-learning from demonstrations [C]. In Proceedings of the AAAI conference on artificial intelligence, 2018.

[27] Dabney W, Ostrovski G, Silver D, et al. Implicit quantile networks for distributional reinforcement learning [C]. In International conference on machine learning, 2018: 1096–1105.

[28] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms [J]. arXiv preprint arXiv:1707.06347, 2017.

[29] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016: 770–778.

[30] Ba J L. Layer normalization [J]. arXiv preprint arXiv:1607.06450, 2016.

[31] Howard J, Ruder S. Universal language model fine-tuning for text classification [J]. arXiv preprint arXiv:1801.06146, 2018.

[32] Peters M E, Neumann M, Iyyer M, et al. Deep contextualized word representations [J]. arXiv preprint arXiv:1802.05365, 2018.

中国知网 https://www.cnki.net

[33] Devlin J. Bert: Pre-training of deep bidirectional transformers for language understanding [J]. arXiv preprint arXiv:1810.04805, 2018.

[34] Liu Y. Roberta: A robustly optimized bert pretraining approach [J]. arXiv preprint arXiv:1907.11692, 2019, 364.

[35] Lan Z. Albert: A lite bert for self-supervised learning of language representations [J]. arXiv preprint arXiv:1909.11942, 2019.

[36] Yang Z. XLNet: Generalized Autoregressive Pretraining for Language Understanding [J]. arXiv preprint arXiv:1906.08237, 2019.

[37] Clark K. Electra: Pre-training text encoders as discriminators rather than generators [J]. arXiv preprint arXiv:2003.10555, 2020.

[38] Zhang Z, Han X, Liu Z, et al. ERNIE: Enhanced language representation with informative entities [J]. arXiv preprint arXiv:1905.07129, 2019.

[39] Sun Y, Wang S, Li Y, et al. Ernie 2.0: A continual pre-training framework for language understanding [C]. In Proceedings of the AAAI conference on artificial intelligence, 2020: 8968–8975.

[40] Radford A, Narasimhan K, Salimans T, et al. Improving Language Understanding by Generative Pre-Training [J]. OpenAI blog, 2018.

[41] Radford A, Wu J, Child R, et al. Language models are unsupervised multitask learners [J]. OpenAI blog, 2019, 1 (8): 9.

[42] Brown T B. Language models are few-shot learners [J]. arXiv preprint arXiv:2005.14165, 2020.

[43] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models [J]. arXiv preprint arXiv:2302.13971, 2023.

[44] Touvron H, Martin L, Stone K, et al. Llama 2: Open foundation and fine-tuned chat models [J]. arXiv preprint arXiv:2307.09288, 2023.

[45] Dubey A, Jauhri A, Pandey A, et al. The Llama 3 herd of models [J]. arXiv preprint arXiv:2407.21783, 2024.

[46] Bai J, Bai S, Chu Y, et al. Qwen technical report [J]. arXiv preprint arXiv:2309.16609, 2023.

[47] Yang A, Yang B, Hui B, et al. Qwen2 technical report [J]. arXiv preprint arXiv:2407.10671, 2024.

[48] Yang A, Yang B, Zhang B, et al. Qwen2.5 technical report [J]. arXiv preprint arXiv:2412.15115, 2024.

[49] Bi X, Chen D, Chen G, et al. Deepseek llm: Scaling open-source language models with longtermism [J]. arXiv preprint arXiv:2401.02954, 2024.

[50] Liu A, Feng B, Wang B, et al. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model [J]. arXiv preprint arXiv:2405.04434, 2024.

[51] Liu A, Feng B, Xue B, et al. DeepSeek-V3 technical report [J]. arXiv preprint arXiv:2412.19437, 2024.

中国知网 https://www.cnki.net

[52] Guo D, Yang D, Zhang H, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning [J]. arXiv preprint arXiv:2501.12948, 2025.

[53] Zhao W X, Zhou K, Li J, et al. A survey of large language models [J]. arXiv preprint arXiv:2303.18223, 2023, 1 (2).

[54] Arel I, Liu C, Urbanik T, et al. Reinforcement learning-based multi-agent system for network traffic signal control [J]. IET Intelligent Transport Systems, 2010, 4 (2): 128–135.

[55] Achiam J, Adler S, Agarwal S, et al. Gpt-4 technical report [J]. arXiv preprint arXiv:2303.08774, 2023.

[56] Hu E J, Shen Y, Wallis P, et al. Lora: Low-rank adaptation of large language models. [J]. ICLR, 2022, 1 (2): 3.

[57] Zhang H, Feng S, Liu C, et al. Cityflow: A multi-agent reinforcement learning environment for large scale city traffic scenario [C]. In The world wide web conference, 2019: 3620–3624.

[58] Carta T, Romac C, Wolf T, et al. Grounding large language models in interactive environments with online reinforcement learning [C]. In International Conference on Machine Learning, 2023: 3676–3713.

[59] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback [J]. Advances in neural information processing systems, 2022, 35: 27730–27744.

[60] Azar M G, Guo Z D, Piot B, et al. A general theoretical paradigm to understand learning from human preferences [C]. In International Conference on Artificial Intelligence and Statistics, 2024: 4447–4455.

[61] Ethayarajh K, Xu W, Muennighoff N, et al. Kto: Model alignment as prospect theoretic optimization [J]. arXiv preprint arXiv:2402.01306, 2024.

[62] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model [J]. Advances in Neural Information Processing Systems, 2023, 36: 53728–53741.

[63] Wei H, Zheng G, Gayah V, et al. A survey on traffic signal control methods [J]. arXiv preprint arXiv:1904.08117, 2019.

[64] Loshchilov I, Hutter F. Decoupled weight decay regularization [J]. arXiv preprint arXiv:1711.05101, 2017.

[65] Lopez P A, Behrisch M, Bieker-Walz L, et al. Microscopic traffic simulation using SUMO [C]. In 2018 21st international conference on intelligent transportation systems (ITSC), 2018: 2575–2582.

[66] Fellendorf M, Vortisch P. Microscopic traffic flow simulator VISSIM [J]. Fundamentals of traffic simulation, 2010: 63–93.

[67] Cameron G D, Duncan G I. PARAMICS—Parallel microscopic simulation of road traffic [J]. The Journal of Supercomputing, 1996, 10: 25–53.

[68] Duan Y, Yisheng L, Wang F-Y. Travel time prediction with LSTM neural network [C]. In 2016 IEEE

中国知网 https://www.cnki.net

19th international conference on intelligent transportation systems (ITSC), 2016: 1053–1058.

[69] Wang D, Zhang J, Cao W, et al. When will you arrive? Estimating travel time based on deep neural networks [C]. In Proceedings of the AAAI conference on artificial intelligence, 2018.

[70] Djuric N, Radosavljevic V, Cui H, et al. Uncertainty-aware short-term motion prediction of traffic actors for autonomous driving [C]. In Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, 2020: 2095–2104.

[71] Zhang P, Ouyang W, Zhang P, et al. Sr-lstm: State refinement for lstm towards pedestrian trajectory prediction [C]. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019: 12085–12094.

[72] Yang H, Yue S, He Y. Auto-gpt for online decision making: Benchmarks and additional opinions [J]. arXiv preprint arXiv:2306.02224, 2023.

[73] Qiao S, Zhang N, Fang R, et al. AutoAct: Automatic agent learning from scratch for QA via self-planning [J]. arXiv preprint arXiv:2401.05268, 2024.

[74] Islam M A, Ali M E, Parvez M R. Mapcoder: Multi-agent code generation for competitive problem solving [J]. arXiv preprint arXiv:2405.11403, 2024.

[75] Zhang W, Tang K, Wu H, et al. Agent-pro: Learning to evolve via policy-level reflection and optimization [J]. arXiv preprint arXiv:2402.17574, 2024.

[76] Qian C, Dang Y, Li J, et al. Experiential co-learning of software-developing agents [J]. arXiv preprint arXiv:2312.17025, 2023.

[77] Miller J J. Graph database applications and concepts with Neo4j [C]. In Proceedings of the southern association for information systems conference, Atlanta, GA, USA, 2013: 141–147.

[78] Wang P, Wei X, Hu F, et al. TransGPT: Multi-modal generative pre-trained transformer for transportation [C]. In 2024 International Conference on Computational Linguistics and Natural Language Processing (CLNLP), 2024: 96–100.

[79] Chen J, Xiao S, Zhang P, et al. BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation [J]. arXiv preprint arXiv:2402.03216, 2024.

[80] Xiao S, Liu Z, Zhang P, et al. C-Pack: Packed resources for general chinese embeddings [C]. In Proceedings of the 47th international ACM SIGIR conference on research and development in information retrieval, 2024: 641–649.

[81] Abid A, Abdalla A, Abid A, et al. Gradio: Hassle-Free Sharing and Testing of ML Models in the Wild [J]. arXiv preprint arXiv:1906.02569, 2019.

[82] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems [J]. arXiv preprint arXiv:2110.14168, 2021.

中国知网 https://www.cnki.net